

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ



دانشگاه اصفهان

دانشکده فنی و مهندسی

گروه مهندسی پزشکی

پایان نامه کارشناسی ارشد رشته‌ی مهندسی پزشکی
گرایش بیوالکتریک

استفاده از روش‌های تکاملی جهت بازشناسی حالت
عاطفی با استفاده از سیگنال الکتریکی مغز

استاد راهنما:

دکتر محمدرضا یزدچی

دانشجو:

پریچهر مرادی

بهمن ۱۴۰۰

کلیه حقوق مادی و معنوی مترتب بر نتایج مطالعات، ابتکارات و نوآوری‌های ناشی از تحقیق موضوع این رساله متعلق به دانشگاه اصفهان است. دانشجو موظف به رعایت آئین‌نامه و منشور اخلاق در پژوهش برای ارایه و یا چاپ مطالب مستخرج از رساله خود می‌باشد.



دانشگاه اصفهان
دانشکده فنی و مهندسی
گروه مهندسی پزشکی

پایان نامه کارشناسی ارشد رشته‌ی مهندسی پزشکی گرایش بیوالکتریک خانم پریچهر مرادی تحت عنوان

استفاده از روش‌های تکاملی جهت بازشناسی حالت
عاطفی با استفاده از سیگنال الکتریکی مغز

در تاریخ توسط هیئت‌داوران زیر بررسی و با درجه به تصویب نهایی رسید.

- | | | |
|------|-----------------|----------------------------------|
| امضا | با مرتبه‌ی علمی | ۱- استاد راهنمای پایان‌نامه دکتر |
| امضا | با مرتبه‌ی علمی | ۲- استاد مشاور پایان‌نامه |
| امضا | با مرتبه‌ی علمی | ۳- استاد داور داخل گروه |
| امضا | با مرتبه‌ی علمی | ۴- استاد داور خارج از گروه |

مهر و امضای مدیر گروه

تشکر و قدردانی

از استاد فرهیخته و بزرگوارم جناب آقای دکتر محمدرضا یزدچی که در کمال سعه صدر، با حسن خلق و فروتنی، از هیچ کمکی به من دریغ ننمودند و زحمت راهنمایی این پایان نامه را بر عهده گرفتند، کمال تشکر و قدردانی را دارم. همچنین از پدر و مادر عزیزتر از جانم که در تمامی مراحل زندگی و تحصیل مشوق و راهنمای من بوده‌اند، صمیمانه تشکر می‌کنم و سلامتی و شادی روزافزون ایشان را از خداوند بزرگ خواستارم.

چکیده

احساس نقش بسیار مهمی در برقراری ارتباط میان انسان‌ها ایفا می‌کند و تشخیص آن برای انسان‌ها به‌منظور درک رفتار متقابل از اهمیت بالایی برخوردار است. در سال‌های اخیر، با پیشرفت روش‌های یادگیری ماشین و به‌ویژه روش‌های یادگیری عمیق، در زمینه بازشناسی خودکار احساس پیشرفت‌های چشمگیری حاصل شده است. یکی از روش‌های رایج و کاربردی برای این منظور، شبکه‌های عصبی پیچشی است. اگرچه این شبکه‌ها از دو مشکل اساسی پیچیدگی شبکه و تعداد ابر پارامترهای زیاد رنج می‌برند، بسیاری از پژوهش‌ها برای حل مشکل دوم از روش‌های بهینه‌سازی ابر پارامترها استفاده می‌کنند. بهینه‌سازی ابر پارامترها فرآیندی برای یافتن ترکیب مناسبی از مقادیر ابر پارامترها به‌منظور دستیابی به حداکثر کارایی روی داده‌ها در مدت‌زمان معقول است. بیشتر شبکه‌های عمیق با مقادیر پیش‌فرض ابر پارامترها آموزش داده می‌شوند. مقادیر پیش‌فرض به‌طور معمول در بررسی شبکه‌های عمیق عملکرد خوبی ندارند، به همین دلیل باید آن‌ها را بهینه کرد تا ترکیب مناسبی را که بهترین عملکرد را دارد به دست آورد. فرآیند تنظیم ابر پارامترها شامل چهار روش اساسی؛ روش جستجوی شبکه‌ای، جستجوی تصادفی، روش بهینه‌سازی بیزی و روش‌های تکاملی (برای مثال الگوریتم بهینه‌سازی ازدحام ذرات، الگوریتم ژنتیک) است. درواقع ابر پارامترها برای تنظیم ساختار شبکه تعریف شده است بنابراین؛ مشکل یافتن ساختار بهینه یک شبکه عصبی پیچشی یک مشکل بهینه‌سازی ابر پارامترها مطرح می‌شود. هدف از بهینه‌سازی ابر پارامترها یافتن ساختاری است که تابع خطا را کمینه کند و یا معیارهای ارزیابی دیگر مانند صحت مدل را بیشینه کند. ابر پارامترهای شبکه عصبی پیچشی پیشنهادی که در این پژوهش تنظیم و تعدیل شدند، شامل تمامی لایه‌های مورد استفاده در این شبکه است. روش پیشنهادی از یک استراتژی لایه به لایه برای بهینه‌سازی ابر پارامترهای شبکه عصبی عمیق استفاده می‌کند. این کار با استفاده از الگوریتم ژنتیک چندهدفی، جهت بازشناسی و دسته‌بندی احساسات مبتنی بر سیگنال‌های مغزی انجام می‌شود. در این پایان‌نامه از دو مجموعه داده عمومی به نام‌های DEAP و SEED برای آموزش و ارزیابی روش پیشنهادی استفاده می‌شود. برای مجموعه داده DEAP، صحت ۹۶/۴۶، ۹۷/۵۴، ۹۸/۱۰، ۹۸/۱۸ به ترتیب برای ظرفیت، برانگیختگی، دوست داشتن و تسلط به‌دست‌آمده است. از طرف دیگر، برای مجموعه داده SEED، صحت بازشناسی احساسات به ۹۶/۱۴ درصد رسید. نتایج به‌دست‌آمده نشان می‌دهد که روش پیشنهادی نسبت به پیشرفته‌ترین روش‌ها قابل ملاحظه است.

کلیدواژه‌ها: واسط مغز و رایانه، سیگنال الکتریکی مغز، تشخیص احساسات، یادگیری عمیق، شبکه عصبی پیچشی، بهینه‌سازی چند هدفی

فهرست مطالب

عنوان	صفحه
فصل اول: مقدمه.....	۱
۱-۱ مقدمه.....	۱
۲-۱ واسط مغز و رایانه.....	۲
۳-۱ ثبت سیگنال واسط مغز و رایانه.....	۴
۱-۳-۱ ثبت تهاجمی.....	۵
۲-۳-۱ ثبت غیرتهاجمی.....	۵
۴-۱ دسته بندی و نام گذاری عواطف.....	۵
۵-۱ تعریف و بازشناسی حالات عاطفی.....	۸
۱-۵-۱ عواطف در حالت چهره.....	۸
۲-۵-۱ عواطف در گفتار.....	۹
۳-۵-۱ سیگنال های فیزیولوژی.....	۱۰
۶-۱ کاربردهای بازشناسی احساسات.....	۱۱
۷-۱ اهمیت و ارزش تحقیق.....	۱۱
۸-۱ ساختار پایان نامه.....	۱۲
فصل دوم: پیشینه پژوهش.....	۱۳
۱-۲ مقدمه.....	۱۳
۲-۲ منشا سیگنال های مغزی.....	۱۳
۳-۲ ثبت سیگنال الکتریکی مغز.....	۱۵
۴-۲ ریتم های مغزی.....	۱۷
۵-۲ انواع روش های تشخیص عواطف.....	۱۸
۶-۲ انواع روش های یادگیری.....	۱۹
۷-۲ یادگیری عمیق (DL).....	۲۰
۱-۷-۲ شبکه عصبی مصنوعی (ANN).....	۲۰
۲-۷-۲ شبکه های عصبی روبه جلو.....	۲۱
۳-۷-۲ توابع فعال سازی غیر خطی.....	۲۳
۸-۲ مروری بر روش های مختلف یادگیری عمیق.....	۲۵
۱-۸-۲ شبکه عصبی بازگشتی (RNN).....	۲۵
۲-۸-۲ شبکه عصبی حافظه طولانی کوتاه مدت (LSTM).....	۲۶
۳-۸-۲ ماشین بولتزمن محدود (RBM).....	۲۷
۴-۸-۲ شبکه باور عمیق (DBN).....	۲۷

۲-۸-۵ شبکه عصبی پیچشی (CNN).....	۲۷
۲-۹ بهینه‌سازی مختلف برای آموزش شبکه عصبی.....	۳۲
۲-۱۰ تنظیم ابر پارامترها.....	۳۳
۲-۱۰-۱ بهینه‌سازی چند هدفی به کمک الگوریتم‌های تکاملی.....	۳۴
۲-۱۰-۲ الگوریتم تکاملی ژنتیک چند هدفی (NSGA-II).....	۴۰
۲-۱۱ معرفی پایگاه داده‌های موجود.....	۴۲
۲-۱۲ پیشینه بازشناسی عواطف بر اساس سیگنال EEG.....	۴۳
۲-۱۳ جمع‌بندی.....	۴۸
فصل سوم: مواد و روش‌ها.....	۴۹
۳-۱ مقدمه.....	۴۹
۳-۲ مجموعه داده‌های استفاده‌شده برای ارزیابی روش‌های پیشنهادی.....	۴۹
۳-۲-۱ مجموعه داده DEAP.....	۴۹
۳-۲-۲ مجموعه داده SEED.....	۵۰
۳-۲-۳ بخش‌بندی و برچسب‌گذاری دوباره پایگاه داده DEAP.....	۵۱
۳-۳ روش پیشنهادی.....	۵۱
۳-۴ بهینه‌سازی ابر پارامترها.....	۵۳
۳-۵ شبکه عصبی پیچشی بهینه‌سازی شده.....	۵۷
۳-۵-۱ لایه پیچشی.....	۵۹
۳-۵-۲ لایه Pooling.....	۵۹
۳-۵-۳ لایه نرمال‌سازی دسته‌ای (BN).....	۵۹
۳-۵-۴ Dropout.....	۵۹
۳-۵-۵ لایه تمام متصل (FC).....	۶۰
۳-۵-۶ Softmax.....	۶۰
۳-۶ جمع‌بندی.....	۶۰
فصل چهارم: نتایج.....	۶۱
۴-۱ مقدمه.....	۶۱
۴-۲ جزییات پیاده‌سازی.....	۶۱
۴-۳ معیارهای ارزیابی دسته‌بندی.....	۶۲
۴-۴ تقسیم‌بندی مجموعه آموزش و آزمایش.....	۶۳
۴-۵ ارزیابی روش پیشنهادی.....	۶۳
۴-۵-۱ نتایج بر روی مجموعه داده DEAP.....	۶۳

صفحه	عنوان
۷۱	۴-۵-۲ نتایج برروی پایگاه داده SEED.....
۷۳	فصل پنجم: نتیجه گیری و پیشنهادها.....
۷۳	۵-۱ جمع بندی و نتیجه گیری.....
۷۶	۵-۲ پیشنهادهای فعالیت های آینده.....
۷۷	منابع و مآخذ.....

فهرست شکل‌ها

صفحه	عنوان
۳.....	شکل ۱-۱ واسط مغز و رایانه (BCI).....
۴.....	شکل ۱-۲ طبقه‌بندی سیگنال‌های مغزی.....
۷.....	شکل ۱-۳ فضای دوبعدی جاذبه-برانگیختگی.....
۸.....	شکل ۱-۴ مدل سه‌بعدی احساسات.....
۱۷.....	شکل ۲-۱ نحوه قرارگیری الکترودها.....
۱۹.....	شکل ۲-۲ طبقه‌بندی سیستم‌های تشخیص احساسات.....
۲۱.....	شکل ۲-۳ واحد محاسباتی.....
۲۳.....	شکل ۲-۴ شبکه روبه‌جلو چندلایه.....
۲۹.....	شکل ۲-۵ لایه کانولوشن.....
۳۰.....	شکل ۲-۶ تاثیر گام در خروجی.....
۳۰.....	شکل ۲-۷ Zero padding.....
۴۱.....	شکل ۲-۸ فاصله ازدحامی کل i
۴۱.....	شکل ۲-۹ فرآیند انتخاب جمعیت برتر NSGA-II.....
۵۲.....	شکل ۳-۱ ساختار کلی روش پیشنهادی.....
۵۳.....	شکل ۳-۲ چارچوب فرآیند بهینه‌سازی.....
۵۶.....	شکل ۳-۳ نمودار مختصات موازی، بهترین عملکرد ابر پارامترها در لایه پیچشی اول.....
۵۶.....	شکل ۳-۴ نمودار مختصات موازی، بهترین عملکرد ابر پارامترها در لایه FC اول.....
۵۷.....	شکل ۳-۵ نمودار برش، بهترین عملکرد ابر پارامترها در لایه FC اول.....
۵۸.....	شکل ۳-۶ معماری شبکه بهینه‌شده مجموعه داده DEAP.....
۶۴.....	شکل ۴-۱ ماتریس درهم‌ریختگی برای مجموعه آزمون پایگاه داده DEAP برای دسته ظرفیت بدون تنظیم ابر پارامترها.....
۶۵.....	شکل ۴-۲ منحنی acc مجموعه آموزش و اعتبارسنجی پایگاه داده DEAP برای دسته ظرفیت.....
۶۵.....	شکل ۴-۳ منحنی تابع هزینه مجموعه آموزش و اعتبارسنجی پایگاه داده DEAP برای دسته ظرفیت.....
۶۵.....	
۶۶.....	شکل ۴-۴ ماتریس درهم‌ریختگی برای مجموعه آزمون پایگاه داده DEAP برای دسته ظرفیت.....
۶۶.....	شکل ۴-۵ منحنی acc مجموعه آموزش و اعتبارسنجی پایگاه داده DEAP برای دسته برانگیختگی.....
۶۷.....	شکل ۴-۶ منحنی تابع هزینه مجموعه آموزش و اعتبارسنجی پایگاه داده DEAP برای دسته برانگیختگی.....
۶۷.....	شکل ۴-۷ ماتریس درهم‌ریختگی برای مجموعه آزمون پایگاه داده DEAP برای دسته برانگیختگی.....
۶۸.....	شکل ۴-۸ منحنی acc مجموعه آموزش و اعتبارسنجی پایگاه داده DEAP برای دسته تسلط.....

شکل ۴-۹	منحنی تابع هزینه مجموعه آموزش و اعتبارسنجی پایگاه داده DEAP برای دسته تسلط	۶۸
شکل ۴-۱۰	ماتریس درهم‌ریختگی برای مجموعه آزمون پایگاه داده DEAP برای دسته تسلط	۶۹
شکل ۴-۱۱	منحنی acc مجموعه آموزش و اعتبارسنجی پایگاه داده DEAP برای دسته دوست داشتن	۶۹
شکل ۴-۱۲	منحنی تابع هزینه مجموعه آموزش و اعتبارسنجی پایگاه داده DEAP برای دسته دوست داشتن	۷۰
شکل ۴-۱۳	ماتریس درهم‌ریختگی برای مجموعه آزمون پایگاه داده DEAP برای دسته دوست داشتن	۷۰
شکل ۴-۱۴	منحنی acc مجموعه آموزش و اعتبارسنجی پایگاه داده SEED	۷۱
شکل ۴-۱۵	منحنی تابع هزینه مجموعه آموزش و اعتبارسنجی پایگاه داده SEED	۷۱
شکل ۴-۱۶	ماتریس درهم‌ریختگی برای مجموعه آزمون پایگاه داده SEED	۷۲

فهرست جداول

صفحه	عنوان
۵.....	جدول ۱- ۱ خلاصه ای از ویژگی‌های سیگنال‌های مختلف مغز
۱۸.....	جدول ۱- ۲ طبقه‌بندی امواج مغزی.....
۲۴.....	جدول ۲- ۲ توابع فعالساز شبکه‌های عصبی.....
۴۲.....	جدول ۲- ۳ مجموعه داده‌های در دسترس عموم برای تشخیص احساسات.....
۵۰.....	جدول ۳- ۱ نگاه اجمالی به مجموعه داده DEAP.....
۵۴.....	جدول ۳- ۲ مقادیر مورد استفاده برای ابر پارامترهای لایه‌های شبکه.....
۵۵.....	جدول ۳- ۳ بهترین ابر پارامترهای یافت شده.....
.....	جدول ۴- ۱ گزارش دسته‌بندی برای مجموعه آزمون پایگاه داده DEAP برای دسته ظرفیت بدون
۶۴.....	تنظیم ابر پارامترها.....
۶۵.....	جدول ۴- ۲ گزارش دسته‌بندی برای مجموعه آزمون پایگاه داده DEAP برای دسته ظرفیت.....
۶۷.....	جدول ۴- ۳ گزارش دسته‌بندی برای مجموعه آزمون پایگاه داده DEAP برای دسته برانگیختگی.....
۶۸.....	جدول ۴- ۴ گزارش دسته‌بندی برای مجموعه آزمون پایگاه داده DEAP برای دسته تسلط.....
.....	جدول ۴- ۵ گزارش دسته‌بندی برای مجموعه آزمون پایگاه داده DEAP برای دسته دوست داشتن
۷۰.....	
۷۲.....	جدول ۴- ۶ گزارش دسته‌بندی برای مجموعه آزمون پایگاه داده SEED.....

فصل اول

مقدمه

۱-۱ مقدمه

عواطف به عنوان یک حالت روان‌شناختی و فیزیولوژی نقش مهمی در فعالیت‌های روزمره انسان و تعاملات او با سایر افراد جامعه بازی می‌کند. انسان‌ها اطلاعات عاطفی را به طور مداوم در طی فرآیند ارتباط منتقل می‌کنند. توانایی رایانه‌ها در درک احساسات انسانی و انجام اقدامات مناسب یکی از محورهای اصلی تحقیق در رابط‌های انسان رایانه^۱ (HCI) است. واسط مغز رایانه عاطفی^۲ (aBCI) از نظریه‌ها و روش‌های روان‌شناختی، علوم اعصاب و علوم کامپیوتر برای اندازه‌گیری و تشخیص حالات عاطفی و استفاده از نتایج برای بهبود تعامل با ماشین‌ها استفاده می‌کند. برای علوم اعصاب، محققان قصد دارند مدارهای عصبی و مکانیسم‌های مغزی پردازش احساسات را کشف کنند. در روانشناسی، بررسی نظریه‌های اساسی احساسات از تحقیقات مختلف و ساخت مدل‌های محاسباتی احساسات بسیار مهم است، به طور مثال شناخت حالات عاطفی بیمارانی با اختلالات بیان عاطفی در روند درمان موثر خواهد بود و در نهایت در علوم کامپیوتر، در زمینه یادگیری ماشین و تعامل انسان و رایانه تمرکز صورت گرفته است. محاسبات عاطفی^۳ (AC) قصد دارد که با ایجاد سیستم‌های محاسباتی که احساسات انسان را تشخیص داده و به آن‌ها پاسخ می‌دهد، فاصله ارتباطی بین انسان و کامپیوتر را کاهش دهد. اگرچه در سال‌های اخیر

¹ Human Computer Interaction

² Affective- Brain Computer-Interface

³ Affective Computing


محاسبات عاطفی شاهد پیشرفت‌های زیادی بوده است، اما هنوز با چالش‌هایی روبرو است [۱].

۲-۱ واسط مغز و رایانه

واسط مغز و رایانه یک ابزار ارتباطی قوی بین کاربران و سیستم‌ها است که توانایی مغز انسان را در برقراری ارتباط و تعامل مستقیم با محیط افزایش می‌دهد. پیشرفت در علوم اعصاب و علوم رایانه در دهه‌های گذشته منجر به پیشرفت‌های زیادی در سیستم‌های واسط مغز و رایانه شده است که آن را به‌عنوان یک تحقیقات بین‌رشته‌ای در علوم عصبی و هوش محاسباتی تبدیل کرده است. پیشرفت‌های اخیر در یادگیری ماشین و روش‌های یادگیری عمیق باعث افزایش علاقه به سیستم‌های واسط مغز و رایانه مبتنی بر سیگنال‌های الکتریکی مغز^۱ (EEG) برای کاربردهای مختلف شده است. سیستم‌های واسط مغز و رایانه از نظریه‌ها و روش‌های روان‌شناختی (مفاهیم و پروتکل‌ها)، علوم اعصاب (عملکرد مغز و پردازش سیگنال) و علوم رایانه (یادگیری ماشین و ارتباط انسان و رایانه) برای تحریک، اندازه‌گیری و تشخیص حالات احساسی استفاده می‌کند و از اطلاعات به‌دست‌آمده برای بهبود تعامل با ماشین‌ها استفاده می‌کند [۱].

شکل ۱-۱ چهارچوب کلی یک سیستم واسط مغز و رایانه را نشان می‌دهد که سیگنال‌های مغزی را دریافت کرده و آن‌ها را به دستورات کنترلی برای رایانه‌ها تبدیل می‌کند. این سیستم شامل چندین جز کلیدی که شامل جمع‌آوری سیگنال مغز، پیش‌پردازش سیگنال، استخراج ویژگی‌ها، طبقه‌بندی و تجهیزات هوشمند است. سیگنال‌های مغزی جمع‌آوری شده از مغز انسان برای حذف نویز و بهبود به بخش پیش‌پردازش فرستاده می‌شوند. سپس، ویژگی‌های مناسب از سیگنال‌های پردازش شده استخراج می‌شوند و به طبقه‌بندی ارسال می‌شوند که وظیفه تشخیص فرمان ذهنی کاربر را دارند. این سیستم‌ها به‌طور معمول از بازخورد جهت تصحیح و بهبود کارایی سیستم استفاده می‌شود [۱].

^۱ Electroencephalography



شکل ۱-۱ واسط مغز و رایانه (BCI) [۱]

روش های جمع آوری از سیگنالی به سیگنال دیگر متفاوت است. برای مثال، سیگنال های الکتریکی مغز نوسان های ولتاژ ناشی از جریان یونی در نورون های مغز را اندازه گیری می کنند. جمع آوری سیگنال های الکتریکی مغز مستلزم قرار دادن یک سری الکتروود بر روی پوست سر انسان برای ثبت فعالیت الکتریکی مغز است. از آنجایی که جریان یونی تولید شده در مغز روی پوست سر اندازه گیری می شود، موانع (برای مثال مجموعه) کیفیت سیگنال را تا حد زیادی کاهش می دهند. قابلیت اطمینان سیگنال های الکتریکی مغز جمع آوری شده که به عنوان نسبت سیگنال به نویز^۱ (SNR) اندازه گیری می شود، تقریباً پنج درصد سیگنال های اصلی مغز است [۲]؛ بنابراین، سیگنال EEG به طور معمولی قبل از استخراج ویژگی برای افزایش نسبت سیگنال به نویز پیش پردازش می شوند. در مرحله پیش پردازش باید بخش های اضافی و نویزها مانند نویز برق شهر و همچنین درست نماهای حرکتی مانند حرکت چشم و پلک زدن از سیگنال های ثبت شده حذف شوند. پس از آنکه داده ها حذف نویز شدند، همچنان با حجم وسیعی از داده ها مواجه هستیم. هدف از استخراج ویژگی پیدا کردن ویژگی هایی است که حاوی اطلاعات مورد نیاز برای تشخیص احساسات است. به طور کلی ویژگی ها به سه دسته ویژگی های حوزه زمان (مانند میانگین سیگنال، ویژگی های Hjorth، عبور از صفر مرتبه بالا^۲)، حوزه فرکانس (مانند توان باند، تبدیل موجک گسسته) و حوزه های زمان و فرکانس (مانند طیف Hilbert-Huang) استخراج می شوند. استخراج دستی ویژگی ها نیز زمان بر و دشوار است. اخیراً یادگیری عمیق^۳ گزینه بهتری برای استخراج خودکار ویژگی های مناسب ارائه می دهد. پس از تعیین ویژگی های مناسب و تشکیل بردار ویژگی، نوبت به تصمیم گیری

¹ Signal to Noise Ratio

² Higher Order Crossings

³ Deep Learning

۱-۳ ثبت سیگنال واسط مغز و رایانه

[illegible]

شکل ۱-۲ طبقه‌بندی سیگنال‌های مغزی [۵]

³ Cerebral Cortex

۱-۳-۱ ثبت تهاجمی

ثبت‌های تهاجمی توسط الکترودهایی در زیرپوست سر به دست می‌آید. روش‌های تهاجمی می‌توانند سیگنال‌های مغزی باکیفیت بالا را ارائه دهند زیرا الکترودها سیگنال‌ها را مستقیماً از مکان‌های نزدیک به نورون‌های مغز جمع‌آوری می‌کنند. با این وجود، روش‌های تهاجمی با چالش‌هایی روبرو هستند. اول، کاشت الکترودها نیاز به یک روش جراحی دارد که به دلیل عوارض بالقوه پزشکی مانند رد پیوند، پرهزینه و خطرناک است. دوم، الکترودهای کاشته شده ثابت هستند و بنابراین فقط می‌توانند سیگنال‌های مغز را از همان مکان‌ها اندازه‌گیری کنند. به دلایل فوق، روش‌های تهاجمی واسطه مغز و رایانه عمدتاً در حیوانات (مانند میمون و موش صحرایی) و برای افراد دارای ناتوانی شدید (مانند بیماران ALS) در عمل استفاده می‌شود [۵].

۱-۳-۲ ثبت غیرتهاجمی

سیگنال‌های غیرتهاجمی عمدتاً شامل سیگنال الکتریکی مغز (EEG)، طیف‌نگاری کارکردی مادون قرمز نزدیک^۱ (fNIRS)، تصویربرداری تشدید مغناطیسی عملکردی^۲ (fMRI)، الکترواکولوگرافی^۳ (EOG) و مگنتوآنسفالوگرافی^۴ (MEG) هستند. سیگنال الکتریکی مغز رایج‌ترین روش غیرتهاجمی مورد استفاده برای اندازه‌گیری فعالیت‌های مغز است [۵]. ویژگی‌های اساسی سیگنال‌های مختلف مغز در جدول ۱-۱ خلاصه شده است.

جدول ۱-۱ خلاصه ای از ویژگی‌های سیگنال‌های مختلف مغز [۵]

سیگنال‌ها	تهاجمی		غیرتهاجمی				
	درون قشر	EcoG	EEG	fNIRS	fMRI	EOG	MEG
خطر	بالا	بالا	کم	کم	کم	کم	کم
وضوح مکانی	خیلی بالا	بالا	کم	متوسط	بالا	کم	متوسط
وضوح زمانی	بالا	بالا	متوسط	کم	کم	متوسط	بالا
نسبت سیگنال به نویز	بالا	بالا	کم	کم	متوسط	متوسط	کم
قابلیت حمل	متوسط	متوسط	بالا	بالا	کم	بالا	کم
هزینه	بالا	بالا	کم	کم	بالا	کم	بالا
مشخصات	الکتریکی	الکتریکی	الکتریکی	نوری	متابولیک	الکتریکی	مغناطیسی

۱-۴ دسته بندی و نام گذاری عواطف

مدل کردن احساسات از جنبه‌های مهم اندازه‌گیری عاطفی است زیرا این امکان را می‌دهد تا ارزیابی دقیق‌تری از حالات احساسی انجام گیرد. برای مدل‌سازی حالات عاطفی، محققان نظریه‌های فراوانی را ارائه نموده‌اند که دو مدل آن بسیار پرکاربرد است، مدل گسسته احساسات اکمن و همکاران [۶] و مدل

^۱ Functional Near Infrared Spectroscopy

^۲ Functional Magnetic Resonance Imaging

^۳ Electrooculography

^۴ Magnetoencephalography

دوبعدی ظرفیت^۱ و برانگیختگی^۲ که توسط راسل و همکاران [۷] ارایه شد.

تعداد دقیق احساسات اساسی مورد بحث است و بین دانشمندان اختلاف وجود دارد. مدل احساسات گسسته ادعا می‌کند که بعضی احساسات اساسی به‌طور جهانی در میان همه فرهنگ‌ها وجود دارد. اکمن احساسات را گسسته، قابل اندازه‌گیری و مرتبط با فیزیولوژی بدن در نظر گرفت و شادی^۳، ناراحتی^۴، خشم^۵، نفرت^۶، تعجب^۷ و ترس^۸ را به‌عنوان احساسات پایه در نظر گرفت و سایر احساسات را ترکیب این احساسات اساسی دانست. در مدل احساسات چندبعدی، دانشمندان دریافتند که بین احساسات جداگانه مانند دشمنی و نفرت، لذت و دوست داشتن رابطه خاصی وجود دارد که نمایانگر درجه خاصی از سطح عاطفی است. از طرف دیگر، احساسات با همان توصیفات ممکن است شدت‌های مختلفی داشته باشند. برای مثال، احساس شادی را می‌توان کمی شاد یا بسیار شاد توصیف کرد. در مدل دوبعدی احساسات، می‌توان احساسات مختلف را در فضای دوبعدی ظرفیت و برانگیختگی ترسیم کرد. محور عمودی برانگیختگی که نشان‌دهنده شدت احساسات است و گستره‌ی آن از برانگیختگی کم تا برانگیختگی زیاد است که درواقع بعد هیجان ذهنی ایجادشده ناشی از احساس است و محور افقی ظرفیت که به معنی حسی است که در فرد ایجاد می‌شود و گستره‌ی آن از منفی تا مثبت متغیر است. در این حالت بسته به درجه‌ی هر بعد، احساس موردنظر به یکی از چهار دسته برانگیختگی کم و ظرفیت کم^۹ (LALV)، برانگیختگی کم و ظرفیت زیاد^{۱۰} (LAHV)، برانگیختگی زیاد و ظرفیت کم^{۱۱} (HALV) و ظرفیت زیاد^{۱۲} (HALV) تعلق پیدا می‌کند. برای مثال از آنجاکه هیجان یک حس درونی با ظرفیت بالا و برانگیختگی زیاد است، این حس در بخش بالا و سمت راست این مدل دوبعدی قرار می‌گیرد و یا نقطه مقابل حس هیجان که افسردگی است در قسمت پایین و سمت چپ این مدل قرار می‌گیرد. در اکثر پژوهش‌های انجام‌شده درزمینه‌ی تشخیص احساسات از این مدل بهره گرفته‌شده است [۸].

¹ Valance

² Arousal

³ Happiness

⁴ Sadness

⁵ Anger

⁶ Disgust

⁷ Surprise


⁸ Fear

⁹ Low Arousal – Low Valance

¹⁰ Low Arousal – High Valance

¹¹ High Arousal – High Valance

¹² High Arousal – Low Valance




شکل ۱-۳ فضای دوبعدی جاذبه-برانگیختگی [۸]

در مدل‌های پیوسته عمدتاً از آدمک‌های خودآزمایی^۱ که توسط لانگ برای گزارش میزان برانگیختگی عاطفی توسط شخص تحریک‌شده مطرح شد، استفاده می‌شود [۹]. این مدل خودآزمایی یک روش غیرکلامی و تصویری است که به‌طور مستقیم میزان ظرفیت و برانگیختگی مرتبط با تحریک عاطفی را در طول آزمایش نشان می‌دهد. به‌منظور دریافت امتیاز کاربران پرسشنامه‌ای طراحی شد و از شرکت کنندگان خواسته می‌شود که برای هر یک از ابعاد ظرفیت و برانگیختگی به‌صورت جداگانه به احساس خود درجه‌ای بین ۱ تا ۹ اختصاص دهند. در این فرم دو ردیف از آدمک‌های ذکرشده قرار گرفته است که آدمک‌های ردیف اول میزان ظرفیت یعنی میزان مثبت یا منفی بودن احساس را نشان می‌دهد. آدمک‌هایی که در حال خندیدن هستند عواطف مثبت و آدمک‌های ناراحت عواطف منفی را نشان می‌دهند. در ردیف دوم آدمک‌ها سطح برانگیختگی احساسات را نشان می‌دهند که هرچه علامت روی بدن آدمک بزرگ‌تر شود به این معنی است که عواطف فرد بیشتر فعال و برانگیخته شده است.

مدل دوبعدی می‌تواند احساسات زیادی را تعریف کند، اما این احتمال وجود دارد که این مدل نتواند احساساتی را که دارای همان سطح برانگیختگی و ظرفیت هستند، متمایز کند. برای مثال، عصبانیت و ترس دو احساس متفاوت هستند، اما هر دو سطح برانگیختگی بالا و از ظرفیت منفی برخوردار هستند. از این‌رو، برای تمایز بین این موارد، بعد سوم به نام تسلط^۲ معرفی می‌شود و نسخه گسترده‌ای از مدل دوبعدی به دست می‌آید، همان‌طور که در شکل ۱-۴ نشان داده شده است بعد سوم در این مدل گسترده، کنترل احساسات را نشان می‌دهد. استفاده از مدل سه‌بعدی یعنی ظرفیت، برانگیختگی و تسلط به دلیل پیچیدگی در محاسبات و تحلیل، کمتر از مدل دوبعدی آن مورد استفاده قرار گرفته شده است [۱۰].

^۱ Self-Assessment Manikins (SAM)

^۲ Dominance



شکل ۱-۴ مدل سه بعدی احساسات [۱۰]

۵-۱ تعریف و بازشناسی حالات عاطفی

با پیشرفت فناوری، محاسبات عاطفی نقش مهمی در تعیین رفتار پیچیده انسان دارد. احساس یک پاسخ ذهنی به محرک‌های بیرونی است که شامل چهار مولفه است:

- (۱) واکنش‌های رفتاری^۱
- (۲) واکنش‌های بروز حالت^۲
- (۳) واکنش‌های فیزیولوژی^۳
- (۴) تجربه ذهنی و درونی^۴

احساسات در تمام شیوه‌های ارتباطی انسان مانند زبان، آهنگ گفتار، حالت چهره، حرکت و وضعیت بدن و همچنین چندین پارامتر فیزیولوژی مانند هدایت پوست، تنفس و ضربان قلب منتقل می‌شوند. استفاده از عکس‌العمل‌های بروز حالت مانند تن صدا و چهره‌ی شخص مشکلاتی از قبیل پنهان کردن احساس توسط فرد را دارد که اندازه‌گیری احساس را مشکل می‌کند. در مقایسه با رویکردهای رفتاری و بروز حالت، سیگنال‌های فیزیولوژی صحت شناسایی بالایی را نشان می‌دهند [۱۱].

۵-۱-۱ عواطف در حالت چهره

شناخت احساسات انسانی از حالات چهره و گفتار، یعنی شناخت احساسات شنیداری و بصری، به دلیل کاربردهای مهمی که در تعامل رایانه و انسان دارد، توجه گسترده‌ای را در حوزه هوش مصنوعی جلب کرده است. احساسات صورت عامل مهمی در ارتباطات انسانی است که به ما کمک می‌کند اهداف دیگران

^۱ Behavioral Reactions

^۲ Expressive Reactions

^۳ Physiological Reactions

^۴ Subjective Feelings

را درک کنیم. به طور کلی، افراد با استفاده از حالت‌های چهره و گفتار، حالات عاطفی مانند شادی، غم و عصبانیت افراد دیگر را استنباط می‌کنند. بررسی‌های مختلف نشان می‌دهد که مولفه‌های کلامی یک سوم ارتباطات انسانی و مولفه‌های غیرکلامی دو سوم را منتقل می‌کنند. در میان چندین مولفه غیرکلامی حامل احساسات، حالات چهره یکی از کانال‌های اصلی اطلاعات در ارتباطات بین فردی است. تشخیص حالات چهره^۱ شامل شناسایی و ردیابی چهره، تشخیص و استخراج ویژگی است. برای تشخیص هرگونه احساس در تصویر، سیستم پیشنهادی ابتدا با شناسایی چهره‌های موجود در تصویر و با پنهان کردن قسمت‌های غیرضروری و تجزیه مساله‌ها به چند مساله فرعی و سپس با اعمال یک الگوریتم یادگیری ماشین سعی دارد الگوهایی را پیدا کند که با ویژگی‌های موجود در چهره مانند چشم، لب، سروصدا، گوش، مو و ابرو مطابقت داشته باشد. سرانجام، احتمال احساسات اساسی موجود در چهره‌های شناسایی شده محاسبه می‌شود و صورت بر اساس حداکثر مقدار احساسات شناسایی شده برچسب‌گذاری می‌شود [۱۲]. کار [۱۳]، یک سیستم تعامل انسان و ربات^۲ (FEER-HRI) مبتنی بر تشخیص احساسات از طریق پردازش چهره ایجاد کرد. سیستم FEER-HRI ربات‌ها را قادر می‌سازد نه تنها احساسات انسان را تشخیص دهند، بلکه همچنین برای ایجاد سازگاری با احساسات انسانی حالت چهره ایجاد می‌کنند.

۱-۵-۲ عواطف در گفتار

گفتار واسطه‌ای موثر برای بیان احساسات از طریق زبان است. یافتن محتوای احساسی از یک سیگنال گفتاری و شناسایی احساسات ناشی از گفته‌ها وظیفه مهمی برای محققان است. فرد احساسات و استرس خود را از طریق حرکات مختلف و تعدیل گفتار بیان می‌کند. تشخیص احساسات از طریق گفتار^۳ به عنوان یک زمینه تحقیقاتی مهم در دهه اخیر مورد توجه قرار گرفته است. مشکلات ذاتی رمزگشایی حالت عاطفی گوینده از صدا به دلیل عواملی مانند آنچه گفته می‌شود (عامل ۱)، نحوه گفتن (عامل ۲) و چه کسی آن را می‌گوید (عامل ۳) به وجود می‌آیند. در دلیل اول، گفتار نشان‌دهنده اطلاعات منشا زبانی است و به نحوه تلفظ کلمات به عنوان نماینده زبان‌بستگی دارد، در حالی که عامل دوم اطلاعات زبانی مربوط به وضعیت عاطفی گوینده را به همراه دارد. عامل سوم شامل اطلاعاتی در مورد ویژگی‌ها و هویت‌های اصلی گوینده مانند سن، جنس و اندازه بدن است. به همین دلیل است که بیرون کشیدن هرگونه اطلاعات احساسی خاص از صدای یک فرد بسیار دشوار است [۱۴].

اگرچه این دو روش دو عامل اصلی بیان احساسات انسان‌ها است و در ثبت آن کاربر احساس راحتی بیشتری می‌کند، با این وجود این روش‌ها بیشتر در معرض فریب و پوشاندن احساسات واقعی توسط کاربر قرار دارند و تحت شرایط مختلف تغییرات متفاوتی دارند، علاوه بر این کنترل حالات صورت یا گفتار بسیار آسان است و افراد می‌توانند احساسات واقعی خود را به خصوص در هنگام ارتباطات اجتماعی پنهان کنند، با این تفاسیر این دو روش قابلیت اطمینان خود را از دست می‌دهند [۱۱].

^۱ Facial Expression Recognition

^۲ Facial Expression Emotion Recognition Based Human-Robot Interaction

^۳ Speech Emotion Recognition

۱-۵-۳ سیگنال های فیزیولوژی

روابط بین احساسات خاص و واکنش های بدن انسان مدت هاست که شناخته شده است، اما عدم قطعیت های زیادی در انتخاب روش های اندازه گیری و تجزیه و تحلیل داده ها وجود دارد. در مقایسه با رویکردهای مبتنی بر سمعی و بصری، سیگنال های فیزیولوژی صحت شناسایی بالایی را نشان می دهند. سیگنال های فیزیولوژی که شامل سیگنال الکتریکی مغز (EEG)، دما^۱ (T)، سیگنال الکتریکی قلب^۲ (ECG)، سیگنال الکتریکی ماهیچه^۳ (EMG)، پاسخ پوست گالوانیک (GSR)، تنفس (RSP) و غیره است، شکل زیر موقعیت سانسورهای فیزیولوژی را نشان می دهد. برای مثال سیگنال های ضربان قلب، در تشخیص رفتار اضطرابی انسان کمک می کند. اضطراب یک احساس منفی است که بر قلب و فعالیت های اجتماعی یک فرد تاثیر می گذارد. علائم فیزیولوژی اضطراب اجتماعی شامل تپش قلب، لرز، تعریق و غیره است.

دو نوع تغییرات فیزیولوژی مربوط به احساسات وجود دارد: یکی مربوط به سیستم عصبی محیطی^۴ (PNS) و دیگری مربوط به سیستم عصبی مرکزی^۵ (CNS) است. سیستم عصبی محیطی از سیستم های عصبی خودمختار^۶ و پیکری^۷ (ANS و SNS) تشکیل شده است. سیستم عصبی خودمختار از نورون های حسی و حرکتی تشکیل شده است که بین سیستم عصبی مرکزی و اندام های مختلف داخلی مانند قلب، ریه ها، احشا و غدد عمل می کنند. این سیستم عصبی وظیفه کنترل عملکردهای بدن انسان مانند ضربان قلب، تنفس، هضم، تحریک و غیره را بر عهده دارد. احساسات بر فعالیت سیستم عصبی خودمختار که زیرمجموعه سیستم عصبی محیطی است تاثیر می گذارد این سیستم ماهیچگان و غدد را تامین کرده و بر روی عملکرد اعضای داخلی اثرگذار است و به دو بخش سمپاتیک و پاراسمپاتیک تقسیم می شود. سیستم سمپاتیک (تحریک کننده) باعث ایجاد تغییراتی در اعضای بدن می شود که بدن در برابر فشار روانی مقاومت می کند دستگاه عصبی سمپاتیک در حالت استرس فعال تر شده و باعث افزایش فشارخون، افزایش تعداد تنفس، افزایش ضربان قلب و گشاد شدن مردمک می شود. سیستم پاراسمپاتیک (بازدارنده) عملکرد طبیعی را حفظ کرده و تمایل به ذخیره انرژی دارد و منابع بدن را حفظ می کند. میزان ضربان قلب و فشارخون را کاهش داده، باعث افزایش فعالیت گوارشی، انقباض مجرای برونشی و انقباض مردمک ها می گردد. به طور معمول ویژگی های استخراج شده از سیگنال های فیزیولوژی محیطی اطلاعات دقیق و پیچیده ای را برای شناخت حالات احساسی فراهم می کنند [۱۰].

در مقایسه با سیگنال هایی که از سیستم عصبی محیطی گرفته می شود رویکرد دیگری وجود دارد که بر روی سیگنال های گرفته شده از سیستم اعصاب مرکزی تمرکز دارد و فعالیت مغز را مستقیماً منعکس می کند. درون سیستم عصبی مرکزی، عصب های آوران وجود دارد که از طناب نخاعی یا ساقه مغز به

¹ Temperature

² Electrocardiogram

³ Electromyography

⁴ Peripheral Nervous System

⁵ Central Nervous System

⁶ Autonomic Nervous Systems

⁷ Somatic Nervous Systems

نواحی مختلف مغز می‌رسند و اطلاعات مربوط به تغییرات محیط خارجی بدن را انتقال می‌دهند. در میان روش‌های اندازه‌گیری فعالیت‌های مغزی از سیستم عصبی مرکزی مانند سیگنال الکتریکی مغز، پتانسیل وابسته به رویداد^۱ (ERP) الکتروکورتیکوگرافی، تصویربرداری تشدید مغناطیسی عملکردی، برش‌نگاری با گسیل پوزیترون^۲ (PET)، سیگنال الکتریکی مغز ویژگی‌های مفیدی در پاسخ به حالات احساسی ارائه می‌دهد. این سیگنال بازتاب و بیان مستقیم احساسات هستند و ارتباط آن با احساسات انسانی نیز توسط بسیاری از مطالعات فیزیولوژی مرتبط اثبات شده است [۱].

۱-۶ کاربردهای بازشناسی احساسات

نتایج این تحقیق به صورت کلی، به ارائه مدلی دقیق از عواطف، به منظور وارد کردن آن در هوش مصنوعی می‌پردازد. نتایج این گونه روش‌های بازشناسی خودکار حالت‌های عاطفی باعث درک بهتر و عمیق‌تر از احساسات و عواطف برای علوم روانشناسی، انسان‌شناسی، شناخت، فلسفه ذهن و غیره می‌شود [۱۵].

- بهبود ارتباط انسان و رایانه: ساخت ربات‌هایی که احساسات انسان را درک کنند و پاسخ مناسب بدهند، شناخت احساسات در برنامه‌های هوشمند تعامل انسان و رایانه مانند واقعیت مجازی، بازی‌های ویدیویی و دستگاه‌های آموزشی مهم است.
- در حوزه روانشناسی: کمک به درمان بیماری‌هایی مانند آلزایمر، اختلال اضطراب، افسردگی، پارکینسون، ترس، اختلالات خواب، اوتیسم و غیره.
- در حوزه پزشکی: کمک به بیمارانی که به دلیل بیماری قادر به بیان احساسات خود نیستند.
- تعیین خودکار رضایت‌مندی: در حوزه تجاری برای تعیین میزان خوشایندی یا ناخوشایندی افراد برای استفاده از خدمات، احساسات فرد محاسبه و بررسی می‌شود، همچنین واکنش عاطفی در پاسخ به فرمت‌های مختلف تبلیغات آنلاین اندازه‌گیری می‌شود.

۱-۷ اهمیت و ارزش تحقیق

سیگنال‌های الکتریکی مغزی ثبت شده با استفاده از الکترودهای روی جمجمه، می‌تواند به طور مستقیم پویایی مغز در پاسخ به حالت‌های عاطفی مختلف را شناسایی کند. در سال‌های اخیر، بازشناسی حالات عاطفی با استفاده از سیگنال الکتریکی مغز توجه زیادی به خود جلب کرده است. علاوه بر روش‌های موجود در تشخیص احساسات مبتنی بر سیگنال الکتریکی مغز، برخی از محققان شروع به استفاده از شبکه‌های عصبی عمیق در این حوزه کرده‌اند. اگرچه روش‌های یادگیری عمیق دستاوردهای بسیاری به دست آورده‌اند، اما طراحی یک مدل یادگیری عمیق تا حد قابل توجهی یک فرآیند زمان‌بر و طولانی است؛ بنابراین یکی از هدف‌های مهم این تحقیق بهینه‌سازی ابر پارامترها در شبکه عصبی پیچشی است. هر شبکه عصبی پیچشی دارای ابر پارامترهایی است که به صورت دستی انتخاب می‌شوند و برای مدل‌ها و مجموعه داده‌های مختلف متفاوت است. زمانی که ساختار شبکه عصبی پیچیده باشد، زمان مصرفی زیاد و محاسبات پیچیده می‌شود. برای جلوگیری از این امر، در این پایان‌نامه با استفاده از الگوریتم تکاملی ژنتیک چند هدفی NSGAII چند ابر پارامتر مهم را در نظر گرفته که الگوریتم در فرایند تکاملی،

¹ Event Related Potential

² Positron Emission Tomography

به دنبال بهترین ترکیب آن‌ها می‌گردد. این روش خودکار انتخاب ابر پارامترهای شبکه عصبی پیچشی جهت بالا بردن صحت تشخیص احساسات با استفاده از سیگنال الکتریکی مغز ترکیب و تطبیق داده شده است.

۸-۱ ساختار پایان نامه

این پایان نامه در پنج فصل تدوین شده است. در فصل اول مقدمه‌ای در مورد عواطف و لزوم بازشناسی خودکار آن شرح داده شده است. سپس اشاره‌ای به روش‌های مختلف نام‌گذاری عواطف شد و در نهایت کاربردهای بازشناسی خودکار عواطف در حوزه‌های مختلف بیان شده است. در فصل دوم علاوه بر توضیح مختصری در خصوص ساختار مغز انسان و سیگنال الکتریکی مغز به معرفی مفاهیم یادگیری عمیق، مبانی تئوری تحقیق و مجموع داده‌های پرکاربرد در حوزه تشخیص احساسات معرفی می‌شود. همچنین پژوهش‌های انجام شده مرتبط با تشخیص احساسات در حوزه‌های مختلف به صورت اجمالی بررسی می‌شود. در فصل سوم، ابتدا مجموع داده‌های استفاده شده در این پژوهش بررسی خواهد شد و الگوریتم پیشنهادی و نحوه‌ی عملکرد آن به منظور بهینه‌سازی ابر پارامترهای شبکه عصبی پیچشی مطرح می‌شود. در فصل چهارم، نتایج و ارزیابی روش پیشنهادی مورد بحث قرار می‌گیرد. در فصل پنجم، به مقایسه و جمع‌بندی نتایج به دست آمده پرداخته می‌شود و نیز پیشنهادهای لازم برای فعالیتهای آینده ذکر می‌شود.

فصل دوم

پیشینه پژوهش

۱-۲ مقدمه

همان‌طور که در فصل قبل گفته شد، توانایی تشخیص حالات عاطفی انسان‌ها بخش مهمی از ارتباطات طبیعی آن‌ها است. با توجه به هجوم ماشین‌ها و رایانه‌ها، تعامل احساسات بین انسان و ماشین به یکی از مهم‌ترین مساله‌ها در ارتباطات بین انسان و ماشین و واسطه‌های مغز و رایانه تبدیل شده است. در این فصل سعی بر این است که به بررسی مبانی و مفاهیم مرتبط با سه حوزه تحقیقاتی (شبکه‌های عصبی، یادگیری عمیق و الگوریتم‌های تکاملی) که به موضوع این پایان‌نامه مرتبط هستند، پرداخته شود، سپس پژوهش‌های مرتبط با تشخیص احساسات با استفاده از EEG بررسی خواهد شد.

۲-۲ منشا سیگنال‌های مغزی

مغز انسان به‌منزله مرکز فرمان دستگاه عصبی انسان است. فعالیت الکتریکی در مغز در محیط قابل تحریک صورت می‌گیرد که این محیط شامل آکسون‌ها، سیناپس‌ها، غشای دندریت‌ها و کانال‌های یونی است. بااینکه ارتباطات بین اکثر نواحی قشر مغز (۸۰ درصد) به‌صورت حلقه‌های بازگشتی است، هیچ‌گونه ناپایداری در مغز سالم وجود ندارد. وقتی سلولی تحریک می‌شود نمی‌تواند مجدداً تحریک شود مگر اینکه مجدداً به حالت استراحت خود برسد. به این دوره زمانی که یک سلول نیاز دارد تا امکان تحریک مجدد آن وجود داشته باشد، دوره بی‌پاسخی^۱ نامیده می‌شود. این دوره‌های بی‌پاسخی در مغز به‌طور معمول طولانی است که باعث پایداری و خودتنظیمی قشر مغز می‌شود. بنابراین سیگنال الکتریکی

^۱ Refractory Period

ویژگی از محیط تحریکی آکسون‌ها و سیناپس‌ها است و به ثبت پتانسیلی اطلاق می‌شود که توسط حرکت خود به خودی و ریتمیک نوروهای مغز بر اساس ترتیب زمانی رخ می‌دهد. محل اصلی تولید الکتریسیته، پتانسیل الکتریکی و میدان مغناطیسی، در نوروهای مغز است. یک قطعه کوچک از مغز، به اندازه دانه برنج، حاوی بیش از ۱۰,۰۰۰ سلول عصبی است که هر یک به طور متوسط ۶۰۰۰ ارتباط با سایر سلول‌های عصبی ایجاد می‌کند. این شبکه بیولوژیکی عظیم به ما این امکان را می‌دهد تا جهان پیرامون خود را تجربه کنیم. سلول‌های عصبی را تعداد زیادی سلول گلیال^۱ در بر گرفته‌اند که کار آن‌ها تغذیه و حفاظت از سلول عصبی است. هر سلول عصبی دارای جسم سلولی به قطر ۵ تا ۱۰۰ میکرومتر است که از آن اندام اصلی به نام آکسون^۲ و تعدادی رشته شاخه مانند به نام دندریت^۳ منشعب می‌شود. انتهای آکسون شاخه‌های متعددی دارد و در ابتدا نیز ممکن است چند شاخه از آن جدا شود. سیگنال‌ها و علامت‌های ورودی، به وسیله جسم سلولی و دندریت‌ها دریافت شده و جسم سلولی پس از ترکیب علائم ورودی، علائم خروجی را ارسال می‌کند. آکسون، پیام خروجی را از جسم سلولی به پایانه‌های آکسونی می‌رساند و آن‌ها اطلاعات را به سایر سلول‌های عصبی منتقل می‌کنند. دستگاه پیام‌رسان دو وجه الکتریکی و شیمیایی دارد. پیامی که در سلول عصبی ایجاد شده و طول آکسون را می‌پیماید، پیام‌رسان الکتریکی است اما انتقال پیام از یک سلول به سلول دیگر به وسیله مولکول‌های مواد ناقل انجام می‌گیرد که از سیناپس^۴ می‌گذرند (پیام‌رسان شیمیایی). سیناپس حفاصل فرستنده پیام پایانه آکسونی یا برخی موارد، دندریت‌ها و گیرنده پیام (دندریت یا جسم سلولی و بعضی موارد، آکسون) است. یک سلول عصبی به طور معمول از صدها یا هزارها سلول دیگر، پیام دریافت می‌کند و به صدها یا هزارها سلول عصبی دیگر پیام می‌فرستد. نوروها شبیه به سایر سلول‌های بیولوژیکی دارای یک غشا هستند که یون‌ها می‌توانند از این غشا عبور کنند. این یون‌ها شامل یون پتاسیم، سدیم و کلر است. تمرکز این یون‌ها در حالت عادی در داخل و خارج متفاوت است. این اختلاف تجمع یون‌ها باعث ایجاد یک پتانسیل در حدود ۷۰ میلی‌ولت نسبت به خارج سلول، در داخل آن می‌شود. وقتی سلول تحریک می‌شود، میدان گذردهی برای یون‌های خاصی تغییر می‌کند و سدیم به راحتی از غشا عبور می‌کند، سپس پتانسیل سلول مثبت‌تر شده و پس از یک بازه زمانی کوتاه گذردهی به حالت معمولی برمی‌گردد و جریان پتاسیم باعث برگشت به حالت در حال انتظار می‌شود. جابجایی یون‌ها باعث یک جریان‌ات الکتریکی در داخل سلول و اطراف بافت می‌شود. پتانسیل ایجاد شده را پتانسیل عمل^۵ می‌گویند. پتانسیل عملی که طول رشته عصبی را طی می‌کند، یک جریان یا ایمپالس عصبی است. ارسال علائم در دستگاه عصبی به فواصل حدود یک میلی‌متر یا بیشتر، همیشه به شکل جریان یا ایمپالس عصبی صورت می‌گیرد. رسیدن ایمپالس به پایانه آکسونی، سلول عصبی بعدی به نحوی متأثر می‌شود و احتمال تولید ایمپالس در آن تغییر می‌کند. ماده

^۱ Glial

^۲ Axon

^۳ Dendrite

^۴ Synapse

^۵ Action Potential

شیمیایی ناقلی از انتهای غشا پیش سیناپسی^۱ آزاد شده و در فضای کوچک میان سلول پخش می شود و بر غشاء پس سیناپسی^۲ اثر می گذارد. این تأثیرگذاری به دو طریق است. در سیناپس تهییجی^۳ آهنگ ایجاد ایمپالس در سلول پس سیناپس افزایش می یابد ولی در سیناپس بازدارنده^۴ یا از تولید ایمپالس جدید جلوگیری می شود یا از آن کاسته می شود. سلول عصبی از صدها یا هزارها پایانه مختلف عصبی علائم دریافت می کند که بعضی از آن ها تهییجی و برخی بازدارنده هستند. چون در هر لحظه برخی علائم ورودی، فعال و برخی غیرفعال اند، در نتیجه شدت تحریک یا آهنگ تحریک سلول عصبی به مجموع تأثیرات تهییجی و بازدارنده بستگی دارد [۱۶]. در حالت کلی فعالیت نورونی به دو گروه تقسیم می شوند.

۱- پتانسیل عمل که با انتشار سیگنال در طول رشته عصبی (فیبرهای نورونی) همراه است.

۲- پتانسیل پس سیناپس

تقریباً تمام امواج و فعالیت های الکتریکی که در یک نوار مغزی ثبت می شود، از لایه های فوقانی قشر مغز، به خصوص شاخه های دندریتی سلولی هرمی و أحياناً نورون های ارتباطی موجود در این ناحیه سرچشمه می گیرند. این امواج، بیانگر مجموعه ای از پتانسیل های متغیر پس سیناپسی از یک طرف و پتانسیل های پس سیناپسی بازدارنده از طرف دیگر است و به پتانسیل عمل ارتباطی ندارد. تحت شرایط طبیعی، پتانسیل های عمل هدایت شده در آکسون ها در ثبت های قشری اثر کمی می گذارند زیرا آن ها به طور معمول از لحاظ زمانی به طور غیر همزمان در تعداد زیادی از آکسون ها اتفاق می افتد که در جهت زیادی نسبت به سطح ردیف شده اند و به این ترتیب تأثیر خالص آن ها بر پتانسیل سطح قابل چشم پوشی است. پتانسیل پس سیناپسی با یک جریان دوقطبی که در حدود چند ده میلی ثانیه حضور دارد، توصیف می شود. یک نورون تحریک شده به تنهایی میدان الکتریکی و مغناطیسی قابل اندازه گیری تولید نمی کند، اما قشر مغز را می توان به صورت مجموعه ای از ستون های عمودی به قطر یک میلی متر در نظر گرفت که سلولی عصبی در آن به صورت همزمان عمل می کنند و از دپلاریزاسیون همزمان و هماهنگ تعداد زیادی از این ستون ها، میدان الکتریکی یا مغناطیسی به وجود می آید. در یک میلی متر مربع در حدود ۱۰۰۰۰۰ نورون وجود دارد. اگرچه فقط نصف این تعداد در تولید میدان مغناطیسی سهمیه هستند، اما تعداد باقیمانده نیز وقتی به صورت همزمان تحریک می شوند، تعداد قابل توجهی هستند. رفتار میدان های الکتریکی و مغناطیسی توسط قوانین فیزیکی قابل پیشگویی است [۱۷].

۲-۳ ثبت سیگنال الکتریکی مغز

در قرن نوزدهم فعالیت الکتریکی پایه مغز در حیوانات بی هوش نشده به کمک الکترودهای داخلی از سطح قشر مغز ثبت شد، اما به صورت یک روش سامانمند توسط هانس برگر، متخصص بیماری های روانی بررسی شد و او بود که اصطلاح الکتروانسفالوگرام را برای نوسانات پتانسیل ثبت شده از مغز معرفی کرد. فعالیت نورونی دایمی یا خودبه خود^۵ درون مجسمه پتانسیل هایی را روی سطح سر تولید می کنند که در

^۱ Pre Synaptic

^۲ Post Synaptic

^۳ Excitatory Synaptic


^۴ Inhibitory Synaptic

^۵ Spontaneous

طول زمان ثبت، نواری را ایجاد می‌کند که با عنوان الکتروانسفالوگرام شناخته می‌شود. سیگنال الکتریکی مغز یک روش پایش الکتروفیزیولوژی برای ثبت فعالیت الکتریکی مغز از طریق اندازه‌گیری نوسان‌های ولتاژ حاصل از جریان یونی در سلول‌های عصبی مغز است. اگرچه سیگنال الکتریکی مغز دارای محدودیت‌هایی است برای مثال نسبت سیگنال به نویز و همچنین وضوح مکانی کمی دارد و اغلب هنگام ثبت همراه با نویز است، اما به دلیل صحت و وضوح زمانی بالا و پایداری به تدریج در زمینه شناخت احساسات وارد شد. رابطه بین برانگیختگی حسی حاد و فعال شدن سیستم عصبی مرکزی با استفاده از سیگنال الکتریکی مغز بررسی شده است و نتایج مطالعات متعدد نشان می‌دهد که احساسات مثبت و منفی با الگوهای مختلف فعال شدن قشر مرتبط هستند. اکثر مطالعات نشان داده‌اند که فعال شدن لوب پیشانی در نیمکره چپ با بیان و تجربه احساسات مثبت مرتبط است، در حالی که فعال شدن لوب پیشانی در نیمکره راست مربوط به تجربه و بیان احساسات منفی است [۱۸]. امواج الکتریکی قابل ثبت در سطح جمجمه بسیار ضعیف و در حدود ۰ تا ۱۰۰ میکرو ولت است. فرکانس‌های این امواج مغزی از ۰/۵ تا ۱۰۰ هرتز تغییر می‌کنند و مشخصه آن‌ها به میزان زیادی به درجه فعالیت قشر مغز بستگی دارد. الکترودهای مورد استفاده برای ثبت سیگنال به‌طور معمول به دو نوع سوزنی و بشقابی تقسیم می‌شوند که به‌طور معمول از جنس آلایژ نقره و پلاتین است. تقویت‌کننده‌های موجود در دستگاه ثبت سیگنال الکتریکی مغز اکثراً از نوع تفاضلی هستند تا نویزها را بهتر حذف کنند. در ثبت نوار مغزی، مشکل تنها تقویت این امواج نیست، بلکه اهمیت مساله در تفکیک آن‌ها از نویزهای محیطی است که ممکن است ولتاژهایی بالاتر از امواج داشته باشند. برای مثال می‌توان به نویز برق شهر و پتانسیل‌های موجود در ماهیچه‌های سطح جمجمه اشاره کرد. برای کم کردن اثر هر یک از این درست‌نماها روش‌هایی ارایه شده است.

انتخاب الکترودها بر اساس نقاط ویژه استخوان جمجمه انجام می‌پذیرد. الکترودها در نواحی تلاقی سطوح استخوان جمجمه قرار می‌گیرند و سایر الکترودهای میانی بر اساس ۱۰ و ۲۰ درصد کل فاصله چیده می‌شوند. شامل ۲۱ الکتروود (به استثنای الکترودهای لاله گوش) است. نام هر منطقه بر اساس لوبی است که در آن قرار گرفته است که شامل Frontal(F), Temporal(T), Occipital(O), Parietal(P), Central(C) است. نام هر الکتروود با شماره‌هایی مشخص می‌شود که اعداد زوج قرار داشتن در نیمکره راست و اعداد فرد قرار گرفتن در نیمکره چپ را مشخص می‌کنند هر چه فاصله از خط صفر (خط عبور کننده از بینی تا پس سر) بیشتر باشد عدد بزرگ‌تر اختصاص داده می‌شود. محل نصب الکترودها نیز دارای قوانین ویژه‌ای است. سه نقطه ویژه در ناحیه جمجمه سر را مشخص می‌کنیم که عبارت‌اند از: بیخ بینی، برآمدگی پشت سر، نقطه‌ای در استخوان ماستوئید پشت گوش (A1 و A2) پس از تعیین سه نقطه ویژه، مراحل نصب الکترودها به این صورت انجام می‌پذیرد. الکتروود Fp در فاصله‌ی ۱۰ درصد بالای بیخ بینی قرار می‌گیرد. سپس الکترودهای بعدی خط میانی (صفر) Oz, Pz, Cz, Fz به ترتیب در فاصله‌های ۲۰ درصدی در مسیر بین بیخ بینی و برآمدگی پشت سر از یکدیگر قرار می‌گیرند. در مرحله بعد الکترودهای T3 و T4 در فاصله‌ی ۱۰ درصدی از نقاط ویژه پشت دو گوش و الکترودهای C3 و C4 در فاصله‌ی ۲۰ درصدی از T3 و T4 قرار می‌گیرند. محیط سر از الکترودهای Fp, O, T3 و T4 تشکیل شده

است. Fp1 و Fp2 در فاصله‌ی ۱۰ درصدی از الکترودهای Fp به ترتیب در سمت چپ و راست بر روی محیط سر قرار می‌گیرند. O1 و O2 در فاصله‌ی ۱۰ درصدی از الکترودهای O به ترتیب در سمت چپ و راست روی محیط سر قرار می‌گیرند. در آخر الکترودهای F3, F4, F7, F8, P3, P4, T4, T6 به فاصله‌های ۲۰ درصدی روی محیط مجسمه از یکدیگر قرار می‌گیرند. طبقه‌بندی ویژگی‌های سیگنال الکتریکی مغز بر اساس فرکانس رایج‌ترین روش برای تمایز امواج آلفا، بتا، تتا و گاما است. الکترودهای F3 و F4 بین حالت‌های عاطفی منفی و مثبت تمایز قائل هستند و AF3 و AF4 احساسات مثبت را از دیگر احساسات متمایز می‌کنند [۱۹].



شکل ۱-۲ نحوه قرارگیری الکترودها [۱۹]

۴-۲ ریتم‌های مغزی

همان‌طور که گفته شد مغز متشکل از میلیون‌ها سلول است. فعالیت‌های این سلول‌ها فرکانس‌های مختلفی را ایجاد می‌کند. به همین علت برای شناخت مغز باندهای فرکانسی معرفی شده است. هرکدام از این باندها متعلق به عمل خاصی است. فرکانس اصلی سیگنال EEG به پنج باند فرکانسی طبقه‌بندی می‌شود که در ادامه به معرفی این باندها پرداخته می‌شود [۵].

- **باند دلتا^۱:** باند فرکانسی ۰/۵ تا ۴ هرتز از سیگنال EEG را باند دلتا می‌نامند که در طول یک خواب عمیق بدون حرکت سریع چشم و در حالت غیر هوشیار مشاهده می‌شود. وضعیت شخص از نظر فیزیولوژی در این حالت، عدم تحرک و پایین آمدن سطح غلظت برخی مواد شیمیایی در بدن است، همچنین فرکانس‌های متعدد در این محدوده با ترشح هورمون رشد انسانی همراه است که در بهبودی مفید است.
- **باند تتا^۲:** این امواج با باند فرکانسی ۴ تا ۸ هرتز در مواقع خواب عمیق و استراحت و نیز در

^۱ Delta Band

^۲ Theta Band

کودکان مشاهده می‌شود، این امواج با ذهن نیمه خودآگاه مرتبط هستند. همچنین در هنگام رویا دیدن تصویری زیبا و یا فراخوانی حافظه نیز دیده شده است. وضعیت شخص از دیدگاه فیزیولوژی در این حالت بهبود بخشیدن و التیام یافتن و هماهنگی فکری است.

- **باند آلفا^۱:** سیگنال‌ها در این باند فرکانسی دامنه‌ای حدود ۱۰ تا ۵۰ میکروولت در محدوده ۸ تا ۱۲ هرتز دارند و مکان‌های توزیع این پتانسیل روی سر، اغلب در مناطق مرکزی و داخلی است و همچنین چنانچه چشم‌ها بسته باشد، در قسمت پس‌سری با قدرت بیشتری ظاهر می‌شود. این امواج با حالت روحی آرام و آگاه مرتبط است.
- **باند بتا^۲:** زمانی که ذهن در هشیاری کامل و فعالیتی با تمرکز بالا باشد، باند بتا با قدرت بیشتری در نواحی آهیانه‌ای و جلوسری مشاهده می‌شود. این موج دارای دامنه اندکی است که در باند فرکانسی ۱۲ تا ۳۰ هرتز گسترده شده است.
- **باند گاما^۳:** در بعضی کاربردها فرکانس‌های بین ۳۰ تا ۱۰۰ هرتز را نیز در نظر می‌گیرند که در همه جای سر دیده می‌شود. امواج گاما با فعالیت بسیار شدید و بیش‌ازحد مغزی مرتبط است. ریتم‌های مغزی و فرکانس مربوط به آن به‌طور خلاصه در جدول ۱-۲ آورده شده است.

جدول ۱-۲ طبقه‌بندی امواج مغزی [۵]

باند	فرکانس (هرتز)	دامنه	وضعیت مغز	آگاهی	منشأ
دلتا	۴-۵	بالا تر	الگوی خواب عمیق	پایین تر	نواحی آهیانه و گیجگاهی
تتا	۸-۴	بالا	الگوی خواب سبک	پایین	قشر انتورینال، هیپوکامپ
آلفا	۸-۱۲	متوسط	چشم‌های بسته، حالت آرام	متوسط	نواحی پشتی سر
بتا	۱۲-۳۰	پایین	تفکر فعال، تمرکز، هوشیاری بالا، مضطرب	بالا	نواحی آهیانه‌ای و جلوسری
گاما	۳۰-۱۰۰	پایین تر	در طول پردازش حسی متقابل	بالا تر	قشر حسی پیکری


۵-۲ انواع روش‌های تشخیص عواطف

تشخیص احساسات فرایند درک و استخراج وضعیت روانی فعلی انسان یا حالت‌های ذهنی است. بطور کلی سیستم تشخیص احساسات از طریق سیگنال EEG را می‌توان به دو گروه اصلی سیستم مبتنی بر یادگیری ماشین و سیستم مبتنی بر یادگیری عمیق طبقه‌بندی کرد. یادگیری عمیق قسمتی از خانواده گسترده‌تر روش‌های یادگیری ماشین بر اساس شبکه‌های عصبی مصنوعی است. یادگیری می‌تواند با نظارت، نیمه نظارت یا بدون نظارت باشد [۳].

^۱ Alpha Band

^۲ Beta Band

^۳ Gamma Band



شکل ۲-۲ طبقه‌بندی سیستم‌های تشخیص احساسات [۱۰]

۲-۶ انواع روش‌های یادگیری

یادگیری با نظارت یک روش یادگیری ماشین است. این روش یک تابع از داده‌های آموزشی برچسب‌گذاری شده که شامل مجموعه‌ای از نمونه‌های آموزشی هستند را به دست می‌آورد. در یادگیری با نظارت، شامل یک ورودی (به‌طور معمول یک بردار) و یک مقدار خروجی مطلوب (که سیگنال با نظارت نامیده می‌شود) است. یک الگوریتم یادگیری با نظارت داده آموزشی را تجزیه و تحلیل می‌کند و یک تابع نتیجه‌گیری شده را تولید می‌کند که می‌تواند برای نگاشت نمونه‌های جدید استفاده شود. یک طرح بهینه برای الگوریتم اجازه خواهد داد که دسته برچسب‌ها برای نمونه‌های دیده نشده به درستی مشخص شوند. یادگیری نیمه نظارت یک دسته از یادگیری ماشین و روش‌هایی است که برای آموزش از داده‌های بدون برچسب استفاده می‌شود. یادگیری نیمه نظارت بین یادگیری بدون نظارت (بدون هیچ‌گونه داده آموزشی برچسب‌دار) و یادگیری با نظارت (با داده آموزشی برچسب زده شده به صورت کامل) قرار می‌گیرد. پردازش یک داده آموزشی برچسب‌گذاری شده، ممکن است سنگین باشد. در چنین شرایطی، یادگیری نیمه نظارتی می‌تواند بهتر عمل کند. یادگیری نیمه نظارت در تلاش برای استفاده از ترکیب اطلاعات به منظور عملکرد بهتر طبقه‌بندی است که می‌تواند توسط دوراندختن داده‌های بدون برچسب و اجرای یادگیری با نظارت یا دور انداختن داده‌های با برچسب و اجرای یادگیری بدون نظارت، به دست آید. روش اصلی استفاده شده در یادگیری بدون نظارت روش‌های خوشه‌بندی است. خوشه‌بندی یک شاخه از یادگیری ماشین که داده‌هایی که برچسب ندارند را طبقه‌بندی می‌کند. به جای پاسخ به بازخورد، آنالیز خوشه مشترک‌ها در داده‌ها را مشخص می‌کند و بر اساس حضور یا عدم حضور این مشترک‌ها در هر تکه جدید داده واکنش نشان می‌دهد. برخی از روش‌های معمول استفاده شده در یادگیری بدون نظارت شامل شبکه‌های عصبی، شبکه‌های باور عمیق، رمزگذار خودکار و... می‌باشند [۳].

۷-۲ یادگیری عمیق^۱ (DL)

در سال‌های اخیر یادگیری عمیق در بسیاری از مسایل تشخیص الگو مورد استفاده قرار گرفته است. یادگیری عمیق به دلیل توانایی آن در مدیریت حجم زیادی از داده‌ها، یک ابزار بسیار قدرتمند است. علاقه به استفاده از لایه‌های پنهان به‌ویژه در تشخیص الگو از روش‌های سنتی پیشی گرفته است. یادگیری عمیق دارای روش‌های پیچیده‌تری برای اتصال لایه‌ها است و تعداد نورون‌های بیشتری نسبت به شبکه‌های سنتی برای بیان مدل‌های پیچیده دارد، علاوه بر این دارای قدرت محاسبه بیشتر برای آموزش و همچنین دارای استخراج خودکار ویژگی است. شبکه‌های عصبی را می‌توان در انواع مشکلات از جمله تشخیص الگو، طبقه‌بندی، خوشه‌بندی، کاهش ابعاد، بینایی رایانه، پردازش زبان طبیعی^۲ (NLP) استفاده کرد. آن‌ها نگاشت بین ویژگی‌ها و دسته‌های پیش‌بینی شده را لایه به لایه از طریق تبدیل داده‌ها از ویژگی‌های سطح پایین به ویژگی‌های سطح بالا یاد می‌گیرند. این فرآیند، سلسله‌مراتب ویژگی‌ها^۳ نام دارد. این ویژگی شبکه‌ی عصبی، باعث می‌شود که بسیار قدرتمند شوند و داده‌هایی با ویژگی‌های متعدد^۴ را پردازش کند [۳].

۷-۲-۱ شبکه عصبی مصنوعی^۵ (ANN)

شبکه عصبی مصنوعی یک مدل ریاضی الهام گرفته از مغز انسان است که تلاش می‌کند توان محاسباتی سیستم عصبی انسان را مدل کند. یک شبکه عصبی از لایه‌هایی از نورون‌ها تشکیل شده است. لایه مجموعه‌ای از نورون‌های موازی است که به یکدیگر متصل نیستند و مجموعه‌ای از وزن‌ها را برای یک ورودی باهم خارج می‌کنند. این لایه‌ها چندین بار روی هم چیده می‌شوند که عمق شبکه را مشخص می‌کند.

شبکه‌های عصبی یک مدل ریاضی برای هر تابع $f: X \rightarrow Y$ یا یک توزیع احتمالاتی روی X تعریف می‌کنند. اساساً نورون‌ها دو نوع محاسبه انجام می‌دهند: مجموع گرفتن روی همه‌ی مقادیر، فعال‌سازی نورون‌های ورودی وزن‌دار با وزن‌های $w_{ji}: net_j = \sum_i x_i w_{ji}$ و سپس اعمال یک تابع بر روی این مجموعه، $y_j = \phi_j(net_j)$. خروجی نورون j هست. نتیجه مقدار برای ایجاد خروجی به یک تابع فعال‌سازی^۶ وارد می‌شود [۲۰].

¹ Deep Learning


² Natural Language Processing

³ Feature Hierarchy

⁴ High Dimensional Data

⁵ Artificial Neural Networks

⁶ Activation Function



شکل ۲-۳ واحد محاسباتی [۲۰]

یک شبکه عصبی مصنوعی در ساختارهای مختلف نورون‌ها به هم مرتبط هستند. ساختار سه لایه یکی از متداول‌ترین ساختارها است که در آن نورون‌ها در سه لایه ورودی، لایه مخفی و لایه خروجی قرار گرفته‌اند. لایه ورودی به‌طور معمول یک تابع فعال‌ساز خطی دارد درحالی‌که لایه‌های مخفی و خروجی یک تابع فعال‌ساز غیرخطی دارند. داده‌ها در لایه ورودی به شبکه وارد می‌شوند. عملکرد لایه ورودی ساده است و آن‌ها را به لایه پنهان ارسال می‌کند، لایه پنهان محاسبات را انجام می‌دهد و اطلاعات را به لایه خروجی انتشار می‌دهد. تعداد نورون‌ها در لایه ورودی به‌طور معمول برابر با تعداد ویژگی‌های موجود در داده‌های در حال پردازش است. یک تابع فعال‌ساز خطی به‌طور معمول در سراسر لایه ورودی استفاده می‌شود، به‌طوری‌که تمام مقادیر ورودی بدون اعوجاج به لایه پنهان می‌رسند. این نوع شبکه‌ها روبه‌جلو^۱ نامیده می‌شوند زیرا اطلاعات را از ورودی به خروجی بدون وجود حلقه انتشار می‌دهند. شبکه‌های عصبی روبه‌جلو به‌طور کامل متصل هستند، به این معنی که هر نورون در یک لایه به هر نورون در لایه متوالی متصل است. اتصالات بین نورون‌ها وزن دارند و وزن یک اتصال برحسب قدرت سیگنال ارسالی است. لایه پنهان سیگنال‌هایی را از لایه ورودی دریافت می‌کند. یک تابع فعال‌ساز غیرخطی مانند تابع سیگموئید به‌طور معمول در تمام واحدهای لایه پنهان استفاده می‌شود [۲۰].

۲-۷-۲ شبکه‌های عصبی روبه‌جلو

شبکه عصبی روبه‌جلو اولین و ساده‌ترین نوع شبکه عصبی مصنوعی است. اصطلاح روبه‌جلو از عملکرد شبکه ناشی می‌شود که در آن داده‌ها بدون هیچ حلقه بازخوردی از ورودی x به خروجی y از طریق سیستم جریان می‌یابند. ساده‌ترین مدل شبکه عصبی مصنوعی یک شبکه یک پرسپترون تک لایه^۲ (SLP) است که هر نورون به هر یک از نورون‌های لایه قبلی و بعدی متصل است. با این وجود، این شبکه قادر به حل الگوهای غیرخطی جدا از هم نیستند. از این رو، یک پرسپترون چندلایه ارایه شد^۳ (MLP) که محدودیت‌های شبکه پرسپترون تک لایه را با لحاظ کردن یک یا چندلایه پنهان در بین یک لایه

^۱ Feed Forward

^۲ Single Layer Perceptron

^۳ Multilayer Perceptron

ورودی و خروجی رفع می‌کرد. این مدل همچنین به عنوان شبکه کاملاً متصل شناخته می‌شود. در ابتدا، الگوریتم پس انتشاری^۱ برای آموزش شبکه عصبی پرسپترون چندلایه استفاده شد. سپس این شبکه آموزش دیده قادر است هر رابطه غیرخطی بین ورودی‌ها و اهداف را نشان دهد، به شرطی که نورون‌های کافی در لایه پنهان وجود داشته باشد؛ بنابراین اگر تعداد کمی از واحدهای پنهان استفاده شود، ترسیم دقیق داده‌ها غیرممکن خواهد بود، زیرا ظرفیت اطلاعاتی شبکه عصبی با مقدار اطلاعات نمایش داده شده توسط داده‌های آموزشی مطابقت نخواهد داشت. از طرف دیگر، اگر تعداد زیادی واحد پنهان استفاده شود، ظرفیت اطلاعاتی شبکه عصبی از حداقل لازم فراتر می‌رود و واحدهای پنهان اضافی اطلاعات غیرضروری را یاد می‌گیرند. در حقیقت، شبکه‌های عصبی روبه‌جلو قادر هستند تا طبقه‌بزرگی از مشکلات مربوط به شناخت الگو و پیش‌بینی را برطرف کنند. توانایی شبکه عصبی برای پیش‌بینی صحیح خروجی‌های الگوهای دیده نشده قبلی توانایی تعمیم^۲ نامیده می‌شود. توانایی تعمیم به معنی این است که سیستم یادگیری ماشین قادر باشد مواردی را که یادگرفته است، برای نمونه‌های جدید و از قبل دیده نشده استفاده کند و بتواند نمونه‌ها را به خوبی دسته‌بندی کند. در بعضی شرایط یک سیستم یادگیری ماشین ممکن است بقدری ضعیف باشد که حتی داده‌های آموزش دیده را هم نتواند به خوبی دسته‌بندی کند به این وضعیت کم‌برازش^۳ گفته می‌شود و در بعضی شرایط دیگر ممکن است سیستم به قدری قوی باشد که داده‌های آموزش دیده را به صورت کامل در حافظه اش ضبط کند و روی آن‌ها صحت خروجی خیلی خوبی بدهد، ولی برای نمونه‌های جدید نمی‌تواند صحت خوبی را نشان دهد و به عبارتی توانایی تعمیم ندارد که به این شرایط بیش‌برازش^۴ گفته می‌شود. علل دیگر بیش‌برازش، آموزش شبکه عصبی برای مدت طولانی و استفاده از مجموعه آموزشی است که قابل آموزش نیست، یا حاوی نویز است؛ بنابراین، داشتن تعداد صحیح واحدهای پنهان در شبکه عصبی مهم است. علاوه بر ورودی‌های لایه قبلی، واحدهای مخفی و خروجی نیز سیگنال ورودی را از واحد بایاس دریافت می‌کنند. واحدهای بایاس مقادیر آستانه واحدها را در لایه بعدی نشان می‌دهند. بایاس یک نورون بدون ورودی است که یک مقدار ثابت (به‌طور معمول منفی یک، در حالی که می‌تواند هر مقدار غیر صفر دیگری باشد) را خروجی می‌دهد که توسط واحدهای مخفی و خروجی به عنوان ورودی اضافی استفاده می‌شود. در طول آموزش شبکه عصبی، وزن‌های متصل‌کننده واحدهای بایاس با واحدهای دیگر همراه با تمام وزن‌های دیگر تنظیم می‌شوند. تعداد متغیرهای وابسته یا خروجی‌ها، تعداد نورون‌ها را در لایه خروجی یک شبکه عصبی تعیین می‌کند. محدوده خروجی نورون‌های خروجی به تابع فعال‌سازی مورد استفاده بستگی دارد. علاوه بر این، ساختار شبکه‌های عصبی مصنوعی با اتصالات بازخورد، اتصالات این‌گره‌ها ممکن است چرخه‌هایی را تشکیل دهد که به عنوان یک شبکه عصبی بازگشتی^۵ (RNN) یا مدل شبکه بازخورد شناخته می‌شود. در شبکه روبه‌جلو چندلایه (شکل ۲-۴)، بیش از یک لایه وزنی وجود دارد که دارای

^۱ Backpropagation


^۲ Generalization

^۳ Under Fit

^۴ Over Fit

^۵ Recurrent Neural Network

لایه پنهان بین لایه ورودی و خروجی است [۲۰].



شکل ۲-۴ شبکه روبه جلو چندلایه [۲۰]

۳-۷-۲ توابع فعال سازی غیرخطی





یک تابع فعال سازی در مورد فعال بودن یا نبودن یک نورون تصمیم می گیرد. شبکه های عصبی جدید از توابع فعال ساز غیرخطی استفاده می کنند. این توابع به مدل کمک می کنند تا نگاشت های پیچیده را میان ورودی ها و خروجی های شبکه به وجود آورد، به عبارت دیگر، این توابع به مدل این امکان را می دهند تا خود را با داده های پیچیده و غیرخطی وفق دهد. متداول ترین توابع فعال سازی شبکه های عصبی تانژانت هایپربولیک^۱ (Tanh)، توابع سیگموئید^۲ (Sigmoid) و واحد خطی اصلاح شده^۳ (ReLU) است. در حال حاضر، محبوب ترین و توصیه شده ترین عملکرد فعال سازی برای شبکه های عصبی عمیق، ReLU است. علاوه بر غیرخطی بودن، مزیت اصلی استفاده از این فعال ساز، این است که همه نورون ها را هم زمان فعال نمی کند. اگر ورودی منفی باشد به صفر تبدیل می شود و نورون فعال نمی شود. این به این معنی است که در یک زمان، فقط چند نورون فعال می شوند که موجب عدم تراکم شبکه می شود و اگر مقدار ورودی بیشتر از صفر باشد، تابع ReLU همان مقدار ورودی را خروجی می دهد. عملکرد ReLU یکی از پیشرفت های اصلی در زمینه یادگیری عمیق بود که منجر به غلبه بر مشکل محوشدگی گرادیان شد. دلیل دیگر محبوبیت این تابع فعال ساز این است که به دلیل عملیات ساده مورد نیاز برای محاسبه، آموزش شبکه عصبی عمیق را چندین برابر سریع تر انجام می دهد، به عبارت دیگر مدت زمان مدل سازی کاهش می یابد. از معایب این تابع فعال ساز این است که زمانی که ورودی صفر یا نزدیک به صفر باشد، تابع ReLU دیگر عملکردی ندارد و به بیان دیگر، می میرد. در این صورت، مقدار گرادیان تابع صفر می شود و شبکه نمی تواند عملیات پس انتشار را انجام دهد و آموزش ببیند. برای حل این مشکل تابع Leaky ReLU معرفی شد. این تابع یک شیب مثبت ملایم به سمت مقادیر منفی دارد که این امر باعث می شود عملیات پس انتشار حتی برای مقادیر منفی هم انجام شود [۲۱، ۲۲].

^۱ Hyperbolic Tangent

^۲ Sigmoid

^۳ Rectified Linear Unit

جدول ۲-۲ توابع فعالساز شبکه‌های عصبی [۲۱]

نمودار	معادله	تابع فعالسازی
	$S(x) = \frac{1}{1 + e^{-x}}$	Sigmoid
	$\tanh x = \frac{e^x - e^{-x}}{e^x + e^{-x}}$	Tanh
	$ReLU(x) = \begin{cases} 0 & \text{if } x < 0 \\ x & \text{if } x \geq 0 \end{cases}$	eLU
	$f(x) = \begin{cases} x & \text{if } x > 0 \\ 0.01x & \text{if otherwise} \end{cases}$	Leaky ReLU

تابع Softmax

یکی دیگر از توابع فعال‌سازی که به‌طور معمول در لایه‌ی خروجی و برای مشکلات مربوط به دسته‌بندی استفاده می‌شود تابع Softmax است. این تابع علاوه بر نگاشت بازه خروجی به $[0, 1]$ ، هر خروجی را به نحوی نگاشت می‌کند که مجموع آن‌ها یک باشد. مقادیر ورودی می‌توانند مثبت، منفی، صفر یا بزرگ‌تر از یک باشند، اما تابع بیشینه هموار آن‌ها را به مقادیری بین ۰ تا ۱ تبدیل می‌کند، به‌طوری‌که می‌توان آن‌ها را به‌عنوان احتمالات تفسیر کرد. اگر یکی از ورودی‌ها کوچک یا منفی باشد، آن را به یک احتمال کوچک تبدیل می‌کند و اگر یک ورودی بزرگ باشد، آن را به یک احتمال بزرگ تبدیل می‌کند، اما همیشه بین ۰ تا ۱ باقی می‌ماند. Softmax را می‌توان در طبقه‌بندی کننده تنها زمانی استفاده کرد که دسته‌ها متقابلاً منحصربه‌فرد هستند. بسیاری از شبکه‌های عصبی چندلایه به یک‌لایه پیش‌فرض ختم می‌شوند که نتایج باارزش واقعی را که مقیاس بندی مناسبی ندارند و کار با آن‌ها دشوار است، خروجی می‌دهد. به همین دلیل معمول است که Softmax به‌عنوان لایه نهایی شبکه عصبی اضافه شود [۲۱].

۸-۲ مروری بر روش‌های مختلف یادگیری عمیق

۸-۲-۱ شبکه عصبی بازگشتی (RNN)

یکی از الگوریتم‌های پرکاربرد و محبوب در یادگیری عمیق، به‌ویژه در پردازش زبان طبیعی و پردازش گفتار شبکه عصبی بازگشتی است. برخلاف شبکه‌های عصبی سنتی، شبکه عصبی بازگشتی از اطلاعات متوالی در شبکه استفاده می‌کند و یک چرخه را تشکیل می‌دهد. شبکه عصبی بازگشتی دارای حلقه‌هایی در داخل است و اطلاعات از حلقه فعلی به حلقه بعدی منتقل می‌شود. خاصیت زنجیر مانند نشان می‌دهد که شبکه عصبی بازگشتی ساختار طبیعی شبکه عصبی است که برای توالی‌ها و فهرست‌ها اعمال می‌شود. شبکه‌های عصبی بازگشتی مدل‌های توالی قدرتمندی هستند. آن‌ها با استفاده از حافظه داخلی خود می‌توانند وابستگی‌های زمانی با مدت‌زمان نامشخص بین ورودی‌ها و خروجی‌های موردنظر را مدل کنند. این ویژگی آن‌ها را کاندیدای خوبی برای مدل‌سازی سری‌های زمانی می‌کند. در شبکه‌های عصبی روبه‌جلو نمونه‌ها در یک جهت بدون بازخورد جریان دارند. در مقابل، شبکه‌های عصبی بازگشتی امکان بازخوردهای شبکه داخلی را فراهم می‌کنند. آن‌ها مجموعه‌ای از شبکه‌های عصبی روبه‌جلو با اتصالات بازگشتی هستند. این بدان معنی است که آن‌ها یک حلقه بازخورد دارند که در آن داده‌ها می‌توانند در نقطه‌ای قبل از اینکه دوباره برای پردازش بیشتر به سمت خروجی نهایی به جلو هدایت شوند، به ورودی بازگردانده شوند. این رویه به شبکه اجازه می‌دهد تا یک بازخورد (حافظه داخلی) داشته باشد و آن را قادر می‌سازد وابستگی‌های زمانی بین ورودی‌ها و خروجی‌های موردنظر را مدل‌سازی کند. این مهم‌ترین مزیت شبکه عصبی بازگشتی در مقایسه با شبکه‌های عصبی روبه‌جلو است. شبکه عصبی بازگشتی ساده از یک لایه ورودی با نورون‌های ورودی d ، یک لایه پنهان با نورون‌های پنهان c و یک لایه خروجی با نورون‌های خروجی q تشکیل شده است. در هر نقطه زمانی t ، بردار x_t $d \times 1$ ورودی‌ها، بردار h_t $c \times 1$ واحدهای پنهان و بردار $q \times 1$ خروجی‌ها باشد. این شامل سه ماتریس وزن، W_{ih} ، W_{hh} ، W_{ho} است که ورودی را به پنهان، بازگشتی پنهان به پنهان و پنهان به خروجی را متصل می‌کند. این ماتریس‌های وزنی پارامترهای شبکه‌های عصبی بازگشتی هستند. خروجی شبکه در زمان t با فرمول‌های زیر محاسبه می‌شود:

$$h_t = f(W_{ih} x_t + W_{hh} h_{t-1}) \quad (1-12)$$

$c \times 1 \quad c \times d \quad d \times 1 \quad c \times c \quad p \times 1$

$$o_t = g(W_{ho} h_t) \quad (2-12)$$

$q \times 1 \quad q \times 1 \quad c \times 1$

که در آن، $f()$ تابع فعال‌سازی لایه پنهان، $g()$ تابع فعال‌سازی لایه خروجی است. همانطور که گفته شد در بیشتر موارد، یک تابع غیرخطی به عنوان تابع فعال‌سازی لایه پنهان، برای معرفی غیرخطی بودن شبکه‌های عصبی، مانند تابع سیگموئید یا تانژانت هذلولی، استفاده می‌شود. عملکرد فعال‌سازی خروجی به هدف هر شبکه بستگی دارد. برای مساله‌های رگرسیون از تابع فعال‌سازی خطی استفاده می‌شود. همانطور که در معادله اولی می‌بینیم، لایه پنهان اطلاعاتی را در مورد آنچه در مرحله زمانی قبلی رخ داده است، می‌گیرد، بنابراین می‌توان آن را به عنوان حافظه شبکه مشاهده کرد. لایه پنهان h_{t-1} لایه پنهان در مرحله زمانی قبلی است، $h_{t-1} = f(W_{ih} x_{t-1} + W_{hh} h_{t-2})$. در اولین مرحله زمانی t

$= 0$ ، لایه پنهان h_0 مقادیر اولیه d برابر با صفر را می‌گیرد، d تعداد واحدهای پنهان است. برای آموزش پارامترهای یک شبکه باید دو مرحله فاز جلو و فاز عقب را تکرار کنیم. در زمان t نورون‌های ورودی در مجموعه‌ای از وزن‌های کاملاً متصل W_{ih} ضرب می‌شوند و لایه ورودی را به لایه پنهان متصل می‌کنند. لایه پنهان نه تنها با لایه ورودی بلکه با لایه پنهان از مرحله قبلی به روز می‌شود؛ بنابراین این واحدهای ورودی وزن‌دار پس از جمع‌آوری و با استفاده از معادله به واحدهای پنهان وزن‌دار از زمان $t-1$ اضافه می‌شوند. سپس توسط تابع فعال‌سازی لایه پنهان $f()$ تبدیل می‌شود تا لایه پنهان h_t را همانطور که در معادله نشان داده شده است تشکیل دهد. به روشی مشابه، نورون‌های پنهان از لایه پنهان h_t در وزن‌هایی که لایه پنهان را به لایه خروجی متصل می‌کند ضرب می‌شوند. نتیجه توسط تابع فعال‌سازی خروجی $g()$ تبدیل می‌شود تا خروجی شبکه را تشکیل دهد. سپس خروجی با هدف مورد نظر y_t مقایسه می‌شود و خطای بین این دو محاسبه می‌شود [۲۳].

$$z_t = W_{ih} x_t + W_{hh} h_{t-1} \quad (3-12)$$

$c \times 1 \quad c \times d \quad d \times 1 \quad c \times c \quad p \times 1$

$$h_t = f(z_t) = f(W_{ih} x_t + W_{hh} h_{t-1}) \quad (4-12)$$

$c \times 1 \quad c \times 1 \quad c \times d \quad d \times 1 \quad c \times c \quad p \times 1$

$$v_t = W_{ho} h_t \quad (5-12)$$

$q \times 1 \quad q \times p \quad c \times 1$

$$o_t = g(v_t) = g(W_{ho} h_t) \quad (6-12)$$

$q \times 1 \quad q \times 1 \quad q \times c \quad c \times 1$

پس از مرحله رو به جلو، مرحله بازگشت به عقب با روش پس انتشار در طول زمان برای محاسبه مشتقات تابع ضرر، با توجه به وزن‌ها استفاده می‌شود. سپس وزن‌ها بر اساس یک تکنیک بهینه‌شده بروز می‌شوند [۲۳، ۲۱].

۲-۸-۲ شبکه عصبی حافظه طولانی کوتاه مدت^۱ (LSTM)

LSTM یک الگوریتم یادگیری عمیق مبتنی بر شبکه عصبی بازگشتی است. برخلاف معماری‌های شبکه‌های روبه‌جلو که در گذشته شرح داده شد، این شبکه می‌تواند اطلاعات وضعیت‌های قبلی را حفظ کند و برای کارهایی که به حافظه نیاز دارند آموزش ببیند. LSTM همانند شبکه بازگشتی ساده، حالت تکرار شدنی خود را دارد اما واحد تکرار شونده آن اندکی پیچیده‌تر است این معماری جدید برای حل مشکل پدیده محوشدگی گرادیان در شبکه‌های عصبی بازگشتی به وجود آمدند. این شبکه متشکل از بلوک‌هایی از سلول حافظه است که از طریق آن‌ها سیگنال جریان می‌یابد درحالی‌که توسط دروازه‌های ورودی، فراموش و خروجی تنظیم می‌شود. این دروازه‌ها آنچه را که در سلول ذخیره، خوانده و نوشته می‌شود، کنترل می‌کنند [۲۴، ۲۱].

¹ Long Short-Term Memory

۲-۸-۳ ماشین بولتزمن محدود^۱ (RBM)

ماشین بولتزمن محدود که نوعی مدل بر مبنای انرژی است بعنوان یک مدل گرافیکی غیر جهت‌دار ارایه شده است. RBM از دو لایه قابل مشاهده و لایه مخفی تشکیل می‌شود. در این مدل واحدهای لایه مخفی با اتصالات وزن‌دار به لایه مخفی متصل شده‌اند با این محدودیت که واحدهای هر لایه به هم متصل نیستند. عموماً لایه مخفی تنها شامل واحدهای باینری می‌باشد در حالی که لایه مخفی می‌تواند مقادیر حقیقی یا باینری داشته باشد.

تابع انرژی برای نگاشت واحدهای مشاهده‌پذیر و مخفی RBM به یک فضای انرژی تعریف شده است و الگوریتم یادگیری شامل هدایت پارامترهای مدل (اتصالات وزن‌دار و بایاس واحدها) است بگونه‌ای که این پیکربندی را به کمینه محلی انرژی نگاشت کند.

$$E(v, h) = -b'v - c'h - h'Wv \quad (7-12)$$

که در آن b و c به ترتیب بایاس واحدهای مشاهده‌پذیر و مخفی هستند. W ماتریس وزن‌های اتصالات، v به ترتیب مقادیر فعال‌سازی واحدهای ورودی و واحدهای مخفی هستند. این یک شبکه عصبی تولیدی آماری می‌باشد که می‌تواند یک توزیع احتمالاتی را روی مجموعه‌ای از ورودی‌ها یاد بگیرد [۲۵].

۲-۸-۴ شبکه باور عمیق^۲ (DBN)

DBN یک ساختار عمیق است که واحد سازنده آن RBM است. RBM انباشته شده روی هم با لایه‌های مشترک یک DBN برای پیش‌آموزش نظارتی را می‌سازند. در RBM های انباشته شده واحد مخفی RBM پایینی واحد ورودی RBM بالایی است. در فاز آموزش، RBM های انباشته شده یکی پس از دیگری آموزش می‌بینند. در فاز تولیدی اتصالات رو به بالا برداشته می‌شوند و تنها دو لایه بالایی یک RBM باقی می‌مانند. سپس مدل قادر به تولید بردار داده است که تقریباً به داده اولیه نزدیک و از توزیع داده اولیه پیروی می‌کند. با توجه به سطح‌های چندگانه، احتمال توأم مدل تولیدی به صورت زیر تجزیه می‌شود:

$$P(x, h^1, h^2, \dots, h^l) = P(h^{l-1}, h^l) \left(\prod_{k=1}^{l-1} P(h^k | h^{k+1}) \right) P(x | h^1) \quad (8-12)$$

$$P(h^k | h^{k+1}) \quad Q(h^k | h^{k+1})$$

که در آن l تعداد لایه‌های مخفی می‌باشد. توزیع توأم دو لایه بالایی یک RBM می‌باشد.

$$P(h^{l-1}, h^l) \propto e^{b'h^{l-1} + c'h^l + h^{l-1}W^lh^l} \quad (9-12)$$

۲-۸-۵ شبکه عصبی پیچشی^۳ (CNN)

یک ساختار یادگیری عمیق خوش ساخت است که از ساختار بینایی موجودات زنده الهام گرفته شده است. غشای بینایی مسئول پردازش اطلاعات بصری در مغز است. مطالعات بر روی غشای بینایی بیانگر این است که نورون‌های درون آن با استفاده از محرک‌های تولید شده در نواحی محلی فعال می‌گردد. به

¹ Restricted Boltzman Machine

² Deep belief Network

³ Convolutional Neural Network

همین دلیل ایده شبکه عصبی پیچشی یادگیری فیلترها، از طریق شیوه‌های مبتنی بر داده‌ها به صورت محلی است. دو لایه اصلی شبکه عصبی پیچشی لایه پیچشی^۱ و لایه Pooling است. در این شبکه‌ها ورودی‌ها می‌توانند ایستا فرض شوند به این معنا که دارای ویژگی‌های آماری یکسانی در نقاط مختلف تصویر باشند. به این صورت که اگر ویژگی‌های استخراجی برای قسمتی از تصویر را بیاموزیم می‌توانیم همان ویژگی‌های استخراجی برای دیگر نقاط تصویر به کار ببریم. ایده لایه پیچشی نیز همین مساله می‌باشد. همچنین برای کاهش پیچیدگی محاسباتی و جلوگیری از بیش‌برازش نیاز به کاهش ویژگی‌ها است که دلیل وجود لایه Pooling است.

در سال ۱۹۹۰ لی سون یک چهارچوب جدید از شبکه عصبی پیچشی ارائه کرد و حاصل بهبود آن یک شبکه عصبی مصنوعی به نام LeNet-5 بود که به منظور طبقه‌بندی دست خط‌ها به کار می‌رفت. ۵- LeNet همانند دیگر شبکه‌های عصبی دارای چندین لایه است و همچنین با استفاده از الگوریتم پس انتشار خطا^۲ آموزش داده شده است. در سال ۲۰۰۶ تلاش‌های بسیاری جهت گسترش و غلبه بر مشکلات آموزش شبکه عصبی پیچشی مطرح شده بود. از جمله معماری‌های قابل توجه، می‌توان به شبکه دسته‌بیک AlexNet که توسط هینتون و همکاران ارائه شده است، اشاره کرد. این شبکه مشابه LeNet-5، با تعداد لایه‌های بیشتر یا به عبارت دیگر شبکه‌ای عمیق‌تر است. با افزایش عمق شبکه (افزایش لایه‌ها) و در نتیجه افزایش غیر خطی بودن مدل تخمینی، شبکه قادر به تخمین مناسب تابع مدل مد نظر در مساله و ارائه بازنمایی بهتر خواهد بود. هرچند پیچیدگی شبکه باعث سخت‌تر شدن بهینه‌سازی و بیش‌برازش می‌شود اما برای حل این مسایل راه حل‌های مختلفی ارائه گردیده است [۲۶]. در ادامه بعضی مفاهیم مربوط به شبکه عصبی عمیق توضیح داده خواهد شد. شبکه عصبی پیچشی مانند سایر شبکه‌های روبه جلو از تعدادی لایه متوالی تشکیل شده است که علاوه بر ورودی و خروجی، لایه‌های اصلی برای تشکیل این شبکه لایه پیچشی، لایه Pooling، لایه تمام متصل^۳ (مشابه آنچه در شبکه‌های عصبی پرسپترون چند لایه است) هستند. در ادامه بعضی مفاهیم مربوط به شبکه عصبی عمیق پیچشی توضیح داده خواهیم شد [۲۲، ۲۷].

لایه پیچشی

لایه پیچشی هسته اصلی تشکیل‌دهنده شبکه عصبی پیچشی است، در این لایه‌ها، شبکه عصبی پیچشی از هسته‌های مختلف برای کانال‌ها کردن تصویر ورودی و همین‌طور نقشه ویژگی^۴ میانی استفاده می‌کند و اینگونه نقشه ویژگی‌های مختلفی ایجاد می‌کند. در لایه پیچشی، متناظر با هر فیلتر نقشه ویژگی مربوط به آن به دست می‌آید. هر واحد از لایه جاری به قطعه‌های^۵ محلی در نقشه ویژگی لایه قبل متصل است که این اتصال از طریق دسته‌ای از وزن‌ها انجام می‌شود. هر کدام از نقشه‌های ویژگی تولیدشده حاصل اعمال فیلتر منحصربه‌فرد است. هر نورون در نقشه ویژگی به یک همسایگی از نورون‌های موجود

^۱ Convolutional Layer


^۲ Back Propagation

^۳ Fully Connected Layer

^۴ Feature Map

^۵ Patch

در لایه قبل متصل است. نقشه ویژگی به این صورت حاصل می‌گردد: ابتدا ورودی با یک فیلتر کانوالو می‌شود سپس یک تابع غیرخطی به نتایج حاصل از کانوالو اعمال می‌گردد. درواقع هر نقشه ویژگی حاصل اعمال هسته‌های مختلف به تصویر است.



نقشه ویژگی پنجره لایه قبل

شکل ۲-۵ لایه کانولوشن [۲۸]

اگر نقشه ویژگی K^{th} در لایه m را به عنوان m^k نشان دهیم و فیلتر مربوطه را با مقادیر وزنی W نشان دهیم و b^k بیانگر بایاس در نقشه ویژگی باشد، یک توصیف ساده و مختصر نقشه ویژگی به صورت ریاضی را می‌توان بصورت زیر بیان کرد:

$$m_{ij}^k = f((W * x)_{ij} + b^k) \quad (۱۰-۱۲)$$

دو مفهوم مهم دیگر در لایه‌های پیچشی وجود دارد: گام^۱ و Padding [۲۲].


گام

منظور از گام تعداد پیکسل‌هایی هستند که یک هسته یا یک فیلتر روی ماتریس ورودی حرکت می‌کند. با کنترل گام می‌توان همپوشانی را کنترل کرد. با توجه به ابعاد تصویر $N \times N$ و اندازه فیلتر $F \times F$ ، اندازه خروجی O همانطور که در شکل زیر نشان داده شده است، معادله زیر بدست می‌آید:

$$O = 1 + \frac{N - F}{S} \quad (۱۱-۱۲)$$

N اندازه ورودی است، F اندازه فیلتر و S اندازه گام است [۲۸].

^۱ Strides



شکل ۲-۶ تاثیر گام در خروجی [۲۲]

Padding

یکی دیگر از پارامترهای موثر در اندازه خروجی، عددی است که با عنوان Padding تعریف می‌شود. یکی از اشکالات مرحله کانولوشن، از دست دادن اطلاعاتی است که ممکن است در حاشیه تصویر وجود داشته باشد؛ اما یک روش بسیار ساده و در عین حال کارآمد برای حل این مشکل، اضافه کردن سطر و ستون صفر به صورت متقارن به دور ماتریس ورودی است که به آن Zero padding گفته می‌شود. وقتی فیلتر با ماتریس ورودی متناسب نیست از Padding استفاده می‌شود. مزیت دیگر Zero padding مدیریت اندازه خروجی است. برای مثال، در شکل قبل، با $N=7$ و $F=3$ و $S=1$ ، خروجی 5×5 خواهد بود. معادله زیر Zero padding را نشان می‌دهد [۲۲].

$$O = 1 + \frac{N + 2P - F}{S} \quad (۱۲-۱۲)$$

0	0	0	0	0	0	0	0	0
0								0
0								0
0								0
0								0
0								0
0								0
0								0
0	0	0	0	0	0	0	0	0

شکل ۲-۷ Zero padding [۲۲]

Pooling

برای کاهش ابعاد نقشه‌های ویژگی، گاهی اوقات یک لایه Pooling پس از یک لایه پیچشی داده می‌شود. سپس درحالی‌که ویژگی‌های غالب را در نقشه‌های ویژگی استخراج می‌کند یک نقشه ویژگی فشرده ایجاد می‌کند. کاهش اندازه منجر به کاهش هزینه‌های محاسباتی برای لایه‌های بعدی شبکه می‌شود و از بیش‌برازش جلوگیری می‌کند. یکی دیگر از مزایای لایه Pooling، ادغام ویژگی‌های معنایی مشابه با یکدیگر است. لایه Pooling به دلیل کاهش وضوح نقشه ویژگی عموماً بین دو لایه پیچشی قرار می‌گیرد. هر نقشه ویژگی لایه Pooling به نقشه ویژگی پیچشی لایه قبل خود متصل است. از جمله لایه‌های Pooling رایج می‌توان به Average Pooling و Max Pooling اشاره کرد. Max Pooling می‌تواند منجر به همگرایی سریع‌تر، انتخاب ویژگی‌های ثابت برتر و همچنین قدرت محاسباتی موردنیاز برای پردازش داده‌ها را کاهش می‌دهد و همچنین حداکثر مقدار عناصر را در قسمتی از تصویر که توسط فیلتر پوشانده شده است را بازمی‌گرداند. درحالی‌که Average pooling کار کاهش ابعاد را به‌عنوان روشی برای حذف نویز اجرا می‌کند [۲۸].

نرمال‌سازی دسته‌ای^۱ (BN)

نرمال‌سازی دسته‌ای را می‌توان تکنیکی برای بهبود عملکرد و پایداری شبکه‌های عصبی دانست. ایده این کار نرمال‌سازی ورودی هر لایه با کمک میانگین و واریانس است. به شکلی که میانگین اعداد بردار نهایی برابر با صفر و واریانس آن‌ها برابر با یک شود. به عبارت دیگر، نرمال‌سازی دسته‌ای مقادیر ماتریس‌ها را که بازه نامشخصی دارند، به بازه مشخصی مانند صفر تا یک تبدیل می‌کند. برای این کار مزایای متفاوتی ذکر شده است: افزایش سرعت یادگیری شبکه، افزایش قدرت و کاهش بیش‌برازش در شبکه و البته با توجه به محل قرارگیری آن در شبکه و لایه‌هایی که پیش و پس از آن قرار می‌گیرند برخی از این مزایا را ایجاد می‌کند. این عملگر هم که نمی‌توان آن را لایه نامید، فقط در برخی از معماری‌ها استفاده می‌شود [۲۸، ۲۹].

لایه تمام متصل

لایه تمام متصل که شکل دهنده اصلی شبکه‌های عصبی معمولی مانند پرسپترون چندلایه است، عموماً در انتهای ساختار شبکه عصبی پیچشی به‌عنوان دسته‌بند به کار گرفته می‌شود. این لایه خود شامل یک لایه خروجی و یک یا چند لایه ماقبل آن (مشابه لایه مخفی در شبکه پرسپترون چندلایه) است. لایه تمام متصل، همان‌طور که از نام آن‌ها مشخص است، تمام نورون‌های لایه قبل را به یکدیگر متصل می‌کنند. از این‌رو فعال‌سازی آن‌ها را می‌توان با ضرب ماتریس و انحراف بایاس محاسبه کرد. لایه‌های کاملاً متصل در نهایت نقشه‌های ویژگی دوبعدی را به بردار ویژگی یک بعدی تبدیل می‌کنند. بردار مشتق شده یا می‌تواند در دسته‌بندی خاصی برای طبقه‌بندی استفاده شود یا می‌تواند به‌عنوان بردار ویژگی برای پردازش بیشتر در نظر گرفته شود. هر لایه تمام متصل از طریق یک تابع فعال‌سازی (به‌عنوان مثال تانژانت هایپربولیک یا ReLU) عبور می‌کند، آخرین لایه شبکه پیچشی لایه خروجی است به‌منظور دسته‌بندی از عملگر softmax استفاده می‌کنند [۲۸].

^۱ Batch Normalization

۹-۲ بهینه‌سازی^۱ مختلف برای آموزش شبکه عصبی

بهینه‌سازها به الگوریتم‌ها یا روش‌هایی گفته می‌شود که برای تغییر ویژگی‌های شبکه عصبی از قبیل وزن و نرخ یادگیری به کار برده می‌شوند. این کار، نقش موثری در کاهش زیان دارد. نحوه تغییر وزن‌ها یا نرخ یادگیری شبکه عصبی به ابزارهای بهینه‌سازی^۲ مورد استفاده بستگی دارد [۲۲].

• گرادیان نزولی تصادفی^۲ (SGD)

روش گرادیان نزولی یکی از محبوب‌ترین الگوریتم‌ها برای بهینه‌سازی شبکه‌های عصبی است. روش گرادیان نزولی راهی برای یافتن مینیمم یک تابع هدف مثل $J(\theta)$ است که بر اساس بردار پارامترهای مدل یعنی $\theta \in \mathbb{R}^d$ نوشته شده است؛ به این صورت که پارامترها در خلاف جهت گرادیان تابع نسبت به پارامترها یعنی $\nabla_{\theta} J(\theta)$ تغییر می‌کنند. نرخ یادگیری شبکه عصبی یا η اندازه‌ی گام تغییر پارامترها برای یافتن مینیمم را تعیین می‌کند. به عبارت دیگر، در جهت شیب سطح ایجاد شده توسط تابع به سمت پایین حرکت می‌کنیم تا به یک دره برسیم. روش گرادیان نزولی تصادفی نسبت به هر کدام از داده‌ها مثل $x^{(i)}$ و مقدار متناظر آن $y^{(i)}$ یک گام تغییر ایجاد می‌کند:

$$\theta = \theta - \eta \cdot \nabla_{\theta} J(\theta; x^{(i)}; y^{(i)}) \quad (۱۲-۱۳)$$

روش گرادیان نزولی انبوه محاسبات اضافی و نالازم برای مجموعه داده‌های بزرگ انجام می‌دهد زیرا گرادیان داده‌های یکسانی را به‌طور مکرر قبل از ایجاد هر تغییر محاسبه می‌کند. روش تصادفی این محاسبات اضافی را با ایجاد یک تغییر با هر گرادیان گیری حذف می‌کند. به همین دلیل هم این روش بسیار سریع‌تر است و می‌تواند یادگیری لحظه‌ای هم داشته باشد. الگوریتم پس انتشار خطا یک روش یادگیری استاندارد است که از گرادیان نزولی برای به‌روزرسانی پارامترها استفاده می‌کند [۳۰].

• مومنتوم^۳

مومنتوم با هدف کاهش واریانس در گرادیان نزولی تصادفی ابداع شد و همگرایی به جهت مورد نظر را تسریع بخشیده و از گرایش به جهات نامربوط پیشگیری می‌کند. در این روش به جای اینکه تنها از مقدار گرادیان در مرحله‌ی فعلی به منظور هدایت جستجو استفاده شود، تکانه گرادیان مراحل گذشته را نیز محاسبه می‌کند و از آن برای تعیین جهت گرادیان استفاده می‌کند. از مزایای آن می‌توان به کاهش نوسانات و واریانس بالای پارامترها و همگرایی سریع در مقایسه با گرادیان کاهشی اشاره نمود [۲۷].

• آدام (Adam)

روش Adam [۳۱] یکی دیگر از روش‌هایی است که نرخ یادگیری را منطبق بر داده‌ها محاسبه می‌کند. علاوه بر ذخیره کردن میانگین میراشونده‌ی نمایی مربعات گرادیان‌های قبلی، یعنی v_t روش Adam میانگین میراشونده‌ی نمایی گرادیان‌ها m_t را هم مثل روش شتاب حفظ می‌کند:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (۱۲-۱۴)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (۱۲-۱۵)$$

^۱ Optimization

^۲ Stochastic Gradient Descent

^۳ Momentum

v_t و m_t به ترتیب تخمین گشتاور اول (میانگین) و گشتاور دوم (واریانس غیرمرکزی) گرادیان‌ها هستند که نام‌گذاری روش هم به همین خاطر است. به خاطر این که حالت اولیه ی بردارهای m_t و v_t صفر است، سازندگان روش مشاهده کردند که نتایج به صفر متمایل می‌شوند، به خصوص در گام‌های اولیه و مخصوصاً وقتی نرخ میراث‌وندگی کوچک است (به عبارت دیگر β_1 و β_2 نزدیک ۱ هستند). آنها این مشکل را با تخمین‌های اصلاح شده‌ی گشتاور اول و دوم حل کردند:

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t} \quad (16-12)$$

$$\hat{v}_t = \frac{v_t}{1 - \beta_2^2} \quad (17-12)$$

سپس از این دو فرمول برای محاسبه‌ی تغییرات پارامترها استفاده کردند که فرمول تغییرات را برای این روش به دست می‌دهد:

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t \quad (18-12)$$

مقادیر پیشفرض ۹/۰ برای β_1 ، ۹۹۹/۰ برای β_2 و 10^{-8} را برای ϵ پیشنهاد کرده اند. آنها به صورت تجربی نشان داده اند که روش Adam در عمل به خوبی کار می‌کند و نسبت به دیگر روش‌های یادگیری انطباق پذیر ارجحیت دارد.

۲-۱۰ تنظیم ابر پارامترها^۱

بهینه سازی ابر پارامترها فرآیندی برای یافتن ترکیب مناسبی از مقادیر ابر پارامترها به منظور دستیابی به حداکثر کارایی روی داده‌ها در مدت زمان معقول است. بیشتر شبکه‌های عمیق با مقادیر پیش فرض ابر پارامترها ارایه می‌شوند. مقادیر پیش فرض به طور معمول در بررسی شبکه‌های عمیق عملکرد خوبی ندارند، به همین دلیل باید آنها را بهینه کرد تا ترکیب مناسبی را که بهترین عملکرد را دارد بدست آورد. فرآیند تنظیم ابر پارامترها شامل چهار روش اساسی؛ روش جستجوی شبکه ای^۲، جستجوی تصادفی^۳، روش بهینه سازی بیزی^۴ و روش‌های تکاملی مانند الگوریتم بهینه‌سازی ازدحام ذرات، الگوریتم ژنتیک است. جستجوی شبکه ای ساده ترین الگوریتم برای تنظیم ابر پارامترها است. دامنه ابر پارامترها را به یک شبکه گسسته تقسیم می‌کند. روش جستجوی شبکه ای یک روش آزمون و خطا برای تنظیم ابر پارامترها در محدوده خاصی از مقادیر است و برخی از معیارهای عملکرد را با استفاده از اعتبارسنجی متقاطع محاسبه می‌کند. نقطه ای از شبکه که مقدار متوسط را در اعتبارسنجی متقاطع به حداکثر می‌رساند، ترکیب بهینه مقادیر برای ابر پارامترها است. جستجوی شبکه ای یک الگوریتم جامع است که همه ترکیب‌ها را در بر می‌گیرد، بنابراین می‌تواند در واقع بهترین نقطه را در دامنه پیدا کند. عیب بزرگ آن این است که بسیار کند است و بررسی هر ترکیبی از فضای جستجو مستلزم زمان زیادی است. علاوه بر این، هر نقطه در شبکه نیاز به اعتبار سنجی متقاطع k-fold دارد که نیاز به k مراحل آموزشی دارد؛

^۱ Hyperparameters

^۲ Grid Search

^۳ Random Search

^۴ Bayesian Optimization

بنابراین، تنظیم ابر پارامترهای یک مدل به این روش می‌تواند بسیار پیچیده و پرهزینه باشد. جستجوی تصادفی مشابه جستجوی شبکه ای است، اما به جای استفاده از تمام نقاط شبکه، تنها زیر مجموعه ای از این نقاط را که به طور تصادفی انتخاب شده اند، آزمایش می‌کند. هرچه این زیرمجموعه کوچک‌تر باشد، بهینه سریع‌تر اما صحت کمتری دارد و می‌تواند از جستجوی شبکه‌ای بهتر عمل کند، به‌ویژه زمانی که تنها تعداد کمی از ابر پارامترها بر عملکرد نهایی شبکه تاثیر می‌گذارند. یکی دیگر از آخرین پیشرفت‌ها در تنظیم ابر پارامترها، استفاده از بهینه سازی بیزی است که از توزیع بر روی توابع استفاده می‌کند که به فرآیند گاوسی معروف است. رویکرد بهینه سازی بیزی، روش بهینه‌سازی جایگزین را وارد چارچوب احتمالات می‌کند؛ بدین صورت که توابع جایگزین را توزیع‌های احتمالی در نظر می‌گیرد که باید بر اساس اطلاعات جدید بروزرسانی شوند. برای ارزیابی احتمال اکتشاف یک نقطه‌ی خاص، از توابع اکتسابی استفاده می‌شود، توابع اکتسابی بین اکتشاف و بهره‌وری توازن برقرار می‌کنند. بهینه سازی بیزی به‌طور معمول در تنظیم ابر پارامترها زمانی که ارزیابی تابع ضرر گران و هزینه‌بر است، استفاده می‌شود. کتابخانه‌های زیادی برای این مساله وجود دارند که از جمله‌ی آن‌ها می‌توان به HyperOpt اشاره کرد [۳۲].

۲-۱۰-۱ بهینه‌سازی چند هدفی به کمک الگوریتم‌های تکاملی^۱

الگوریتم‌های تکاملی روشی است که ابتکاری با الهام از طبیعت برای ترکیب دو استراتژی اکتشاف و بهره‌برداری به کار می‌برد؛ بنابراین، این رویکرد، جایگزین روش‌های متداول برای بهینه‌سازی شبکه‌های عصبی می‌باشند. الگوریتم‌های تکاملی توانایی پرداختن به مشکلات پیچیده، غیرخطی را دارند. به عبارت دیگر، الگوریتم‌های محاسبات تکاملی غالباً از یک جمعیت حاوی راه‌حل‌های تصادفی شروع می‌کنند و در یک فرایند تکراری^۲، جهت بهبود کیفیت راه‌حل‌های ضعیف تولیدشده، آن‌قدر این راه‌حل‌ها را دست‌کاری می‌کنند تا سیستم بتواند با صحت^۳ مطلوبی مساله موردنظر را حل کند. معیار خاتمه می‌تواند حداکثر تعداد تکرارها یا یافتن مجموعه بهینه از ویژگی‌هایی باشد که حداکثر صحت طبقه‌بندی را به دست می‌آورد. برخی از الگوریتم‌های تکاملی که با الهام از طبیعت، فیزیک و انسان طراحی شده‌اند و در حل بسیاری از مساله‌های بهینه‌سازی استفاده می‌شوند. عبارت‌اند از: بهینه‌سازی اجتماع مورچگان (ACO)^۴، بهینه‌سازی شبیه‌سازی ذوب فلزات (SA)^۵، الگوریتم ژنتیک (GA)^۶، بهینه‌سازی ازدحام ذرات (PSO)^۷ و آنتروپی تفاضلی (DE)^۸ [۳۳]. این الگوریتم‌ها و طرح بهبودیافته آن‌ها عملکرد خوبی را در طیف وسیعی از مشکلات مانند آموزش شبکه عصبی، تشخیص الگو، بهینه‌سازی عملکرد، پردازش تصویر، داده‌کاوی، مشکلات بهینه‌سازی ترکیبی و غیره داشته است. در مسایل دنیای واقعی به ندرت با شرایطی

^۱ Evolutionary Algorithms

^۲ Iterative Process

^۳ Accuracy

^۴ Ant Colony Optimization

^۵ Simulated annealing

^۶ Genetic Algorithm

^۷ Particle Swarm Optimization

^۸ Differential Evolution

روبه‌رو می‌شویم که تنها یک هدف برای بهینه‌سازی داشته باشیم. بنابراین مسایل بهینه‌سازی چندهدفی، مسایلی با دو هدف یا بیش از دو هدف عموماً در تضاد با یکدیگر هستند که بهبود یکی از آنها با بدتر شدن یک یا چند هدف دیگر همراه است. تفاوت اصلی مسایل بهینه‌سازی چندهدفی با مسایل بهینه‌سازی تک‌هدفی در این است که این مسایل دارای یک جواب بهینه واحد نیستند و در عوض مجموعه‌ای از راه‌حل‌های بهینه داریم که یک بده بستان^۱ میان اهداف را ارائه می‌دهند. مسایل بهینه‌سازی چندهدفی دارای چندین تابع هستند که به وسیله راه‌حل $\vec{X}$ باید حداکثر یا حداقل شوند و به صورت همزمان قیود مساله نیز ارضا شوند. بنابراین یک مساله بهینه‌سازی چندهدفی را می‌توان به صورت زیر نوشت:

$$\text{Finding } \vec{X} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_I \end{bmatrix}$$

$$\text{Which minimizes/maximizes } F_m(\vec{X}) \quad m = 1, 2, \dots, M \quad (12-19)$$

$$\text{Subject to } g_j(\vec{X}) \leq 0 \quad j = 1, \dots, J$$

$$h_k(\vec{X}) = 0 \quad k = 1, 2, \dots, K$$

$$x_i^L \leq x_i \leq x_i^U \quad i = 1, 2, \dots, I$$

که در آن راه‌حل $\vec{X}$ ، بردار متغیرهای تصمیم‌گیری و g_j ها و h_k ها قیود مساله است. هر کدام از متغیرهای تصمیم x_i محدود به کران پایین x_i^L و کران بالای x_i^U خود هستند. در واقع این قیود، فضای n بعدی تصمیم‌گیری D را به $S_D \subset D$ و نگاشت این قیود، فضای n بعدی هدف O را به $S_O \subset O$ محدود می‌کنند. M نیز تعداد توابع هدف مساله است. این M تابع هدف، نگاشتی از فضای تصمیم‌گیری S_D به فضای S_O را ایجاد می‌کنند. این نگاشت از فضای n بعدی تصمیم‌گیری به فضای m بعدی هدف صورت می‌پذیرد؛ بنابراین هر بردار $\vec{X} = (X_1, X_2, \dots, X_m)^T$ از فضای S_D به یک بردار $\vec{F} = (F_1, F_2, \dots, F_m)^T$ از فضای S_O اشاره دارد. راه‌حلی که در مسایل بهینه‌سازی چندهدفی جستجو می‌شود، به جای یک متغیر نرده‌ای، برداری از مقادیر است. به ازای هر راه‌حل $\vec{X}$ ، بردار توابع هدف $\vec{F}$ را داریم که مولفه i -ام آن، مقدار i -امین تابع هدف را به ازای بردار $\vec{X}$ یا به عبارتی $F_i(\vec{X})$ را نشان می‌دهد. پس به ازای هر راه‌حل، برداری از توابع هدف وجود دارد [۳۴].

الگوریتم بهینه‌سازی ازدحام ذرات (PSO)

الگوریتم بهینه‌سازی ازدحام ذرات یک روش جستجوی مبتنی بر جمعیت هست که رفتار گروهی پرندگان را در هنگام پرواز به سمت مقصد شبیه‌سازی می‌نماید که هر عضو ذره نامیده می‌شود. با استفاده از روش بهینه‌سازی ازدحام ذرات، می‌توان با مساله‌هایی که جواب آن‌ها یک نقطه یا سطح در فضای d بعدی هست برخورد نمود و یک سرعت ابتدایی به ذرات اختصاص داده می‌شود و ارتباط بین ذرات در نظر گرفته می‌شود. سپس این ذرات در فضای جستجو حرکت می‌کنند و نتایج بر مبنای یک ملاک

^۱ Trade Off

شایستگی^۱ پس از هر بازه‌ی زمانی محاسبه می‌شود. در هر لحظه هر ذره مکان خود را در فضای جستجو با توجه به بهترین مکانی که تاکنون در آن قرار گرفته است و بهترین مکانی که در کل همسایگی‌اش وجود دارد، تنظیم می‌کند. اولین مرحله، مقداردهی موقعیت و سرعت اولیه در فضای جستجوی مساله برای پیدا کردن راه‌حل بهینه است. در الگوریتم بهینه‌سازی ازدحام ذرات، هر ذره جهت ذخیره‌سازی بهترین مکان که در حین فرایند جستجو و حرکت در فضای جستجو به آن رسیده از حافظه‌ای برخوردار است که به‌عنوان بهترین تجربه‌ی شخصی خود آن را به خاطر می‌سپارد. هر ذره، این اطلاعات را برای دیگر ذرات موجود در همسایگی قابل‌دسترس می‌نماید و همچنین آن‌ها نیز می‌توانند مشاهده نمایند که دیگر ذرات موجود در همسایگی در کجا بهترین موفقیت را داشته‌اند و بدین‌صورت از بهترین موقعیت در همسایگی خود یا در کل فضای جستجو به‌عنوان بهترین تجربه‌ی گروهی آگاهی یابند. ذرات جمعیت در حین فرایند با انتقال و تبادل اطلاعات خود به یکدیگر با تنظیم و بروز رسانی سرعت و موقعیت‌های خود (که در معادلات ۱۲-۲۰ و ۱۲-۲۱ ارائه شده است)، در فضای جستجو حرکت می‌نمایند. به عبارت دیگر، الگوریتم بهینه‌سازی ازدحام ذرات، روش جستجوی محلی را از طریق تجربه‌ی خود ذره با روش‌های جستجوی سراسری از طریق تجربه‌ی همسایگان ذره، ترکیب می‌نماید. هر یک از ذرات جمعیت سعی می‌کنند به سمتی حرکت نمایند که بهترین تجربه‌های شخصی و گروهی در آن نقاط روی داده است. سپس این ذرات در فضای جستجو حرکت می‌نمایند و نتایج حاصله بر مبنای یک معیار شایستگی بر اساس تابع هدف پس از هر بازه‌ی زمانی محاسبه می‌گردد. یک فرایند تکراری با ارزیابی معیار شایستگی ذرات برای بهبود کاندیدها به‌عنوان بهترین تجربه‌ی گروهی در طی حرکت ذرات در نظر گرفته شده و با گذشت زمان، ذرات به سمت بهترین تجربه‌ی گروهی که دارای معیار شایستگی بالاتری است، شتاب می‌گیرند. مزیت اصلی این روش بر استراتژی‌های بهینه‌سازی دیگر، این است که تعداد فراوان ذرات ازدحام کننده، باعث انعطاف روش در برابر مشکل پاسخ بهینه‌ی محلی می‌گردد. در یک فضای جستجو d بعدی سرعت و مکان ذره در بهینه‌سازی ازدحام ذرات دارای مقادیر حقیقی می‌باشند و ذرات در فضایی با دامنه پیوسته حرکت می‌کنند. بروز رسانی این دو متغیر توسط دو رابطه زیر محاسبه می‌شود:

$$V_{id}(t+1) \leftarrow V_{id}(t) + C_1 r_1 (p_{id}(t) - x_{id}(t)) + C_2 r_2 (p_{gd}(t) - x_{id}(t)) \quad (12-22)$$

$$x_{id}(t+1) \leftarrow x_{id}(t) + V_{id}(t+1) \quad (12-23)$$

- x_{id} موقعیت کنونی و $x_{id} t+1$ موقعیت بعدی ذره i در فضای جستجوی d بعدی است و t تعداد تکرارها هست.
- V_{id} سرعت کنونی و $V_{id}(t+1)$ سرعت بعدی ذره i در فضای جستجوی d بعدی است.
- p_{id} بهترین موقعیت ذره i در فضای جستجوی d بعدی است.
- p_{gd} بهترین موقعیت سراسر یافته شده توسط کل ذرات است.
- r_1 و r_2 دو بردار بعدی با اعداد تصادفی بین $[0, 1]$ است. برای هر بعد یک عدد تصادفی در نظر

¹ Fitness Value

گرفته می‌شود زیرا الگوریتم بهینه‌سازی ازدحام ذرات در هر بعد مستقل عمل می‌نماید.

- C_1 و C_2 ثابت‌های از پیش تعریف‌شده‌ای هستند که عوامل شتاب نامیده می‌شوند. برای تعیین مقدارهای C چهار حالت ممکن است رخ دهد: در صورتی که مقدار C_1 و C_2 بالا باشند، موقعیت جدید در فاصله‌ای دورتر از فضای جستجو ایجاد می‌شود که جستجوهای سراسر بهتری تولید می‌نماید، اما ممکن است ذرات منحرف شوند. در صورتی که مقدار C_1 و C_2 رو به پایین باشند، حرکت ذرات محدود می‌شود و جستجو در اطراف بهترین موقعیت محلی انجام می‌شود. در صورتی که $C_1 > C_2$ باشد، جستجو به سمت بهترین موقعیت یافته شده محلی متمایل می‌شود. در صورتی که $C_1 < C_2$ باشد، جستجو به سمت بهترین موقعیت یافته شده سراسری متمایل می‌شود [۳۵].

الگوریتم بهینه‌سازی ژنتیک^۱

الگوریتم ژنتیک، یک روش برنامه‌نویسی است که از تکامل ژنتیکی به عنوان یک الگوی حل مسئله استفاده می‌کند. مساله‌ای که باید حل شود دارای ورودی‌هایی است که طی یک فرایند الگوبرداری شده از تکامل ژنتیکی به راه‌حل‌ها تبدیل می‌شود سپس راه‌حل‌ها به عنوان کاندیدها توسط تابع شایستگی^۲ مورد ارزیابی قرار می‌گیرند و چنانچه شرط خروج مساله فراهم‌شده باشد الگوریتم خاتمه می‌یابد. به‌طور کلی این الگوریتم مانند الگوریتم ازدحام ذرات یک الگوریتم مبتنی بر تکرار است که ایده آن برگرفته از طبیعت هست که اغلب بخش‌های آن به صورت فرایندهای تصادفی انتخاب می‌شوند. در حقیقت این الگوریتم ژنتیک برای روش‌های دسته‌یک بهینه‌سازی در حل مساله‌های خطی موفق بوده‌اند ولی برای حل مساله‌های گسسته و غیرخطی بسیار کارا تر است. در طبیعت از ترکیب کروموزوم‌های بهتر، نسل‌های بهتری پدید می‌آیند. در این بین گاهی اوقات جهش‌هایی نیز در کروموزوم‌ها روی می‌دهد که ممکن است باعث بهتر شدن نسل بعدی شوند الگوریتم ژنتیک نیز با استفاده از این ایده اقدام به حل مساله‌ها می‌کند. برخی از مزایای الگوریتم ژنتیک که باعث شده بیشتر از الگوریتم‌های بهینه‌سازی دیگر مورد استفاده و استقبال قرار بگیرد این است که الگوریتم ژنتیک را می‌توان در مسایل بهینه‌سازی خطی و غیرخطی مورد استفاده قرارداد و از آنجایی که این الگوریتم یک روش تصادفی و احتمالی است، احتمال گیر افتادن آن در بهینه‌های محلی کمتر می‌شود. علاوه بر این انعطاف‌پذیری الگوریتم ژنتیک، شناسایی پارامترها و ساختار بهینه مدل‌های پیچیده‌ای مانند شبکه‌های عصبی و سیستم‌های استنتاج فازی را ساده‌تر می‌کند [۳۶].

روند الگوریتم ژنتیک به صورت زیر است:

- جواب‌های مسئله به عنوان نمایش کروموزومی^۳
- انتخاب جمعیت اولیه^۴
- ارزیابی پاسخ‌ها با توجه به تابع هدف یا شایستگی

^۱ Genetic

^۲ Fitness Function

^۳ Chromosome

^۴ Population

- انتخاب والدین
- انجام عملگرهای ژنتیکی (عملگرهای تولیدمثل)
- توقف فرآیند در صورت برآورده شدن معیار توقف^۱

در الگوریتم‌های ژنتیک ابتدا به‌طور تصادفی، چندین جواب برای مساله تولید می‌شود. این مجموعه جواب جمعیت اولیه نامیده می‌شود. هر جواب را یک کروموزوم می‌نامند. سپس با استفاده از عملگرهای الگوریتم ژنتیک پس از انتخاب کروموزوم‌های بهتر، کروموزوم‌ها را باهم ترکیب^۲ کرده یا جهشی^۳ در آن‌ها ایجاد می‌کنیم. در هر نسل^۴ جمعیت فعلی با جمعیت جدیدی از ترکیب و جهش در کروموزوم‌ها حاصل می‌شود و کروموزوم‌های با شایستگی بیشتر به نسل بعدی منتقل می‌شوند [۳۷].

نمایش کروموزوم

هر کروموزوم^۵ (عضو) نشان‌دهنده یک‌راه حل احتمالی برای مساله است. کروموزوم را می‌توان به‌صورت یک بردار X شامل m ژن تصور نمود که هر ژن یک پارامتر مساله بهینه‌سازی را نمایش می‌دهد.

$$X = x_1, x_2, \dots, x_m \quad (12-24)$$

یکی از روش‌های پرکاربرد برای نمایش کروموزوم‌ها روش کد کردن دودویی^۶ است. در این روش کروموزوم به‌صورت رشته‌ای از اعداد صفر و یک نشان داده می‌شود. در روش دودویی به‌طور معمول رشته‌های بلندی تولید می‌شوند که حافظه زیادی از کامپیوتر اشغال می‌کنند، در حالیکه تنها چند بیت از آن در عملگرهای ژنتیکی استفاده می‌شود. این مشکل وقتی پارامترهای بهینه‌سازی زیاد بوده و یا صحت بالایی مدنظر باشد جدی‌تر می‌شود. روش‌های دیگری نیز برای کد کردن کروموزوم‌ها پیشنهاد شده که از آن جمله می‌توان به کد کردن خاکستری^۷، کد کردن مقادیر واقعی^۸، کد کردن درختی^۹ و ... اشاره نمود [۳۷، ۳۵].

جمعیت اولیه

به مجموعه‌ای از کروموزوم‌ها جمعیت گفته می‌شود. نقش جمعیت نمایش فضای جستجو به‌صورت کد شده است که بیانگر فضای جستجو است. جمعیت اولیه به‌طور معمول به‌صورت تصادفی در فضای جستجو انتخاب می‌شود درواقع اندازه جمعیت، پارامتر مهمی در عملکرد الگوریتم ژنتیک است یعنی جمعیت کوچک تنوع را محدود کرده و کل فضای جستجو را پوشش نمی‌دهد و تعداد زیاد کروموزوم در جمعیت، باعث کاهش کارایی و کند شدن فرآیند می‌شود.

تابع هدف یا شایستگی

¹ Termination Criteria

² Crossover

³ Mutation

⁴ Generation

⁵ Individual

⁶ Binary

⁷ Gray Coding

⁸ Real Value Coding

⁹ Tree Coding

برای ارزیابی عملکرد اعضا به معیاری نیاز است که به هر عضو یک مقدار شایستگی اختصاص دهد و بر اساس این میزان شایستگی برای هر کروموزوم مشخص می‌شود که آیا کروموزوم در تشکیل نسل بعد استفاده شود یا خیر. بر اساس میزان شایستگی می‌توان اعضا را رتبه‌بندی نمود.

انتخاب والدین

بعد از ارزیابی، اعضای نسل جدید باید بر اساس نسل فعلی تشکیل شود. انتخاب، یکی از عملگرهای الگوریتم ژنتیک است که بر اساس آن کروموزوم‌هایی که از آن‌ها برای تشکیل نسل جدید استفاده می‌شوند انتخاب می‌گردند. انتخاب ممکن است بر اساس میزان شایستگی یا به‌صورت تصادفی باشد. دو برگ خرید مهم در الگوریتم ژنتیک که کاملاً به هم وابسته هستند عبارت‌اند از: فشار انتخاب^۱ و تنوع جمعیتی^۲. فشار انتخاب بالا تمرکز بر شایسته‌ترین افراد در جمعیت است که باعث کم شدن تنوع و احتمال همگرایی زودرس می‌شود و از طرفی فشار انتخاب پایین می‌تواند باعث طولانی شدن فرآیند همگرایی شود. بسته به نوع مسئله می‌توان از یکی از روش‌های انتخاب تصادفی^۳ و انتخاب متناسب^۴ استفاده نمود. در روش انتخاب تصادفی اعضا به‌صورت تصادفی و بدون در نظر گرفتن شایستگی آن‌ها انتخاب می‌شوند و همه اعضا از شانس برابر برای انتخاب شدن برخوردار هستند. انتخاب تصادفی، فشار انتخاب کمی دارد که منجر به کندی همگرایی می‌شود و روش انتخاب متناسب، شانس انتخاب شدن هر عضو متناسب با میزان شایستگی آن است. از آنجایی که در این روش، فشار انتخاب بالایی وجود دارد باعث همگرایی زودرس و همگرایی در یک بهینه محلی شود.

عملکردهای ژنتیکی

برای تولید جمعیت جدید از نسل حاضر باید از عملگرهای ژنتیکی تولید نسل استفاده نمود. این عملگرها عبارت‌اند از: ترکیب یا پیوند، جهش، نخبه‌گرایی^۵.

عملگر ترکیب این ویژگی‌های خوب والدین را تا حدودی حفظ می‌کند. در این فرایند قسمتی از ژن‌های دو فرد انتخابی که به آن‌ها والدین گفته می‌شود با یکدیگر عوض می‌شود تا افرادی با شایستگی بیشتر تولید گردد.

نخبه‌گرایی

در این حالت پس از ارزیابی شایسته‌ترین اعضا به‌عنوان نخبه انتخاب می‌شوند و بدون تغییر به نسل بعد منتقل می‌شوند. می‌توان از این اعضا برای تولید نسل جدید استفاده کرد و اگر اطراف این اعضا جهش انجام شود سریع‌تر به بهینه خواهیم رسید.

معیار توقف

معیار توقف برای متوقف شدن فرآیند تولید نسل جدید مورد نیاز است. هرگاه الگوریتم به تعداد مشخصی نسل برسد و یا میزان تغییرات تابع شایستگی در نسل‌های متوالی نامحسوس باشد فرآیند الگوریتم

¹ Selective pressure

² Population diversity

³ Random Selection

⁴ Proportional Selection

⁵ Elitism

متوقف می‌شود.

۲-۱۰-۲ الگوریتم تکاملی ژنتیک چند هدفی^۱ (NSGA-II)

همان‌طور که ذکر شد، استفاده از الگوریتم‌های تکاملی یکی از راه‌های برخورد با مساله‌های بهینه‌سازی چندهدفی است که جمعیت به صورت تکراری و نسل به نسل پیشرفت می‌کند و افراد آن به سمت پاسخ‌های بهینه‌تر میل می‌کنند که چنین خاصیت الگوریتم‌های تکاملی، به نخبه‌گرایی موسوم است. از جمله این الگوریتم‌ها، NSGA-II است که توسط دب و همکاران در سال ۲۰۰۲ توسعه داده شده است که یکی از پرکاربردترین و قدرتمندترین الگوریتم‌های موجود برای حل مساله‌های بهینه‌سازی، بهینه‌سازی چند هدفی است و کارایی آن در حل مساله‌های مختلف، به اثبات رسیده است. مساله‌ها در صورتی که به شکل واقعی مدل‌سازی شوند دارای چند هدف می‌باشند که ممکن است این اهداف با یکدیگر در تناقض باشند؛ یعنی با کمینه شدن یکی از آن‌ها هدف دیگر افزایش می‌یابد. در الگوریتم‌های تکاملی چند هدفی به جای پاسخ بهینه، سعی در یافتن مجموعه‌ای از جواب‌هاست که توازن نسبی بین اهداف مختلف را برقرار می‌کند. به این پاسخ‌ها، جواب‌های متعادل^۲ یا متوازن می‌گویند. پاسخ بهینه نباید در هر یک از اهداف از بقیه جواب‌ها بدتر باشد. جوابی که در مقایسه با هیچ جواب دیگری در فضای تصمیم مسئله مغلوب^۳ نباشد. به این جواب، جواب بهینه پارتو^۴ می‌گویند و مجموعه این جواب‌ها در یک مسئله چندهدفی، مجموعه بهینه پارتو نامیده می‌شود. به نقاط غیر مغلوب در یک مسئله بهینه‌سازی چندهدفی نقاط پارتو^۵ می‌گویند و مقادیر تابع هدف متناظر با آن‌ها در فضای معیارها، جبهه پارتو را تشکیل می‌دهد [۳۸].

فاصله ازدحامی^۶

برای محاسبه فاصله ازدحامی هر نقطه روی یک جبهه پارتو مشخص، نقاط قبل و بعد نسبت به توابع هدف مسئله انتخاب و مطابق شکل ۲-۸ یک مستطیل تشکیل می‌شود. برای محاسبه فاصله ازدحام جواب i ام در این شکل، مستطیلی ترسیم شده که جواب‌های قبلی و بعدی نسبت به توابع هدف، در گوشه‌های آن قرار گرفته‌اند. فاصله ازدحام برای این نقطه معادل متوسط اضلاع این مستطیل است. هر چه فاصله ازدحام کمتر باشد، نشان‌دهنده تراکم بیشتر جواب‌هاست. فاصله ازدحامی هر چه بزرگ‌تر باشد، بهتر است چون ناحیه بزرگ‌تری را به خود اختصاص می‌دهد و تراکم جواب‌ها در این ناحیه کمتر است. فاصله ازدحامی جواب i ام مطابق روابط زیر به دست می‌آید:

$$d_i^1 = \frac{|f_1^{i+1} - f_1^{i-1}|}{f_1^{max} - f_1^{min}} \quad \text{کسری از محور افقی برای پاسخ } i \quad (۲۵-۱۲)$$

$$d_i^2 = \frac{|f_2^{i+1} - f_2^{i-1}|}{f_2^{max} - f_2^{min}} \quad \text{کسری از محور عمودی برای پاسخ } i \quad (۲۶-۱۲)$$

¹ Nondominated Sorting Genetic Algorithm II

² Trade-Offs


³ Dominated

⁴ Pareto Optimal

⁵ Pareto Point

⁶ Crowding Distance


$$d_i = d_i^1 + d_i^2 \quad (۲۷-۱۲)$$



شکل ۲-۸ فاصله ازدحامی کل i [۳۸]

مراحل الگوریتم ژنتیک چند هدفی NSGA-II

ابتدا یک جمعیت اولیه به طور تصادفی انتخاب می شود. رتبه بندی جبهه ها انجام شده و پس از آن به کروموزوم های هر جبهه برآزشی مطابق رتبه آن اختصاص داده می شود. با اعمال عملگرهای پیوند یا تقاطع و جهش جمعیت ثانویه تولید می شود. دو جمعیت باهم ادغام شده و جمعیتی با دو برابر عضو تشکیل می دهد. رتبه بندی نامغلوب روی جمعیت جدید انجام می شود و کروموزوم ها در جبهه ها دسته بندی می شوند. در مرحله بعد با استفاده از فاصله ازدحامی، رتبه بندی کروموزوم هایی که به طور کامل نمی توانند در نسل جدید شرکت کنند صورت می گیرد. بر این اساس کروموزوم ها به صورت نزولی مرتب شده و عملگر انتخاب بر مبنای فاصله ازدحامی بر آن ها اعمال می شود. تمامی مراحل فرآیند انتخاب جمعیت برتر در الگوریتم ژنتیک چند هدفی در شکل ۲-۹ نشان داده شده است.



شکل ۲-۹ فرآیند انتخاب جمعیت برتر NSGA-II [۳۸]

۱۱-۲ معرفی پایگاه داده‌های موجود

برای تشخیص احساسات، اولین نیاز جمع آوری یا ثبت داده است. هرگاه تحقیقاتی با استفاده از داده های خام یکسان انجام شود، می توان عملکرد یا صحت تحقیق را با هم مقایسه کرد. در نتیجه، برخی از محققان داده‌هایی در این زمینه تحقیقاتی ساختند و بدون هیچ هزینه‌ای برای همه در دسترس قرار دادند. برخی از مجموعه داده‌های رایج و محبوب در جدول ۲-۳ فهرست شده است.

جدول ۲-۳ مجموعه داده های در دسترس عموم برای تشخیص احساسات

پایگاه داده	سال	محرك‌ها	تعداد شرکت کنندگان	مقیاس‌های درجه بندی	سیگنال‌های ثبت شده	توضیحات
[۳۹] GAMEEMO	۲۰۲۰	بازی‌های رایانه ای	۲۸	ظرفیت، برانگیختگی	EEG	شرکت کنندگان ۴ بازی رایانه ای مختلف (خسته کننده، آرام، ترسناک و خنده دار) را به مدت ۵ دقیقه به صورت احساسی انجام دادند.
SEED[۴۰]	۲۰۱۷	کلیپ‌های فیلم	۱۵(۷/۸)	مثبت، خنثی، منفی	EEG	سیگنال‌های EEG از ۶۲ کانال در طول تماشای ۱۵ کلیپ فیلم ضبط شدند.
AMIGOS[۴۱]	۲۰۱۷	فیلم	۴۰(۲۷/۱۳)	ظرفیت، برانگیختگی	EEG, ECG, GSR	مجموعه داده چندوجهی برای عاطفه، شخصیت و خلق و خو
DREAMER[۴۲]	۲۰۱۵	محرك های سمعی و بصری	۲۵(۱۴/۱۱)	ظرفیت، برانگیختگی، تسلط	۱۴ کانال ۱۲۸ هرتز EEG, ۲۵۶ هرتز ECG	با استفاده از تجهیزات قابل حمل، پوشیدنی، بی‌سیم، کم‌هزینه
DEAP[۴۳]	۲۰۱۲	فیلم	۳۲(۱۶/۱۶)	ظرفیت، برانگیختگی، تسلط، دوست	۳۲ کانال EEG, ۸ کانال	شامل داده های EEG, GSR, SKT, RESP

پایگاه داده	سال	محرك‌ها	تعداد شرکت کنندگان	مقیاس‌های درجه بندی	سیگنال‌های ثبت شده	توضیحات
				داشتن، آشنایی	فیزیولوژی	EOG, EMG BVP از ۳۲ داوطلب است که ۴۰ موزیک ویدیو یک دقیقه ای را تماشا می‌کنند.
MAHNOB-[۴۴] HCI	۲۰۱۱	ویدیو، عکس	۲۷(۱۱/۱۶)	کلیدواژه‌های احساسی، برانگیختگی، ظرفیت، تسلط، قابلیت پیش بینی	۳۲ کانال EEG، فیزیولوژی، حرکت چشم، صوت	۶ دوربین فیلمبرداری، میکروفون روی سر، ردیاب نگاه چشم و همچنین سنسورهای فیزیولوژی اندازه‌گیری ECG، EEG(۳۲ کانال)، دامنه تنفس و دمای پوست زیر نظر گرفتند.
IAPS[۴۵]	۲۰۰۵	عکس‌های رنگی	به درستی تعریف نشده است	لذت، برانگیختگی، تسلط	به درستی تعریف نشده است	تحریک احساسات افراد به‌وسیله چشم
IADS[۴۶]	۲۰۰۷	صدا	به درستی تعریف نشده است	لذت، برانگیختگی، تسلط	به درستی تعریف نشده است	صوت‌ها برای تحریک احساسات افراد به‌وسیله گوش

۲-۱۲ پیشینه بازشناسی عواطف بر اساس سیگنال EEG

در مطالعه وانگ و همکاران [۴۷] با استفاده از تحلیل مولفه‌های اصلی^۱ نتیجه بهتری نسبت به تحلیل تشخیصی خطی^۲ و ویژگی مبتنی بر همبستگی^۳ به دست آوردند. بالاترین درصد صحت ۸۲/۲۹ را با

^۱ Principal Component Analysis

^۲ Linear Discriminant Analysis

^۳ Correlation-Based Feature

طبقه‌بندی ماشین بردار پشتیبان^۱ با ویژگی اختلاف نامتقارنی ۱۲ جفت کانال درمجموع تمام باندهای فرکانسی و بعدازآن درصد صحت ۸۱/۵۲ با طبقه‌بندی پرسپترون چندلایه با ویژگی اختلاف نامتقارنی ۱۲ جفت کانال درمجموع تمام باندهای فرکانسی داشته‌اند. ژنگ و لو^[۴۰] باندها و کانال‌های فرکانسی بحرانی EEG را با استفاده از مدل شبکه باور عمیق آموزش داده‌شده با ویژگی‌های آنتروپی تفاضلی^۲ (DE)، در یک سیستم تشخیص احساسات (مثبت، خنثی و منفی) موردبررسی قرار دادند و توانستند به میانگین صحت ۸۶/۰۸ درصد در چهار کانال برسند. ژانگ و همکاران^[۴۸] به‌منظور بررسی الکترودهای حائز اهمیت، آزمایشی بر روی پایگاه داده‌ی در دسترس DEAP که متشکل از چند مجموعه داده برای بازشناسی حالت‌های عاطفی است انجام دادند. ۱۲۸ ویژگی (۴ ویژگی برای هر کانال) برای تمایز بین چهار حالت عاطفی شادی، ترس، غم، اندوه و آرامش استخراج شد. روش‌های انتخاب کانال مبتنی بر روش Relief موردبررسی قرار گرفت. در ابتدا رتبه‌بندی با استفاده از این الگوریتم بر روی ۱۲۸ ویژگی انجام شد. به‌منظور بررسی عملکرد سیستم تشخیص عواطف، طبقه‌بندی چهار حالت عاطفی شادی، ترس، غم و آرامش با استفاده از طبقه‌بند ماشین بردار پشتیبان انجام شد و حداکثر صحت طبقه‌بندی ۵۸/۵۱ درصد با کاهش تعداد الکترودها به هشت الکترودها به دست آمد. در پایان الگوریتم Relief بر روی ویژگی‌های همه نمونه‌ها (۱۶ نفر) مستقل از هر فرد^۳ اعمال شد و ۱۵ الکترودها برتر با میانگین‌گیری بر روی وزن‌ها به دست آمد. لی و همکاران^[۴۹] یک شبکه‌ی عصبی پیچشی سلسله مراتبی^۴ برای تشخیص سه احساس اساسی مبتنی بر EEG (مثبت، منفی و خنثی) پیشنهاد کردند. آنتروپی تفاضلی استخراج‌شده از کانال‌های EEG به‌عنوان ویژگی اصلی محاسبه می‌شود. این مقاله برای اولین بار پیشنهاد می‌کند که سیگنال‌های EEG چند کانال را به یک ماتریس دوبعدی تبدیل کند، که از وابستگی‌های فضایی در بین کانال‌های EEG استفاده می‌کند، درواقع آن‌ها محل ۶۲ کانال EEG را به نقشه دوبعدی تبدیل می‌کنند. برای کار تشخیص احساسات، این مقاله عملکرد شبکه‌ی عصبی پیچشی سلسله مراتبی با مدل عمیق یک‌بعدی رمزگذار خودکار پشته‌ای^۵ و همچنین مدل‌های سنتی کم‌عمق ماشین بردار پشتیبان و K نزدیک‌ترین همسایه مقایسه شد و نشان داد که مدل شبکه‌ی عصبی پیچشی سلسله مراتبی (۸۸/۲±۳/۵) از رمزگذار خودکار پشته‌ای (۸۵/۴±۸/۱) بهتر عمل می‌کند و مدل‌های عمیق در تشخیص احساسات واسط مغز-رایانه نسبت به مدل‌های کم‌عمق مطلوب‌تر هستند. در کار دیگری از لیس و همکاران^[۵۰] نشان دادند که شبکه‌ی عصبی پیچشی سلسله مراتبی در تشخیص احساسات به‌ویژه در امواج بتا و گاما کارآمد است. ژنگ^[۵۱] یک روش جدید تحلیل همبستگی متعارف پراکنده گروهی^۶ برای انتخاب هم‌زمان کانال EEG و تشخیص احساسات پیشنهاد کرد. تحلیل همبستگی متعارف پراکنده گروهی یک بسط گروهی پراکنده از روش تحلیل همبستگی متعارف^۷ برای مدل‌سازی

¹ Support Vector Machine

² Differential Entropy

³ Subject Independent

⁴ Hierarchical Convolutional Neural Networks

⁵ Stacked Autoencoder

⁶ Group Sparse Canonical Correlation Analysis

⁷ Canonical Correlation Analysis

همبستگی خطی بین بردارهای برچسب دسته EEG احساسی و بردارهای ویژگی EEG مربوطه است. آن‌ها ثابت کردند که روش تحلیل همبستگی متعارف پراکنده گروهی از روش‌های مدرن تشخیص احساسات مبتنی بر EEG بهتر است. صحت تشخیص متوسط چهار کانال هنگام تشخیص ویژگی‌های کامل باند فرکانسی، ۸۰/۲۰ درصد به دست آمد و یک الگوریتم جدید تشخیص احساسات در زمان واقعی [۵۲] بر اساس پایدارترین ویژگی‌ها مانند بعد فراکتال^۱، پنج ویژگی آماری، عبور از صفر مرتبه بالاتر^۲ و HOC مرتبه اول و ویژگی‌های توان چهار باند ایجاد کرد. این الگوریتم وابسته به سوژه^۳ است که برای یک سوژه جدید فقط به یک آموزش نیاز دارد و صحت آن برای طبقه‌بندی چهار احساسی ۴۹/۶۳ درصد، برای طبقه‌بندی دو احساسی ۷۱/۷۵ درصد و برای طبقه‌بندی احساس‌های مثبت/منفی ۷۳/۱۰ درصد است. با صحت کافی، نتایج آموزش را می‌توان در برنامه‌های تشخیص احساسات در زمان واقعی بدون آموزش مجدد استفاده کرد. در کار [۵۳] یک شبکه عصبی حافظه کوتاه‌مدت ماندگار دولایه برای تشخیص احساسات از سیگنال‌های EEG خام استفاده شد. به این ترتیب میانگین صحت ۸۵/۶۵، ۸۵/۴۵ و ۸۷/۹۹ درصد را برای سه دسته برانگیختگی، ظرفیت و دوست داشتن بر روی مجموعه داده‌ی DEAP به دست آورد. در پژوهشی از ژنگ و همکاران [۸]، هفت مرد و هشت زن با میانگین سنی ۲۳/۲۷ سال به منظور بررسی الگوی مغزی مرتبط با عواطف به صورت ایستا در طول زمان، مورد آزمایش قرار گرفتند. پانزده کلیپ محلی تحریک‌کننده‌ی عواطف با محتوای صوتی و تصویری شامل پنج فیلم برای القای حالت عاطفی مثبت، پنج فیلم عادی برای القای حالت خنثی و پنج فیلم برای القای حالت منفی استفاده شده است. در این مطالعه از ویژگی‌های چگالی طیفی توان^۴ (PSD)، آنالیز تفاضلی (DE)، عدم تقارن دیفرانسیل^۵ (DASM)، عدم تقارن منطقی^۶ (RASM)، عدم تقارن^۷ (ASM) و علیت دیفرانسیل^۸ (DCAU) استفاده شد. به منظور بهبود کارایی سیستم در بازشناسی حالت عاطفی و نیز افزایش راندمان یادگیری طبقه‌بند، از روش MRMR برای کاهش ابعاد داده‌ها استفاده و با روش تحلیل مولفه‌های اصلی مقایسه شد. در پایان طبقه‌بندی با استفاده از چهار الگوریتم K نزدیک‌ترین همسایه، رگرسیون لجستیک^۹، ماشین بردار پشتیبان و ماشین یادگیری افراطی^{۱۰} انجام گرفت و نتایج مقایسه شد. بهترین متوسط صحت ۹۱/۰۷ درصد برای طبقه‌بندی چهار حالت عاطفی (HAHV, LALV, LAHV, HALV) با استفاده از روش GELM به دست آمد. چارچوب جدیدی که متشکل از یک مدل مختلط EEG خطی و یک مدل زمان‌بندی احساسات است پیشنهاد شد [۵۴]. به ویژه، همبستگی‌های زمینه توالی‌های ویژگی EEG برای بهبود صحت تشخیص استفاده شد. مدل مختلط

¹ Fractal Dimension

² Higher Order Crossings

³ Subject Dependent Experiment

⁴ Power Spectral Density

⁵ Differential Asymmetry

⁶ Rational Asymmetry

⁷ Asymmetry

⁸ Differential Caudality

⁹ Logistic Regression

¹⁰ Graph Regularized Extreme Learning Machine

EEG خطی بر اساس رمزگذار خودکار پشته‌ای برای تجزیه سیگنال منبع EEG و برای استخراج همبستگی کانال EEG استفاده شد که زمان استخراج ویژگی را کاهش داد و عملکرد تشخیص احساسات را بهبود بخشید. شبکه عصبی حافظه کوتاه مدت ماندگار برای شبیه‌سازی مدل زمان‌بندی احساسات، که می‌تواند همبستگی‌های زمانی در توالی‌های ویژگی EEG را نیز بررسی کند، استفاده شد. نتایج به میانگین صحت تشخیص احساس ۷۶/۶۷ درصد در داده DEAP رسید. سلاما و همکاران [۱۵] یک روش شبکه عصبی پیچشی سه‌بعدی برای تشخیص احساسات از سیگنال‌های EEG چند کانال ارائه داد. آن‌ها یک مرحله افزایش داده را برای بهبود عملکرد مدل شبکه خود توسعه دادند و از مجموعه داده DEAP برای به دست آوردن ظرفیت ۸۷/۴۴ درصد و برانگیختگی ۸۸/۴۹ درصد استفاده کردند. یانگ و همکاران [۵۵] یک شبکه عصبی ترکیبی شبکه عصبی پیچشی و شبکه عصبی بازگشتی برای طبقه‌بندی احساسات انسان با یادگیری نمایش فضایی زمانی سیگنال‌های EEG خام پیشنهاد کرد. ماژول شبکه عصبی پیچشی ارتباط بین کانال را در بین سیگنال‌های EEG مجاور فیزیکی استخراج می‌کند و ماژول شبکه عصبی بازگشتی اطلاعات زمینه‌ای سیگنال‌ها را استخراج می‌کند. آن‌ها مدل خود را بر روی مجموعه داده DEAP آزمایش کردند و نشان دادند که مدل آن‌ها برای ظرفیت صحت ۹۰/۸۰ درصد و برای برانگیختگی صحت ۹۱/۰۳ درصد را به دست آورد. یانگ و همکاران [۵۶] با در نظر گرفتن سیگنال‌های پایه سعی در بهبود صحت تشخیص داشتند. آن‌ها سیگنال‌های EEG را به صورت یک مکعب سه‌بعدی از طریق ترکیبی از ویژگی‌های باندهای فرکانسی مختلف نشان داد و تأیید کردند که ترکیب چند باند فرکانسی نتایج بهتری را نسبت به تک باند نشان می‌دهد. این ویژگی‌های شکل سه‌بعدی ساخته شده به عنوان ورودی به شبکه عصبی کانولوشن پیوسته داده می‌شود. این مقاله نشان داده است که ویژگی‌های آنتروپی تفاضلی استخراج شده از سیگنال‌های EEG پایه می‌تواند صحت تشخیص را تا حد قابل توجهی بهبود بخشد. نتایج طبقه‌بندی عملکردی با میانگین صحت ۹۰/۲۴ و ۸۹/۴۵ درصد برای طبقه‌بندی برانگیختگی و ظرفیت در مجموعه داده SEED نشان می‌دهد. در مقاله [۵۷]، یک روش تشخیص هیجان EEG چند کانال بر اساس یک شبکه پویا جدید شبکه‌های عصبی پیچشی^۱ پیشنهاد شده است. گراف شبکه‌های عصبی پیچشی^۲ برای ثبت روابط بین کانال با استفاده از یک ماتریس مجاورت استفاده شده است. یک رابطه گراف بر اساس داده‌های EEG چند کانال ایجاد کرد و سپس برای جمع‌آوری ویژگی برای طبقه‌بندی، گراف پیچشی را روی آن انجام داد. میانگین صحت تشخیص در پایگاه داده SEED برای آزمایش وابسته به موضوع ۹۰/۴ درصد و برای اعتبارسنجی متقابل موضوعی^۳ ۷۹/۹۵ درصد به دست آمد و میانگین صحت ۸۶/۲۳، ۸۴/۵۴ و ۸۵/۰۲ درصد به ترتیب برای طبقه‌بندی ظرفیت، برانگیختگی و تسلط بر پایگاه داده DREAMER به دست آمده است. در مطالعه دیگری از تبدیل موجک تحلیلی انعطاف‌پذیر^۴ استفاده شده است که سیگنال‌های EEG را به زیر باند تجزیه می‌کند. الگوریتم‌های جنگل تصادفی و ماشین بردار پشتیبان به عنوان طبقه‌بندی شد و به میانگین

¹ Dynamical Graph Convolutional Neural Networks

² Graph Convolutional Neural Networks

³ Subject Independent Cross Validation

⁴ Flexible Analytic Wavelet Transform

صحت طبقه‌بندی ۹۰/۴۸ درصد برای مثبت، خنثی و منفی (سه دسته) در مجموعه داده SEED و ۷۱/۴۳ درصد برای HVHA/HVLA/LVLA/LVHA در مجموعه داده DEAP رسید [۵۸]. چارچوب ارایه‌شده در [۵۹] بر اساس یک شبکه متخاصم مولد^۱ (GAN) معمولی، به نام CWGAN^۲، برای تقویت تشخیص احساسات مبتنی بر EEG ساخته شد. داده‌های EEG با ابعاد بالا تولیدشده توسط چارچوب GAN پیشنهادی توسط سه شاخص ارزیابی شد تا اطمینان حاصل شود که داده‌های مصنوعی باکیفیت بالا به مکمل منیفولد اضافه می‌شوند. نتایج آزمایش مثبت بر روی مجموعه داده SEED به صحت ۸۶/۹۶ درصد و بر روی مجموعه داده DEAP برای ظرفیت صحت ۷۸/۱۷ درصد و برای برانگیختگی صحت ۷۳/۷۹ درصد را به دست آورد. در کار [۶۰] از یک روش فیلترینگ مبتنی بر همبستگی دومرحله‌ای و تجزیه به حالت‌های مختلف برای تشخیص احساسات شاد، ترس، غم و آرامش سیگنال EEG استفاده کردند. پس از فیلتر دومرحله‌ای ویژگی‌های استخراج‌شده به‌عنوان ورودی به طبقه‌بندی ماشین بردار پشتیبان چند مربعی چندطبقه^۳ (MC-LS-SVM) وارد می‌شود و به صحت ۹۰/۶۳ درصد می‌رسد. همچنین در [۶۱] یک مدل شبکه پیچشی ساختاری چند کانال برای تشخیص احساسات از سیگنال‌های EEG غیرثابت ارایه کرد که صحت ۹۰/۰۱ درصد برای ظرفیت و صحت ۹۰/۶۵ درصد برای برانگیختگی نشان داد. چینگ و همکاران [۶۲]، یک الگوریتم مبتنی بر ضریب را برای شبیه‌سازی عاطفی بر روی سیگنال‌های EEG از طریق یادگیری ماشین پیشنهاد کرد. طبقه‌بندی یادگیری ماشین برای استخراج ویژگی‌ها استفاده شد و برای اعتبارسنجی روش پیشنهادی، آزمایش‌هایی بر روی مجموعه داده‌های DEAP و SEED به ترتیب به صحت ۶۳/۰۹ و ۷۵ درصد رسیدند. نتایج این نکته را تأیید می‌کند که احساسات به تدریج در طول آزمایش فعال می‌شوند، و ضرایب وزن دهی بر اساس ضریب همبستگی و ضریب آنتروپی می‌تواند به‌طور موثری صحت تشخیص احساسات مبتنی بر EEG را بهبود بخشد. در [۶۳]، شبکه پیچشی را با استفاده از الگوریتم ازدحام ذرات با مجازات گرادین^۴ جهت رسیدگی به مساله‌هایی از جمله بازده همگرایی پایین الگوریتم ازدحام ذرات هنگامی که تعداد زیادی پارامتر برای بهینه‌سازی وجود دارد، بهبود بخشید. روش پیشنهادی با استفاده از سه حالت احساسی (ترس، شادی، غم) افراد که با استفاده از سیگنال‌های EEG جمع‌آوری شده بودند به صحت ۹۲/۴۴ درصد با انحراف استاندارد ۳/۶۰ در پانزده نفر به دست آمد. در مقاله دیگری در زمینه تشخیص احساسات [۶۴] یک چارچوب میدان تصادفی شرطی عمیق (DBN-CRF) با زنجیره گلیا (DBN-GC) و زمینه تصادفی مشروط برای ضبط وابستگی‌های طولانی‌مدت، اطلاعات زمینه‌ای و اطلاعات همبستگی را بین کانال‌های مختلف EEG پیشنهاد کرد. آن‌ها سیگنال‌های EEG چند کانال مجموعه داده‌های DEAP، AMIGOS و SEED را در یک پنجره زمانی خاص به چندین بخش تقسیم کردند و یک بردار ویژگی خام را از سیگنال‌ها استخراج کردند. هر بردار ویژگی خام در DBN-GC موازی تغذیه شد تا نمایشی در سطح بالا استخراج شود. سپس، توالی سطح بالا حاوی اطلاعات همبستگی بین کانال سیگنال EEG به CRF داده شد.

^۱ Generative Adversarial Network

^۲ Conditional Wasserstein GAN

^۳ Multi Class Least Squares Support Vector Machine

^۴ Gradient Penalties

CRF دنباله برچسب احساسات پیش‌بینی شده را ایجاد می‌کند و لایه ادغام تصمیم‌گیری بر اساس الگوریتم K نزدیک‌ترین همسایه می‌تواند برای تعیین حالت احساسی استفاده شود. آن‌ها به میانگین صحت ۷۶/۵۸ درصد از نظر اعتبارسنجی متقابل leave-one-out رسیدند. کار [۶۵]، یک شبکه عصبی پیچشی سه‌بعدی برای استخراج خودکار ویژگی‌های مکانی زمانی از سیگنال‌های EEG در کار تشخیص احساسات پیشنهاد کرد. این شبکه در مجموعه داده DEAP به صحت ۹۶/۶۱، ۹۶/۴۳ درصد در کار طبقه‌بندی دو دسته (برانگیختگی، ظرفیت) و ۹۳/۵۳ درصد در طبقه‌بندی چهار دسته (HVHA/HVLA/LVLA/LVHA) رسید و همچنین در مجموعه داده‌های AMIGOS به صحت‌های ۹۷/۵۲، ۹۶/۹۶ درصد در طبقه‌بندی دو دسته و صحت ۹۵/۸۶ درصد در طبقه‌بندی چهار دسته رسید. یک شبکه عصبی گراف منظم در [۶۶] برای تشخیص احساسات مبتنی بر EEG، که شامل روابط بین کانال است، استفاده می‌شود. نتایج طبقه‌بندی در مجموعه داده SEED عبارت‌اند از: ۶۴/۸۸، ۶۰/۶۹، ۶۰/۸۴، ۷۴/۹۶، ۷۷/۵۰ و ۸۵/۳۰ درصد برای دلتا، تتا، آلفا، بتا، گاما و همه باندها. علاوه بر این، صحت درصد ۷۳/۸۴ را در مجموعه داده SEED به دست آورد. در پژوهش نکيسا و همکاران [۳۳] با استفاده از دو مجموعه داده عمومی (DEAP، MAHNOB) و یک مجموعه داده جدید که با سنسورهای EEG موبایل به دست آمده، یک روش جدید برای انتخاب ویژگی بهینه EEG با استفاده از الگوریتم پردازش تکاملی و یک شبکه عصبی احتمالی (PNN)^۱ پیشنهاد شده است. در ۱۰۰ تکرار در الگوریتم آنتروپی تفاضلی و ازدحام ذرات و الگوریتم ژنتیک به صحت $3/38 \pm 67/47$ و $3/22 \pm 65/32$ و $3/17 \pm 63/63$ درصد بترتیب در مجموعه داده DEAP رسید. حداکثر صحت عملکرد مبتنی بر مجموعه داده MAHNOB، ۹۶/۹۷ درصد و در مجموعه داده DEAP، ۶۷/۶۷ درصد بود. ین و همکاران [۶۷] با استفاده از شبکه عصبی پیچشی گرافی (GCNN) و شبکه‌ی عصبی حافظه کوتاه‌مدت ماندگار یک روش جدید تشخیص احساسات را بر روی مجموعه داده DEAP آرایه کرد. آنتروپی دیفرانسیل استخراج شده از هر بخش مکعب ویژگی ایجاد می‌کند و به عنوان ورودی به مدل داده می‌شود. میانگین صحت طبقه‌بندی ۹۰/۴۵ و ۹۰/۶۰ درصد برای ظرفیت و برانگیختگی در این مجموعه داده بود.

۱۳-۲ جمع‌بندی

در این فصل، پس از بیان مقدمات و مبانی مربوط به احساسات، به تشریح فرآیند کلی و عمومی شناسایی احساسات به کمک سیگنال EEG پرداخته شد. سپس برخی از شبکه‌های عصبی عمیق شرح داده شدند و روش‌های مختلف بهینه‌سازی ابرپارامترهای شبکه عصبی توضیح داده شد. در نهایت تحقیقات گذشته را مورد بررسی قرار گرفته شد. در فصل بعد به شرح الگوریتم پیشنهادی پرداخته خواهد شد.

^۱ Probabilistic Neural Network

فصل سوم

مواد و روش‌ها

۳-۱ مقدمه

در این فصل ابتدا به معرفی مجموعه داده‌های استفاده‌شده برای ارزیابی روش پیشنهادی در این پژوهش پرداخته می‌شود. سپس، ساختار کلی و جزئیات روش پیشنهادی شامل روش بهینه‌سازی ابر پارامترها، معماری شبکه بهینه تشریح داده می‌شود.

۳-۲ مجموعه داده‌های استفاده‌شده برای ارزیابی روش‌های پیشنهادی

ارزیابی و مقایسه روش‌های گوناگون تشخیص احساسات نیازمند مجموعه داده استاندارد و یکسان است. به این منظور در این پایان‌نامه از مجموعه داده‌های استاندارد DEAP و SEED استفاده‌شده است تا امکان مقایسه نتایج به‌دست‌آمده با نتایج دیگر محققان وجود داشته باشد. به‌علاوه، برچسب‌گذاری هر حالت از قبل انجام‌شده که این موضوع امکان ایجاد خطا در دسته‌بندی حالات را بسیار کم می‌کند.

۳-۲-۱ مجموعه داده DEAP

مجموعه داده DEAP که توسط تیمی از محققان در دانشگاه کوبین مری لندن تهیه‌شده است، حاوی سیگنال‌های فیزیولوژی متعدد با ارزیابی احساسی است. این پایگاه، یک پایگاه داده چندوجهی^۱ است که شامل سیگنال EEG و سایر سیگنال‌های فیزیولوژی (همانند EMG و EOG) است. داده‌های این پایگاه با استفاده از ۳۲ داوطلب (۱۶ مرد و ۱۶ زن) در حین تماشای کلیپ‌های ویدیویی انتخاب‌شده برای مطالعه حالات عاطفی انسان جمع‌آوری شده است. این پایگاه به‌طور کلی ۴۰ کانال دارد که ۳۲ کانال آن

^۱ Multimodal

برای سیگنال EEG و هشت کانال باقیمانده برای سیگنال‌های فیزیولوژی دیگر است. کلیپ‌های موسیقی انتخاب شده حاوی ۴۰ ویدیوی ۱ دقیقه‌ای هستند که بسته به احساسات القاکننده آن‌ها برچسب‌گذاری شده‌اند. ۳۲ کانال EEG با استفاده از روش الکتروود گذاری ۱۰-۲۰ جمع‌آوری شدند. نسخه از پیش‌پردازش شده داده‌ها از ۵۱۲ هرتز به ۱۲۸ هرتز کاهش یافت و یک فیلتر میان‌گذر از ۴/۰ تا ۴۵/۰ هرتز اعمال شد. شرکت‌کننده‌ها پس از تماشای کلیپ‌های موسیقی، آزمون خودارزیابی آدامک (SAM) با رتبه‌بندی از ۱ تا ۹ پنج حالت مختلف برانگیختگی، ظرفیت، تسلط، دوست داشتن و آشنایی را انجام دادند (جدول ۳-۱). محدوده ظرفیت از ناراضی به راضی (به‌طور نمونه از منفی به مثبت)، دامنه برانگیختگی از غیرفعال به فعال (مثلاً از غیر هیجان‌زده به هیجان‌زده) گسترش می‌یابد. مدل دوبعدی اطلاعاتی در مورد تسلط و دوست داشتن ارائه نداده است. پایگاه DEAP حالات احساسی را به دو سطح از برانگیختگی و ظرفیت تقسیم می‌کند. مطابق با مقادیر اختصاص داده‌شده، آزمایش‌های حالات به دو دسته مختلف تقسیم می‌شود. آستانه به‌عنوان ۵ انتخاب شده است و طرح حالت عاطفی را می‌توان به‌عنوان چهار تخمین باینری استفاده کرد. مدل دوبعدی توسط چهار ترکیب مختلف به‌صورت مقادیر کم یا زیاد حالت‌های احساسی ظرفیت و برانگیختگی (HALV, HAHV, LALV, LAHV) نگاشت شده است.

جدول ۳ - ۱ نگاه اجمالی به مجموعه داده DEAP

شرکت‌کننده‌ها	فیلم	کانال‌ها	نرخ نمونه‌برداری (هرتز)	مقیاس رتبه‌بندی	ارزش‌های رتبه‌بندی
۳۲	۴۰	۳۲	۱۲۸	ظرفیت برانگیختگی	مقیاس پیوسته ۱-۹

۳-۲-۲ مجموعه داده SEED

این پایگاه داده با استفاده از ۱۵ داوطلب (۷ مرد و ۸ زن) زمانی که از آن‌ها خواسته شد ۱۵ فیلم را تماشا کنند جمع‌آوری شده است. به‌منظور برانگیختن موثر احساسات ۱۵ شرکت‌کننده در آزمایش، مدت‌زمان هر کلیپ حدود ۴ دقیقه در نظر گرفته شده بود و هر فیلم به‌راحتی قابل‌درک بود. برای هر موضوع ۱۵ آزمایش^۱ در نظر گرفته شد که هر کدام ۳۰۵ ثانیه به طول انجامید. این کار آزمایی شامل ۵ ثانیه اشاره به فیلم، ۴ دقیقه کلیپ، ۴۵ ثانیه خودارزیابی و ۱۵ ثانیه استراحت است. سیگنال‌های EEG در این پایگاه داده از ۶۲ الکتروود (که شامل اطلاعات بیشتری نسبت به پایگاه داده DEAP است) جمع‌آوری شده است. بعد از جمع‌آوری، سیگنال‌های EEG با فرکانس ۲۰۰ هرتز نمونه‌کاهی^۲ شده‌اند. همچنین یک پالایه میان‌گذر گذر از ۰ تا ۷۵ هرتز به آن‌ها اعمال شده است. این پایگاه داده دارای سه برچسب احساسی به نام‌های منفی، مثبت و خنثی (طبیعی) است. مقدار برچسب‌ها برای دسته‌های منفی، مثبت و خنثی به ترتیب ۱-، ۰ و ۱ است. بدین ترتیب، برچسب‌ها در پایگاه داده SEED شامل سه دسته هستند. در این پایان‌نامه، به‌منظور ساده‌سازی فرآیند آموزش شبکه‌ی عمیق این مقادیر به ترتیب ۰، ۲ و ۱ تغییر

^۱ Trial

^۲ Downsampled

داده شده است.

۳-۲-۳ بخش‌بندی و برچسب‌گذاری دوباره پایگاه داده DEAP

منتشرکنندگان پایگاه DEAP، یک نسخه پیش‌پردازش شده ثبت‌های EEG را نیز ارائه داده‌اند. در این نسخه، سیگنال‌های EEG با فرکانس ۱۲۸ هرتز نمونه‌کاهی^۱ شده‌اند. درست‌نماهای الکتروکولوگرافی (EOG) حذف شدند و نویز نیز با استفاده از یک فیلتر میان‌گذر^۲ با فرکانس‌های قطع ۴-۴۵ هرتز حذف شده است. در این پایان‌نامه، از این نسخه استفاده شده است و هیچ فیلترسازی دیگری برای سیگنال‌های EEG پیش‌پردازش اعمال نشده است و تنها بخش‌بندی^۳ و برچسب‌گذاری دوباره انجام شده است. در مرحله بخش‌بندی، ۳۲ کانال سیگنال EEG به ۶ پنجره ۱۰ ثانیه‌ای (هر پنجره شامل ۱۲۸۰ نمونه) با همپوشانی ۲ ثانیه‌ای (۲۵۶ نمونه) برای هر فیلم تقسیم می‌شوند. این بدان معناست که برای شخص اول timestamp از $t=0$ تا $t=1279$ است. به طور مشابه، برای شخص دوم timestamp از $t=256$ تا $t=1535$ است. این نوع بخش‌بندی منجر به دستیابی به ۳۴۵۶۰ فایل EEG چندکاناله می‌شود و اندازه ماتریس نهایی به صورت $32 \times 1280 \times 34560$ خواهد شد؛ که در آن ۳۲ تعداد کانال‌های EEG و ۱۲۸۰ اندازه پنجره است. توزیع نمونه‌های دارای برچسب کم و زیاد برای مجموعه داده‌ها به صورت ۱۵۸۴۹ نمونه با برچسب زیاد و ۱۸۷۱۱ نمونه با برچسب کم برای حالت برانگیختگی، ۱۶۷۹۴ نمونه با برچسب زیاد و ۱۷۷۶۶ نمونه با برچسب کم برای حالت ظرفیت، ۱۶۸۲۱ نمونه با برچسب زیاد و ۱۷۷۳۹ نمونه با برچسب کم برای حالت تسلط، ۲۰۹۲۵ نمونه با برچسب زیاد و ۱۳۶۳۵ نمونه با برچسب کم برای حالت دوست داشتن پس از اعمال رویکرد برچسب‌گذاری مجدد پیشنهادی یافت می‌شود. همه فریم‌های به‌دست‌آمده از یک کلیپ ویدیویی پس از فرآیند برچسب‌گذاری مجدد، به‌طور خودکار به همان برچسبی اختصاص می‌یابند که همان برچسب ویدیویی را برای هر شخص با کمک کد مشخص می‌کند. با استفاده از روش پیشنهادی برچسب‌گذاری مجدد، توزیع برچسب در سطح معینی متعادل شده است. مطابق با رتبه‌بندی آدمک خودارزیابی توسط شرکت‌کننده‌ها برای برچسب‌های ظرفیت، برانگیختگی، تسلط و دوست داشتن در مجموعه داده DEAP، هشت نوع احساس گوناگون ایجاد می‌شود. اگر مقدار یک حالت کمتر از ۵ باشد، حالت احساسی به‌عنوان کم (دسته ۰) برچسب‌گذاری می‌شود؛ در غیر این صورت، به‌عنوان زیاد (دسته ۱) برچسب‌گذاری می‌شود. به‌بیان دیگر، هر حالت عاطفی شامل دو حالت کم و زیاد خواهد بود. این فرآیند برچسب زدن برای چهار نوع حالت عاطفی (ظرفیت، برانگیختگی، تسلط و دوست داشتن) انجام می‌شود.

۳-۳ روش پیشنهادی


در سال‌های اخیر، با پیشرفت روش‌های یادگیری ماشین و به‌ویژه روش‌های یادگیری عمیق، در حوزه تشخیص خودکار احساسات پیشرفت‌های چشمگیری حاصل شده است. یکی از روش‌های رایج و کاربردی برای این منظور، شبکه‌های عصبی پیچشی (CNN) است. این شبکه از دو مشکل اساسی پیچیدگی

¹ Downsampled

² Bandpass

³ Segmentation


شبکه و تعداد ابر پارامترهای زیاد رنج می‌برد. در این پایان‌نامه برای حل مشکل اول یک شبکه عمیق با تعداد پارامترهای کم پیشنهاد شده است. همچنین برای حل مشکل دوم در این پژوهش به منظور دستیابی به یک مدل یادگیری عمیق بهینه از روش بهینه‌سازی ابر پارامترها^۱ با استفاده از یک الگوریتم تکاملی به نام الگوریتم ژنتیک چند هدفی NSGAII استفاده شده است. بعد از دستیابی به مدل بهینه، از آن برای دسته‌بندی حالت احساسی در دو پایگاه داده DEAP و SEED استفاده می‌کنیم. شکل ۳-۱، ساختار کلی و مراحل روش پیشنهادی را نشان می‌دهد. در ادامه به تشریح اجزای اصلی روش پیشنهادی پرداخته خواهد شد.



شکل ۳-۱ ساختار کلی روش پیشنهادی

بهینه‌سازی ابر پارامترها فرآیندی برای یافتن ترکیب مناسب از مقادیر ابر پارامترها به منظور دستیابی به حداکثر کارایی روی داده‌ها در مدت‌زمان معقول است. بیشتر شبکه‌های عمیق با مقادیر پیش‌فرض ابر پارامترها آموزش داده می‌شوند. مقادیر پیش‌فرض به‌طور معمول در بررسی شبکه‌های عمیق عملکرد خوبی ندارند، به همین دلیل باید آن‌ها را بهینه کرد تا ترکیب مناسبی را که بهترین عملکرد را دارد بدست آورد؛ به عبارت دیگر، معماری شبکه تأثیر بسزایی در صحت دارد؛ بنابراین، یک روش بهینه‌سازی شبکه عصبی پیچشی با استفاده از الگوریتم NSGA-II پیشنهاد شده است. شکل ۳-۲ چارچوب روش بهینه‌سازی را نشان می‌دهد.

¹ Hyperparameters Optimization



شکل ۳-۲ چارچوب فرآیند بهینه سازی

در این فرآیند، بهینه‌سازی سه مرحله وجود دارد. نخست الگوریتم NSGA-II افراد را برای هر نسل برای به دست آوردن بهترین راه حل برای یک مشکل تولید می‌کند. این افراد با یک امتیاز یا معیار شایستگی رتبه‌بندی می‌شوند؛ یعنی هر فرد تبدیل به جواب متناظر شده و در تابع هدف قرار می‌گیرد، این شایستگی احتمال انتخاب شدن را بسته به روش انتخاب تعیین می‌کند. افراد ابر پارامترهایی هستند که برای پیکربندی شبکه استفاده می‌شوند. دوم اینکه شبکه با استفاده از افراد ساخته می‌شود. شبکه آموزش‌دیده و آزمایش می‌شود. بالا بردن صحت هدف الگوریتم بهینه‌سازی چند هدفی است. در نهایت، این هدف به الگوریتم NSGA-II برای تولید افراد جدید بازگردانده می‌شوند. در این پایان‌نامه، ابر پارامترها برای تنظیم ساختار شبکه تعریف می‌شود و بنابراین مساله یافتن ساختار بهینه یک شبکه عصبی پیچشی به‌عنوان یک مساله بهینه‌سازی ابر پارامترها چند هدفی مطرح می‌شود. هدف از بهینه‌سازی ابر پارامتر یافتن ساختاری است که تابع خطا را کمینه کند و یا معیارهای ارزیابی دیگر مانند صحت مدل را بیشینه کند.

روش پیشنهادی از یک استراتژی لایه به لایه برای بهینه‌سازی ابر پارامترهای شبکه پیچشی عمیق استفاده می‌کند. در الگوریتم‌های تکاملی چند هدفی به‌جای پاسخ بهینه، سعی در یافتن مجموعه‌ای از جواب‌هاست که توزان نسبی بین اهداف مختلف را برقرار می‌کند. هدف اصلی استفاده از استراتژی لایه به لایه، کاهش حجم محاسبات و کاهش پیچیدگی فرآیند تنظیم ابر پارامترها است. به‌بیان دیگر، از بهینه سازی ایستا استفاده می‌شود؛ زیرا بهینه‌سازی پویا نه تنها باعث افزایش میزان RAM می‌شود بلکه فضای جستجوی پارامترها را نیز پیچیده می‌کند. این استراتژی بدین صورت است که در زمان بهینه‌سازی ابر پارامترها، تنها یک لایه ابر پارامترهای متغیر دارد و بقیه لایه‌ها پارامترهای پیش فرض دارند.

۳-۴ بهینه‌سازی ابر پارامترها

یکی از پرکاربردترین و قدرتمندترین الگوریتم‌های موجود برای حل مساله‌های بهینه‌سازی، بهینه‌سازی چند هدفی است و کارایی آن در حل مساله‌های مختلف، به اثبات رسیده است. در کنار تمام کارایی‌هایی که الگوریتم تکاملی NSGA-II دارد، می‌توان آن را الگوی شکل‌گیری بسیاری از الگوریتم‌های بهینه‌سازی چندهدفی دانست. بدون شک این الگوریتم یکی از اساسی‌ترین الگوریتم‌های بهینه‌سازی چندهدفی تکاملی است. مساله‌ها در صورتی که به شکل واقعی مدل‌سازی شوند دارای چند هدف می‌باشند که ممکن است این اهداف با یکدیگر در تناقض باشند؛ یعنی با کمینه شدن یکی از آن‌ها هدف دیگر افزایش

می‌باید. در الگوریتم‌های تکاملی چند هدفی به‌جای پاسخ بهینه، سعی در یافتن مجموعه‌ای از جواب‌هاست که توزان نسبی بین اهداف مختلف را برقرار می‌کند. به این پاسخ‌ها، جواب‌های متعادل^۱ یا متوازن می‌گویند. در این پژوهش هدف به حداکثر رساندن صحت یا به حداقل رساندن خطای به‌دست‌آمده از مجموعه داده آزمایشی است. تعداد پارامترها را می‌توان به‌عنوان شاخصی از پیچیدگی شبکه در نظر گرفت. شبکه عصبی پیچشی دارای ابر پارامترهای زیادی است که بر عملکرد شبکه تاثیر می‌گذارد. جدول ۲-۳ ابر پارامترهای اصلی انتخاب‌شده و مقادیر متغیر آن‌ها را نشان می‌دهد. پیمودن هر ترکیبی برای یافتن مجموعه شبکه بهینه دشوار است؛ بنابراین می‌توان از الگوریتم NSGA-II برای یافتن بهترین ترکیب استفاده کرد. جمعیت اولیه به‌طور تصادفی با استفاده از نام ابر پارامتر و مقادیری برای ابر پارامتر پیشنهاد می‌شود. در این پژوهش اندازه جمعیت (Np)، ۵۰ است. سپس، ارزیابی ابر پارامترها در جایگاه‌های آموزشی ذخیره می‌شود. تولید نسل جدید تا زمانی که شرط یا شرایط توقف برآورده شود، ادامه پیدا می‌کند. یکی از روش‌ها محدود کردن تعداد نسل‌ها است که می‌توان مشخص کرد، برنامه تا چند نسل پیش برود. در این پژوهش شرط توقف ۱۰ آزمایش است. الگوریتم متغیرهای شبکه را باهم ترکیب کرده و برای هر آزمایش صحت و تابع هزینه محاسبه می‌شود و با استفاده از الگوریتم NSGA-II بهترین ترکیب برای هر لایه انتخاب می‌شود. به دلیل حجم بالای حافظه مصرفی برای عملیات جستجوی ابر پارامترها، تعداد نمونه‌ای آموزش به ۴۲۵۰ نمونه، نمونه‌های اعتبارسنجی به ۷۵۰ نمونه و نمونه‌های آزمون به ۱۰۰۰ نمونه تقلیل داده شد. شایان‌ذکر است که این بهینه‌سازی تنها برای پایگاه داده DEAP انجام‌شده است و پس از دستیابی به مدل بهینه، از آن برای آموزش و آزمون پایگاه داده SEED استفاده شد.

جدول ۳ - ۲ مقادیر مورد استفاده برای ابر پارامترهای لایه‌های شبکه

لایه FC اول		لایه پیچشی اول	
ابری پارامتر	بازه	ابری پارامتر	بازه
تعداد واحدها	[۶۴، ۱۲۸، ۲۵۶]	تعداد فیلترها	[۳۲، ۶۴، ۱۲۸]
تابع فعال‌سازی	['relu', 'linear', 'tanh']	اندازه هسته	[۱، ۲]
		گام‌ها	[۱، ۲]
		لایه‌گذاری	['valid', 'same', 'causal']
		تابع فعال‌سازی	['relu', 'elu', 'swish']
لایه FC دوم		لایه پیچشی دوم	
تعداد واحدها	[۸، ۱۶، ۳۲]	تعداد فیلترها	[۳۲، ۶۴، ۱۲۸]
تابع فعال‌سازی	['relu', 'linear', 'tanh']	اندازه هسته	[۳، ۵]
		گام‌ها	[۱، ۲]
		لایه‌گذاری	['valid', 'same', 'causal']
		تابع فعال‌سازی	['relu', 'elu', 'swish']

^۱ Trade-Offs


لایه FC اول	لایه پیچشی اول	
	لایه پیچشی سوم	
	تعداد فیلترها	[۱۲۸, ۱۹۲, ۲۵۶]
	اندازه هسته	[۳, ۵]
	گام‌ها	[۱, ۲]
	لایه‌گذاری	['valid', 'same', 'causal']
	تابع فعال‌سازی	['relu', 'elu', 'swish']

الگوریتم NSGAII در فضای ابر پارامترها جستجو می‌کند و یکسری از ابر پارامترها را انتخاب می‌کند و با استفاده از این ابر پارامترها، آموزش و آزمون مدل را انجام می‌دهد و در نهایت بعد از ۱۰ آزمایش، بهترین ابر پارامترها را پیشنهاد می‌دهد و با استفاده از این ابر پارامترهای پیشنهادی برای هر لایه، ابر پارامترهای هر لایه تنظیم می‌شود. جدول ۳-۳ ابر پارامترهای ساختار شبکه پس از بهینه‌سازی توسط NSGA-II را نشان می‌دهد.


جدول ۳ - ۳ بهترین ابر پارامترهای یافت شده

لایه FC اول		لایه پیچشی اول	
ابر پارامتر	بازه	ابر پارامتر	بازه
تعداد واحدها	۶۴	تعداد فیلترها	۳۲
تابع فعال سازی	tanh	اندازه هسته	۲
		گام	۱
		لایه گذاری	same
		تابع فعال سازی	relu
لایه FC دوم		لایه پیچشی دوم	
تعداد واحدها	۸	تعداد فیلترها	۱۲۸
تابع فعال سازی	tanh	اندازه هسته	۵
		گام ها	۱
		لایه گذاری	same
		تابع فعال سازی	relu
		لایه پیچشی سوم	
		تعداد فیلترها	۱۹۲
		اندازه هسته	۳
		گام ها	۲
		لایه گذاری	same
		تابع فعال سازی	relu

نمودار مختصات موازی^۱ برای مقایسه بسیاری از متغیرها باهم و دیدن روابط بین آن‌ها ایده آل است و امکان مقایسه نمونه‌ها را در بین متغیرهای عددی متعدد فراهم می‌کند. مقادیر به صورت یک سری خطوط که در تمام محورها به هم متصل می‌شوند رسم می‌شوند. این بدین معناست که هر خط مجموعه‌ای از نقاط قرار گرفته در هر محور است که همه به هم متصل شده‌اند. برای نمونه نمودار مختصات موازی تنظیم ابر پارامترها در لایه پیچشی اول در شکل ۳-۳ و لایه FC اول در شکل ۳-۴ نشان داده شده است. بهترین عملکرد مجموعه ابر پارامترها با رنگ آبی پررنگ مشخص شده است. نمودار مناسب دیگر برای درک اهمیت ابر پارامترها نمودار برش^۲ است؛ که نوعی نمودار سه بعدی از ابر پارامترهای مختلف را ارائه می‌دهد که بر اساس مقدار هدف آن‌ها تنظیم شده است و نتایج به صورت نقاط تیره نشان داده می‌شود. این نمودار می‌تواند به درک اینکه بهترین زیر فضاها برای هر پارامتر به صورت جداگانه در کجا قرار دارند کمک کند. شکل ۳-۵ نمودار برش برای لایه FC اول را نشان می‌دهد.




شکل ۳-۳ نمودار مختصات موازی، بهترین عملکرد ابر پارامترها در لایه پیچشی اول



شکل ۳-۴ نمودار مختصات موازی، بهترین عملکرد ابر پارامترها در لایه FC اول

^۱ Parallel Coordinates Plot

^۲ Plot Slice




شکل ۳-۵ نمودار برش، بهترین عملکرد ابر پارامترها در لایه FC اول

۳-۵ شبکه عصبی پیچشی بهینه‌سازی شده

بعد از تعیین شبکه عصبی پیچشی بهینه با استفاده از بهینه‌سازی ابر پارامترها، از این شبکه برای دسته بندی حالت احساسی استفاده می‌کنیم. ورودی این شبکه سیگنال EEG است که از لایه پیچشی و سپس، به منظور کاهش تعداد ویژگی‌ها از لایه Pooling (Average Pooling) عبور می‌کند. همچنین از آنجایی که لایه مسطح سازی^۱ شامل تعداد زیادی پارامتر است، به منظور کاهش تعداد پارامترهای شبکه به جای استفاده از لایه مسطح سازی از لایه Global Average Pooling (GAP) استفاده شد. از طرف دیگر، به منظور جلوگیری از مشکل واریانس بالا که ممکن است باعث ایجاد بیش برآزش به داده‌ها توسط مدل شود، از لایه Dropout نیز استفاده شد. در نهایت، برای دسته‌بندی حالت‌های احساسی از لایه Softmax استفاده شد. در شکل (۳-۴) معماری شبکه پیشنهادی نشان داده شده است. شایان ذکر است که شبکه پیشنهادی تنها ۱۱۰۹۰۶ و ۱۰۸۹۲۲ پارامتر به ترتیب برای داده DEAP و SEED دارد و در مقایسه با بسیاری از روش‌های پیشرفته در تشخیص احساسات، تعداد پارامترهای کمتری دارد. در ادامه جزئیات بیشتر در مورد هر یک از لایه‌های تشکیل دهنده شبکه پیشنهادی شرح داده خواهد شد. شکل ۳-۴ شبکه‌های عصبی پیچشی بهینه‌شده را در مجموعه داده DEAP نشان می‌دهد.

^۱ Flatten



شکل ۳-۶ معماری شبکه بهینه شده مجموعه داده DEAP

۳-۵-۱ لایه پیچشی

لایه پیچشی اصلی‌ترین لایه در شبکه عصبی پیچشی است که چند فیلتر (تحت عنوان کرنل نیز شناخته می‌شود) را با سیگنال ورودی کانوالو می‌کند. هدف استفاده از این لایه استخراج ویژگی‌ها از سیگنال ورودی است که با کانوالو کردن درایه‌های سیگنال ورودی با ناحیه کوچکی به نام ناحیه تأثیر^۱ که به صورت محلی به هم متصل هستند، انجام می‌شود. درواقع می‌توان بیان کرد که این لایه به سیگنال عمق می‌دهد. ابر پارامترهای آن مجموعه‌ای از فیلترهای قابل آموزش است که شامل ابعاد (F) و اندازه گام (S) فیلتر می‌شود. اندازه گام (S) به تعداد پیکسل‌هایی که پنجره بعد از هر عملیات جابه‌جا می‌شود، اشاره دارد. شایان ذکر است که عملیات کانولوشن می‌تواند به صورت یک‌بعدی، دوبعدی و سه‌بعدی انجام شود. در این پایان‌نامه به دلیل ساختار یک‌بعدی سیگنال ورودی از عملیات کانوالوشن یک‌بعدی استفاده شده است.

۳-۵-۲ Pooling

بعد از به دست آوردن ویژگی‌ها در لایه پیچش، مرحله بعدی استفاده از این ویژگی‌ها برای دسته‌بندی است. استفاده از یک دسته‌بندی‌کننده برای دسته‌بندی میلیون‌ها ویژگی هیچ مزیتی ندارد. علاوه بر این دسته‌بندی‌کننده ممکن است دچار بیش‌برازش شود. برای حل این مشکل از لایه Pooling استفاده می‌شود که باعث کاهش ابعاد مکانی^۲ می‌شود و این تا حدی منجر به کاهش محاسبات آموزش شبکه می‌شود. شایان ذکر است که عملیات Pooling به صورت مجزا بر روی هر کانال سیگنال انجام می‌شود. همان‌طور که در فصل قبل گفته شد، Max Pooling و Avg Pooling انواع خاص Pooling هستند. در Max Pooling، مقدار بیشینه در یک ناحیه تعریف شده با استفاده از یک پنجره Pooling (به‌طور معمول یک فیلتر 2×2) گرفته می‌شود. در Avg Pooling، مقدار میانگین در یک ناحیه تعریف شده گرفته می‌شود و اولین بار در شبکه LeNet به کار گرفته شد. در این پایان‌نامه از Avg Pooling استفاده شده است.

۳-۵-۳ لایه نرمال‌سازی دسته‌ای (BN)

به‌طور معمول بعد از یک لایه‌ی تمام متصل یا لایه‌ی پیچشی و قبل از یک لایه‌ی غیرخطی، نرمال‌سازی دسته‌ای اعمال می‌شود و امکان استفاده از نرخ یادگیری بالاتر را می‌دهد و هم‌چنین باعث می‌شود که وابستگی شدید مدل به مقداردهی اولیه کاهش یابد.

۳-۵-۴ Dropout

Dropout روشی است که در شبکه‌های عصبی برای جلوگیری از بیش‌برازش بر روی داده‌های آموزشی با حذف تصادفی نورون‌ها با احتمال $p > 0$ استفاده می‌شود. این روش مدل را مجبور می‌کند تا از تکیه کردن بیش از حد بر روی مجموعه خاصی از ویژگی‌ها خودداری کند، به بیان دیگر، در این روش از آن‌جا که یک نورون نمی‌تواند بر حضور برخی از نورون‌های دیگر متکی باشد، سازگاری نورون‌ها را کاهش می‌دهد؛ بنابراین، شبکه مجبور به یادگیری ویژگی‌های قوی‌تر و مفیدتر است. در عمل، واحدها با احتمال p حذف یا با احتمال $1-p$ حفظ می‌شوند.

¹ Respective Field

² Spatial

۳-۵-۵ لایه تمام متصل (FC)

لایه‌ی FC شبیه به شبکه عصبی پرسپترون چندلایه است و به عنوان یک دسته‌بندی کننده عمل می‌کند که هر نورون را به نورون‌های لایه قبل متصل می‌کند و سپس امتیازات هر دسته را در خروجی می‌آورد. لایه‌های FC در صورت وجود، به طور معمول در انتهای معماری‌های شبکه عصبی پیچشی یافت می‌شوند و می‌توان آن‌ها را برای بهینه‌سازی اهدافی مانند امتیازات دسته به کار برد.

۳-۵-۶ Softmax

لایه Softmax وظیفه دسته‌بندی نهایی ویژگی‌ها را بر عهده دارد. در این لایه از تابع Softmax به عنوان تابع فعال‌سازی استفاده می‌شود. این تابع را می‌توان به عنوان یک تابع لجستیکی تعمیم یافته در نظر گرفت که رابطه‌ای به صورت معادله (۱) دارد. این لایه یک بردار به صورت $x \in \mathbb{R}^n$ را به عنوان ورودی می‌گیرد و یک بردار خروجی با احتمال $p \in \mathbb{R}^n$ ، به واسطه‌ی تابع Softmax در انتهای معماری، تولید می‌کند.

$$p = \begin{pmatrix} p_1 \\ \vdots \\ p_n \end{pmatrix} \text{ where } p_i = \frac{e^{x_i}}{\sum_{j=1}^n e^{x_j}} \text{ and } n \text{ is number of classes} \quad (1-18)$$

۳-۶ جمع‌بندی

در این فصل، دادگان مورد استفاده در این پژوهش بررسی شد، نحوه عملکرد روش پیشنهادی و شبکه عصبی پیچشی بهینه شده مورد بحث قرار گرفت. نتایج ارزیابی و آزمایش موارد ذکر شده در فصل چهارم ارائه می‌شود.

فصل چهارم

نتایج

۴-۱ مقدمه

در این فصل عملکرد روش پیشنهادی با انجام آزمایش‌های مختلف مورد بررسی قرار خواهد گرفت. نتایج دسته‌بندی بر روی چهار دسته ظرفیت، برانگیختگی، تسلط و دوست داشتن از پایگاه داده DEAP و سه دسته مثبت، منفی و خنثی از پایگاه داده SEED ارزیابی شده است. همچنین، جزییات پیاده‌سازی روش پیشنهادی شرح داده خواهد شد. در ادامه نتایج حاصل از روش پیشنهادی آورده شده است.

۴-۲ جزییات پیاده‌سازی

یکی از معایب شبکه‌های عصبی پیچشی نیاز به توان سخت‌افزاری بالا یا به بیان دیگر واحدهای پردازش گرافیکی (GPU) برای انجام فرآیند آموزش شبکه است زیرا GPU حافظه لازم برای محاسبه الگوریتم GD را فراهم می‌کند. به علاوه، به منظور ایجاد مدل برای آموزش الگوریتم، احتیاج به یک پلتفرم برای ساخت مدل است. در سال‌های اخیر پلتفرم‌های متعددی (همانند TensorFlow, PyTorch, caffe) که بر پایه زبان برنامه‌نویسی پایتون هستند، برای ساخت و آموزش مدل‌های شبکه‌های عصبی عمیق ارایه شده است. در این پایان‌نامه از زبان برنامه‌نویسی پایتون ۳ (همراه با کتابخانه‌های مرتبط همانند pandas, matplotlib, numpy و scikit-learn)، پلتفرم TensorFlow و Keras استفاده شده است. همچنین به منظور تامین سخت‌افزار مورد نیاز از Colaboratory (تحت عنوان Google Colab نیز شناخته می‌شود) استفاده شده است. Google Colab یک سرویس ابری رایگان ارایه شده توسط شرکت گوگل برای محققان حوزه AI است که امکان استفاده رایگان کاربران از CPU, GPU و TPU در پلتفرم‌های

مشهور پایتون (مانند TensorFlow، Keras و PyTorch) را فراهم می‌کند. در سال‌های اخیر، گوگل یک نسخه غیر رایگان از این سرویس را تحت عنوان Google Colab Pro ارائه کرده است. این سرویس یک GPU با حافظه کل ۲۷۱۰۹ مگابایت را فراهم می‌کند که از این میزان حافظه حدود ۲۵۷۲۰ مگابایت قابل دسترسی است. این میزان حافظه نیاز سخت‌افزاری مورد نیاز برای انجام این پروژه را برطرف می‌کند. برای هر مجموعه داده DEAP، تمامی سیگنال‌ها به اندازه ۱۲۸۰×۳۲ و برای مجموعه SEED به اندازه ۳۱۰×۱ تغییر مقیاس داده شدند. برای تمامی لایه‌های پیچشی (به جز لایه دسته‌بندی) شبکه از تابع فعال‌سازی ReLU، برای لایه‌های FC از تابع فعال‌سازی tanh و برای لایه دسته‌بندی از تابع فعال‌سازی softmax استفاده شده است. از تابع آنتروپی متقاطع^۱ به عنوان تابع هزینه برای بهینه‌ساز استفاده شده است. از بهینه‌ساز آدام با اندازه دسته ۵۱۲ در تمام آزمایش‌ها استفاده شده است. از نرخ یادگیری ۰/۰۰۱ برای آموزش مدل استفاده شده است. وزن‌های شبکه به صورت تصادفی مقداردهی اولیه شدند و از مدل‌های از پیش آموزش دیده برای مقداردهی اولیه استفاده نشده است. به بیان دیگر، شبکه از scratch آموزش داده شده است و از هیچ گونه داده‌ای خارج از سیگنال‌های ارائه شده در پایگاه‌های مورد استفاده، استفاده نشده است. برای پیاده‌سازی روش پیشنهادی بهینه‌سازی ابر پارامترها از کتابخانه کاربردی Optuna [۶۸] استفاده شده است. این فریمورک دارای مزیت‌های بسیاری است که از جمله آن‌ها می‌توان به فضای جستجوی گسترده، دسترسی رایگان و امکان موازی‌سازی^۲ هسته‌های GPU اشاره کرد.

۳-۴ معیارهای ارزیابی دسته‌بندی

در این پایان‌نامه از معیارهای اساسی و مهم درزمینه‌ی دسته‌بندی مانند ماتریس درهم‌ریختگی^۳، صحت (acc^۴)، دقت^۵، فراخوانی^۶ (تحت عنوان حساسیت^۷ نیز شناخته می‌شود) و امتیاز اف یک^۸ به منظور ارزیابی عملکرد مدل استفاده شده است. برای ارزیابی میزان کارایی روش پیشنهادی از معیار نرخ تشخیص درست و یا مفهوم عکس آن نرخ خطا استفاده شده است. صحت، نسبت تعداد پیش‌بینی‌های صحیح (مثبت واقعی^۹ و هم منفی واقعی^{۱۰}) به تعداد کل موارد پیش‌بینی شده است و به این صورت تعریف می‌شود:

$$\text{صحت} = \frac{TP + TN}{TP + TN + FP + FN} \quad (۱-۲۴)$$

که در این رابطه TP مثبت واقعی، TN منفی واقعی، FP^{۱۱} مثبت کاذب و FN^{۱۲} منفی کاذب است.

^۱ Crossentropy

^۲ Parallelization

^۳ Confusion Matrix

^۴ Accuracy

^۵ Precision

^۶ Recall

^۷ Sensitivity

^۸ F1 Score

^۹ True Positives

^{۱۰} True Negatives

^{۱۱} False Negative

^{۱۲} False Positive

۴-۴ تقسیم‌بندی مجموعه آموزش و آزمایش

هنگام انتخاب مدل، سه بخش مختلف از مجموعه داده را به صورت مجموعه آموزش (به طور معمول ۸۰ درصد از مجموعه داده)، اعتبارسنجی (این مجموعه تحت عناوین مجموعه بیرون نگه داشته شده یا مجموعه توسعه نیز شناخته می شود و به طور معمول ۱۰ تا ۲۰ درصد از مجموعه داده در نظر گرفته می شود) و مجموعه آزمایش مشخص می شود. بعد از این که مدل انتخاب شد، روی کل مجموعه داده آموزش داده می شود و بر روی داده های دیده نشده آزمایش می شود، به بیان دیگر مدل پیش بینی می کند. اعتبارسنجی متقاطع (CV^1) رایج ترین نوع اعتبارسنجی است و عبارت است از روشی برای انتخاب مدلی که بیش از حد به مجموعه ی آموزش اولیه تکیه نمی کند. از پرکاربرترین روش های CV می توان به دو روش کنارگذاری^۲ و k -بخشی^۳ اشاره کرد. به دلیل نیاز روش k -بخشی به میزان حافظه بالا، در این پایان نامه از روش کنارگذاری استفاده شده است. این روش باعث می شود تا اطمینان لازم از عدم هم پوشانی موضوع بین مجموعه آموزش و آزمایش تضمین شود. در این روش اکثریت موضوع های برای مجموعه آموزش و تعدادی برای مجموعه آزمایش کنار گذاشته می شود. در این پژوهش، ۶۵ درصد از مجموعه داده را برای آموزش، ۱۵ درصد برای مجموعه اعتبارسنجی و ۲۰ درصد برای مجموعه آزمایش در نظر گرفته شد.

۴-۵ ارزیابی روش پیشنهادی

برای ارزیابی روش پیشنهادی، در هر یک از پایگاه های داده DEAP و SEED که در فصل سوم شرح داده شدند، در ابتدا پیش پردازش به صورتی که در فصل سوم بیان شد، انجام می شود و به شبکه اعمال می شود. تمامی مقادیر گزارش شده مربوط به مجموعه آزمون پایگاه داده های مورد استفاده هستند.


۴-۵-۱ نتایج بر روی مجموعه داده DEAP

ابر پارامترها به این دلیل مهم هستند که مستقیماً رفتار الگوریتم آموزشی را کنترل می کنند و تاثیر بسزایی بر عملکرد مدل در حال آموزش دارند. برای مثال نتایج بر روی دسته ظرفیت قبل از تنظیم ابر پارامترها در شکل ۴-۱ نشان داده شده است. با استفاده از تنظیم ابر پارامترها، شبکه حدود چهار درصد در دسته ظرفیت افزایش صحت داشته است.

¹ Cross Validation

² Holdout

³ K-fold



شکل ۴- ۱ ماتریس درهم‌ریختگی برای مجموعه آزمون پایگاه داده DEAP برای دسته ظرفیت بدون تنظیم ابر پارامترها

جدول ۴- ۱ گزارش دسته‌بندی برای مجموعه آزمون پایگاه داده DEAP برای دسته ظرفیت بدون تنظیم ابر پارامترها


دسته	صحت	فراخوانی	امتیاز اف ۱
کم	۰/۹۳۵۸	۰/۹۲۲۲	۰/۹۲۹۰
زیاد	۰/۹۱۱۰	۰/۹۲۶۴	۰/۹۱۸۷

منحنی یادگیری مدل در طول آموزش می‌تواند مشکلات مربوط به یادگیری، مانند کم برآزش یا بیش برآزش را نشان دهند. منحنی یادگیری مجموعه آموزش، منحنی یادگیری که از مجموعه داده‌های آموزشی محاسبه می‌شود و ایده‌ای از چگونگی یادگیری مدل ارائه می‌دهد. منحنی یادگیری اعتبارسنجی، منحنی یادگیری است که از یک مجموعه داده اعتبارسنجی ثابت محاسبه می‌شود و ایده‌ای از نحوه تعمیم مدل را به خوبی ارائه می‌دهد. شکل و پویایی یک منحنی یادگیری را می‌توان برای تشخیص رفتار یک مدل شبکه عصبی استفاده کرد. شکل‌های ۲-۴، ۵-۴، ۸-۴ و ۱۱-۴ منحنی صحت مجموعه آموزش و اعتبارسنجی را در طول ۱۰۰ دوره به ترتیب در دسته ظرفیت، برانگیختگی، تسلط و دوست داشتن نشان می‌دهد. زمانی که مدل روی داده‌های آموزشی عملکرد خوبی دارد اما در داده‌های اعتبارسنجی عملکرد خوبی ندارد، مدل دچار بیش برآزش می‌شود.


ماتریس درهم‌ریختگی برای چهار دسته ظرفیت، برانگیختگی، تسلط و دوست داشتن را به ترتیب در شکل‌های ۴-۴، ۷-۴، ۱۰-۴ و ۱۳-۴ نشان داده شده است. ماتریس، مقایسه مقادیر واقعی با مقادیر پیش‌بینی شده برای هر دسته را نشان می‌دهد. برای مثال در دسته ظرفیت ماتریس نشان می‌دهد که در ظرفیت کم، ۰/۰۳ از نمونه‌ها به اشتباه ظرفیت بالا تشخیص داده شده است. قطر اصلی صحت

پیش‌بینی احساسات را نشان می‌دهد.

نتایج دسته ظرفیت




شکل ۴-۲ منحنی acc مجموعه آموزش و اعتبارسنجی پایگاه داده DEAP برای دسته ظرفیت



شکل ۴-۳ منحنی تابع هزینه مجموعه آموزش و اعتبارسنجی پایگاه داده DEAP برای دسته ظرفیت


جدول ۴-۲ گزارش دسته‌بندی برای مجموعه آزمون پایگاه داده DEAP برای دسته ظرفیت

دسته	صحت	فراخوانی	امتیاز اف ۱	تعداد نمونه‌ها
کم	۰/۹۶۵۶	۰/۹۶۹۷	۰/۹۶۷۶	۳۶۴۴
زیاد	۰/۹۶۳۷	۰/۹۵۸۸	۰/۹۶۱۲	۳۰۲۴




شکل ۴-۴ ماتریس درهم‌ریختگی برای مجموعه آزمون پایگاه داده DEAP برای دسته ظرفیت

نتایج دسته برانگیختگی




شکل ۴-۵ منحنی acc مجموعه آموزش و اعتبارسنجی پایگاه داده DEAP برای دسته برانگیختگی



شکل ۴-۶ منحنی تابع هزینه مجموعه آموزش و اعتبارسنجی پایگاه داده DEAP برای دسته برانگیختگی


جدول ۴-۳ گزارش دسته‌بندی برای مجموعه آزمون پایگاه داده DEAP برای دسته برانگیختگی

دسته	صحت	فراخوانی	امتیاز اف ۱	تعداد نمونه‌ها
کم	۰/۹۶۴۸	۰/۹۸۸۹	۰/۹۷۶۷	۳۵۶۸
زیاد	۰/۹۸۷۶	۰/۹۶۰۷	۰/۹۷۳۹	۳۱۷۴




شکل ۴-۷ ماتریس درهم‌ریختگی برای مجموعه آزمون پایگاه داده DEAP برای دسته برانگیختگی

نتایج دسته تسلط




شکل ۴-۸ منحنی acc مجموعه آموزش و اعتبارسنجی پایگاه داده DEAP برای دسته تسلط



شکل ۴-۹ منحنی تابع هزینه مجموعه آموزش و اعتبارسنجی پایگاه داده DEAP برای دسته تسلط


جدول ۴-۴ گزارش دسته‌بندی برای مجموعه آزمون پایگاه داده DEAP برای دسته تسلط

تعداد نمونه‌ها	امتیاز اف ۱	فراخوانی	صحت	دسته
۳۵۷۱	۰/۹۸۲۷	۰/۹۸۹۵	۰/۹۷۵۹	کم
۳۲۱۵	۰/۹۸۰۸	۰/۹۷۳۴	۰/۹۸۸۳	زیاد




شکل ۴-۱۰ ماتریس درهم‌ریختگی برای مجموعه آزمون پایگاه داده DEAP برای دسته تسلط

نتایج دسته دوست داشتن




شکل ۴-۱۱ منحنی acc مجموعه آموزش و اعتبارسنجی پایگاه داده DEAP برای دسته دوست داشتن



شکل ۴-۱۲ منحنی تابع هزینه مجموعه آموزش و اعتبارسنجی پایگاه داده DEAP برای دسته دوست داشتن

جدول ۴-۵ گزارش دسته‌بندی برای مجموعه آزمون پایگاه داده DEAP برای دسته دوست داشتن


تعداد نمونه‌ها	امتیاز اف ۱	فراخوانی	صحت	دسته
۲۶۲۵	۰/۹۷۵۷	۰/۹۶۱۲	۰/۹۹۰۶	دوست داشتن
۴۱۵۶	۰/۹۸۴۵	۰/۹۹۴۰	۰/۹۷۵۱	دوست نداشتن




شکل ۴-۱۳ ماتریس درهم‌ریختگی برای مجموعه آزمون پایگاه داده DEAP برای دسته دوست داشتن

۴-۵-۲ نتایج برروی پایگاه داده SEED

برای ارزیابی شبکه پیشنهادی بر روی مجموعه داده SEED از پوشه استخراج ویژگی این مجموع داده استفاده شد که شامل ویژگی‌های چگالی طیفی توان (PSD)، آنتروپی تفاضلی (DE)، عدم تقارن دیفرانسیل (DASM)، عدم تقارن منطقی (RASM)، عدم تقارن (ASM) و علیت دیفرانسیل (DCAU) است. پژوهش [۸] آنتروپی تفاضلی و ویژگی چگالی طیف توان استخراج شده از کانال‌های EEG را به‌عنوان ویژگی‌های اصلی نشان دادند. با تکرار آزمایش برای هر دو ویژگی، ویژگی آنتروپی تفاضلی بهترین صحت را در این مجموعه داده نشان داد.




شکل ۴-۱۴ منحنی acc مجموعه آموزش و اعتبارسنجی پایگاه داده SEED



شکل ۴-۱۵ منحنی تابع هزینه مجموعه آموزش و اعتبارسنجی پایگاه داده SEED

جدول ۴ - ۶ گزارش دسته‌بندی برای مجموعه آزمون پایگاه داده SEED

دسته	صحت	فراخوانی	امتیاز اف ۱
منفی	۰/۹۵۴۰	۰/۹۵۸۴	۰/۹۵۶۲
خنثی	۰/۹۵۱۸	۰/۹۵۶۸	۰/۹۵۴۳
مثبت	۰/۹۷۷۸	۰/۹۶۸۵	۰/۹۷۳۱



شکل ۴-۱۶ ماتریس درهم‌ریختگی برای مجموعه آزمون پایگاه داده SEED

فصل پنجم

نتیجه‌گیری و پیشنهادها

۵-۱ جمع‌بندی و نتیجه‌گیری

با توجه به اینکه عواطف نقش مهمی در زندگی روزمره انسان و تصمیم‌گیری‌های مهم زندگی او بازی می‌کنند و هم‌چنین با توجه به اهمیت بازشناسی عواطف در مطالعات پزشکی، روانشناسی و بهبود ارتباطات انسان و رایانه، در این مطالعه، یک چارچوب بهینه‌سازی بر اساس الگوریتم تکاملی ژنتیک چندهدفی برای تنظیم ابر پارامترهای شبکه عصبی پیچشی طراحی شد و از شبکه عصبی پیچشی بهینه‌سازی شده جهت بهبود صحت در تشخیص احساسات مبتنی بر سیگنال الکتریکی مغز استفاده شد. الگوریتم تکاملی ژنتیک چندهدفی یکی از پرکاربردترین و قدرتمندترین الگوریتم‌های موجود برای حل مسایل بهینه‌سازی چند هدفی است و کارایی آن در حل مساله‌های مختلف، به اثبات رسیده است. مزیت استفاده از این الگوریتم در این است که به جای ارایه یک پاسخ بهینه به عنوان جواب نهایی مساله، تعدادی نقاط را به عنوان پاسخ‌های مساله ارایه می‌کند. جواب‌های بدست آمده از این الگوریتم، با توجه به دارا بودن تکنیک‌های منحصر به فرد جستجو، با اطمینان بیشتری به عنوان جواب‌های بهینه مطرح می‌شود. مساله بهینه‌سازی ابر پارامترهای الگوریتم‌های یادگیری در حال حاضر چالش اصلی برای کاربرد آن است. روش‌های جستجوی شبکه‌ای، جستجوی تصادفی و بهینه‌سازی بیزی به عنوان موثرترین روش برای حل مشکل بهینه‌سازی ابر پارامترهای الگوریتم‌های یادگیری مورد توجه قرار گرفته‌اند. روش بهینه‌سازی مبتنی بر الگوریتم‌های تکاملی در سال‌های اخیر نیز در مساله بهینه‌سازی ابر پارامترهای الگوریتم‌های یادگیری مورد استفاده قرار می‌گیرد، نتایج این پژوهش نشان می‌دهد که الگوریتم‌های تکاملی پتانسیل زیادی در حل مساله بهینه‌سازی ابر پارامتر الگوریتم‌های یادگیری دارند. برای اثبات

اثر بخشی پژوهش انجام شده در زمینه تشخیص احساسات، عملکرد روش پیشنهادی با سایر روش‌های استفاده شده در مطالعه‌های پیشین مقایسه می‌شود. نتایج روش پیشنهادی در مجموعه آزمون دو پایگاه داده مورد استفاده در مقایسه با روش‌های پیشرفته در حوزه تشخیص احساسات در جدول‌های ۵-۱ و ۵-۲ نشان داده شده است. در این جداول روش‌های معتبر سال‌های اخیر مبتنی بر ML و به‌ویژه روش‌های مبتنی بر DL با روش پیشنهادی این مطالعه از لحاظ صحت و تعداد دسته‌ها مقایسه شده‌اند. برای مثال کیو و همکاران با استفاده از شبکه عصبی پیچشی منطقه‌ای - نامتقارن^۱ (RACNN) به استخراج ویژگی‌های متمایز و تشخیص دقیق احساسات پرداختند مطالعه آن‌ها بر استخراج ویژگی‌های زمانی، منطقه‌ای و نامتقارن متمرکز بود، آن‌ها از لایه‌های پیچشی یک‌بعدی پیوسته در استخراج‌کننده ویژگی زمانی و سپس از دولایه پیچشی دوبعدی برای گرفتن اطلاعات منطقه‌ای استفاده کردند. سپس یک لایه دیفرانسیل نامتقارن^۲ (ADL) برای استخراج ویژگی نامتقارن احساسات بین لوب چپ و راست مغز پیشنهاد کردند و دقت تشخیص بیش از ۹۵ درصد برای دسته‌های ظرفیت و برانگیختگی در مجموعه داده DEAP به دست آوردند. این در حالی است که مدل پیشنهادی این مطالعه با شبکه‌ای به مراتب ساده‌تر و تعداد پارامتر کمتر به صحت قابل قبولی رسید. همچنین، در پژوهش لئو و همکاران یک الگوریتم تشخیص احساسات مستقل از موضوع را بر اساس شبکه عصبی پیچشی تجربی پویا^۳ (DECNN) با استفاده از سیگنال‌های EEG پیشنهاد کردند. برای استخراج ویژگی‌های سیگنال‌های EEG در مجموعه داده SEED، آن‌ها از الگوریتم آنتروپی دیفرانسیل پویا (DDE) که ترکیب الگوریتم تجزیه حالت تجربی^۴ (EMD) و تحلیل آنتروپی است استفاده کردند، دسته‌ها به صورت باینری در نظر گرفته شد (مثبت و خنثی) و به بالاترین صحت ۹۷/۵۶ درصد با در نظر گرفتن ۲۰ الکتروود رسید [۶۹]. بنابراین می‌توان گفت که صحت به دست آمده از این مطالعه نسبت به پیشرفته‌ترین روش‌ها قابل ملاحظه است.

جدول ۵-۱ مقایسه مدل این مطالعه با مطالعات قبلی در مجموعه داده DEAP

پژوهش	مواد و روش	تعداد دسته‌ها	صحت (%)
اتکینسون و کامپوس (۲۰۱۶) [۷۰]	ماشین بردار پشتیبان و الگوریتم ژنتیک	۲ (برانگیختگی، ظرفیت)	برانگیختگی: ۷۳/۰۶ ظرفیت: ۷۳/۱۴
الهاگری و همکاران (۲۰۱۷) [۵۳]	شبکه عصبی بازگشتی و حافظه کوتاه مدت ماندگار	۳ (برانگیختگی، ظرفیت، دوست داشتن)	برانگیختگی: ۸۵/۶۵ ظرفیت: ۸۵/۴۵ دوست داشتن: ۸۷/۹۹
سالاما و همکاران (۲۰۱۸)	شبکه عصبی پیچشی ۳-بعدی	۲ (برانگیختگی، ظرفیت)	برانگیختگی: ۸۸/۴۹ ظرفیت: ۸۷/۴۴

^۱ Regional-Asymmetric Convolutional Neural Network

^۲ Asymmetric differential layer

^۳ Dynamic empirical convolutional neural network

^۴ Empirical mode decomposition

پژوهش	مواد و روش	تعداد دسته‌ها	صحت (%)
[۱۵]			
نکیسا و همکاران (۲۰۱۸) [۳۳]	شبکه عصبی احتمالی و الگوریتم‌های تکاملی	۴ LALV, HALV,) (LAHV, HAHV	۶۵/۳۱±۳/۲۲
یانگ و همکاران (۲۰۱۹) [۶۱]	شبکه پیچشی چند ستونی	۲ (برانگیختگی، ظرفیت)	برانگیختگی: ۹۰/۶۵ ظرفیت: ۹۰/۰۱
کیو و همکاران (۲۰۲۰) [۷۱]	شبکه عصبی پیچشی منطقه ای- نامتقارن	۲ (برانگیختگی، ظرفیت)	برانگیختگی: ۹۷/۱۱ ظرفیت: ۹۶/۶۵
یین و همکاران (۲۰۲۱) [۶۷]	شبکه‌های عصبی گراف پیچشی و حافظه کوتاه مدت ماندگار	۲ (برانگیختگی، ظرفیت)	وابسته به سوژه: برانگیختگی: ۹۰/۶۰ ظرفیت: ۹۰/۴۵ مستقل از سوژه: برانگیختگی: ۸۵/۲۷ ظرفیت: ۸۴/۸۱
توپیک و روسو (۲۰۲۱) [۷۲]	شبکه عصبی پیچشی و ماشین بردار پشتیبان	۲ (برانگیختگی، ظرفیت)	برانگیختگی: ۷۷/۷۲ ظرفیت: ۷۶/۶۱
این مطالعه	شبکه عصبی پیچشی و الگوریتم ژنتیک چند هدفی	۴ (برانگیختگی، ظرفیت، دوست داشتن، تسلط)	برانگیختگی: ۹۷/۵۴ ظرفیت: ۹۶/۴۷ دوست داشتن: ۹۸/۱۰ تسلط: ۹۸/۱۸

جدول ۵- ۲ مقایسه مدل این مطالعه با مطالعات قبلی در مجموعه داده SEED

پژوهش	مواد و روش	تعداد دسته‌ها	صحت (%)
لیو و همکاران (۲۰۱۶) [۷۳]	رمزگذار خودکار عمیق	۳ (مثبت، خنثی، منفی)	۹۱/۰۱
ژنگ و همکاران (۲۰۱۷) [۸]	ماشین یادگیری افراطی	۳ (مثبت، خنثی، منفی)	۹۱/۰۷
سونگ و همکاران (۲۰۱۸) [۵۷]	شبکه‌های عصبی گراف پیچشی	میانگین صحت	وابسته به سوژه: ۹۰/۴ مستقل از سوژه: ۷۹/۹۵
وانگ و همکاران (۲۰۲۰) [۷۴]	شبکه عصبی پیچشی و نقشه های توزیع فرکانس الکترو	میانگین صحت	۹۰/۵۹
لیو و همکاران (۲۰۲۰) [۶۹]	شبکه عصبی پیچشی تجربی پویا	۳ (مثبت، خنثی)	۹۷/۵۶

پژوهش	مواد و روش	تعداد دسته‌ها	صحت (%)
توپیک و روسو (۲۰۲۱) [۷۲]	شبکه عصبی پیچشی و ماشین بردار پشتیبان	ظرفیت	$88/45 \pm 1/5$
این مطالعه	شبکه عصبی پیچشی و الگوریتم ژنتیک چند هدفی	۳ (مثبت، خنثی، منفی)	۹۶/۱۴

۲-۵ پیشنهادهای فعالیت‌های آینده

مجموعه توضیحات فوق نشان می‌دهد این مطالعه توانسته است به صورت مطلوب به بازشناسی عواطف بپردازد؛ اما با توجه به گستردگی موضوع و زمان کم برای انجام این مطالعه بدیهی است که نتوانسته تمامی موضوعات را پوشش دهد. از جمله پیشنهادهایی که برای پیشرفت در زمینه محاسبات عاطفی می‌توان ارایه داد، عبارت‌اند از:

می‌توان رویکرد پیشنهادی را برای بهینه‌سازی معماری‌های عمیق‌تر مانند Inception، DenseNet و ResNet استفاده کرد.

الگوریتم‌های بهینه‌سازی تکاملی دیگر مانند الگوریتم ازدحام ذرات، الگوریتم کلونی مورچگان و ... برای تنظیم ساختار شبکه عصبی عمیق پیشنهاد می‌شود.

از آنجاکه تعداد پارامترهای شبکه پیشنهادی در مقایسه با بسیاری از روش‌های دیگر در این حوزه، به‌طور چشم‌گیری کمتر است. این مهم باعث می‌شود شبکه پیشنهادی برای کاربردهای بلادرنگ در حوزه تشخیص احساسات بهینه باشد.

نتایج در یک کاربرد عملی در حوزه پزشکی، روانشناسی و بازی استفاده شود.

منابع و مأخذ

- [1] X. Gu *et al.*, "EEG-based brain-computer interfaces (BCIs): A survey of recent studies on signal sensing technologies and computational intelligence approaches and their applications," *IEEE/ACM transactions on computational biology and bioinformatics*, 2021.
- [2] T. Ball, M. Kern, I. Mutschler, A. Aertsen, and A. Schulze-Bonhage, "Signal quality of simultaneously recorded invasive and non-invasive EEG," *Neuroimage*, vol. 46, no. 3, pp. 708-716, 2009.
- [3] M. R. Islam *et al.*, "Emotion recognition from EEG signal focusing on deep learning and shallow learning techniques," *IEEE Access*, vol. 9, pp. 94601-94624, 2021.
- [4] S. N. Abdulkader, A. Atia, and M.-S. M. Mostafa, "Brain computer interfacing: Applications and challenges," *Egyptian Informatics Journal*, vol. 16, no. 2, pp. 213-230, 2015.
- [5] X. Zhang, L. Yao, X. Wang, J. Monaghan, D. Mcalpine, and Y. Zhang, "A survey on deep learning based brain computer interface: Recent advances and new frontiers," *arXiv preprint arXiv:1905.04149*, vol. 96, 2019.
- [6] P. Ekman and W. V. Friesen, "Constants across cultures in the face and emotion," *Journal of personality and social psychology*, vol. 17, no. 2, p. 124, 1971.
- [7] R. Davidson, "Frontal versus parietal EEG asymmetry during positive and negative affect," *Psychophysiology*, vol. 16, no. 2, pp. 202-203, 1979.
- [8] W.-L. Zheng, J.-Y. Zhu, and B.-L. Lu, "Identifying stable patterns over time for emotion recognition from EEG," *IEEE Transactions on Affective Computing*, vol. 10, no. 3, pp. 417-429, 2017.
- [9] M. M. Bradley and P. J. Lang, "Measuring emotion: the self-assessment manikin and the semantic differential," *Journal of behavior therapy and experimental psychiatry*, vol. 25, no. 1, pp. 49-59, 1994.
- [10] L. Shu *et al.*, "A review of emotion recognition using physiological signals," *Sensors*, vol. 18, no. 7, p. 2074, 2018.
- [11] E. C. Leuthardt, G. Schalk, J. Roland, A. Rouse, and D. W. Moran, "Evolution of brain-computer interfaces: going beyond classic motor physiology," *Neurosurgical focus*, vol. 27, no. 1, p. E4, 2009.
- [12] K. Anderson and P. W. McOwan, "A real-time automated system for the recognition of human facial expressions," *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, vol. 36, no. 1, pp. 96-105, 2006.
- [13] Z. Liu *et al.*, "A facial expression emotion recognition based human-robot interaction system," *IEEE/CAA Journal of Automatica Sinica*, vol. 4, no. 4, pp. 668-676, 2017.
- [14] M. Swain, A. Routray, and P. Kabisatpathy, "Databases, features and classifiers for speech emotion recognition: a review," *International Journal of Speech Technology*, vol. 21, no. 1, pp. 93-120, 2018.
- [15] E. S. Salama, R. A. El-Khoribi, M. E. Shoman, and M. A. W. Shalaby, "EEG-based emotion recognition using 3D convolutional neural networks," *Int. J. Adv. Comput. Sci. Appl*, vol. 9, no. 8, pp. 329-337, 2018.

- [16] O. Sporns and G. Tononi, "Structural determinants of functional brain dynamics," in *Handbook of Brain Connectivity*: Springer, 2007, pp. 117-147.
- [17] E. Marder and J.-M. Goaillard, "Variability, compensation and homeostasis in neuron and network function," *Nature Reviews Neuroscience*, vol. 7, no. 7, pp. 563-574, 2006.
- [18] S. R. Waldstein, W. J. Kop, L. A. Schmidt, A. J. Haufler, D. S. Krantz, and N. A. Fox, "Frontal electrocortical and cardiovascular reactivity during happiness and anger," *Biological psychology*, vol. 55, no. 1, pp. 3-23, 2000.
- [19] H. Jasper, "Report of the committee on methods of clinical examination in electroencephalography," *Electroencephalogr Clin Neurophysiol*, vol. 10, pp. 370-375, 1958.
- [20] Y. Hua, J. Guo, and H. Zhao, "Deep belief networks and deep learning," in *Proceedings of 2015 International Conference on Intelligent Computing and Internet of Things*, 2015: IEEE, pp. 1-4.
- [21] A. Graves, "Supervised sequence labelling," in *Supervised sequence labelling with recurrent neural networks*: Springer, 2012, pp. 5-13.
- [22] N. Buduma and N. Locascio, *Fundamentals of deep learning: Designing next-generation machine intelligence algorithms*. " O'Reilly Media, Inc.", 2017.
- [23] C. Wei, L.-l. Chen, Z.-z. Song, X.-g. Lou, and D.-d. Li, "EEG-based emotion recognition using simple recurrent units network and ensemble learning," *Biomedical Signal Processing and Control*, vol. 58, p. 101756, 2020.
- [24] A. Shrestha and A. Mahmood, "Review of deep learning algorithms and architectures," *IEEE Access*, vol. 7, pp. 53040-53065, 2019.
- [25] R. Salakhutdinov and H. Larochelle, "Efficient learning of deep Boltzmann machines," in *Proceedings of the thirteenth international conference on artificial intelligence and statistics*, 2010: JMLR Workshop and Conference Proceedings, pp. 693-700.
- [26] C. Szegedy *et al.*, "Going deeper with convolutions," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2015, pp. 1-9.
- [27] I. Goodfellow, "Deep Learning-Ian Goodfellow, Yoshua Bengio, Aaron Courville- Google Books," ed: MIT Press. <https://books.google.com/books>, 2016.
- [28] J. Gu *et al.*, "Recent advances in convolutional neural networks," *Pattern Recognition*, vol. 77, pp. 354-377, 2018.
- [29] X.-W. Chen and X. Lin, "Big data deep learning: challenges and perspectives," *IEEE access*, vol. 2, pp. 514-525, 2014.
- [30] J. Zhang, "Gradient descent based optimization algorithms for deep learning models training," *arXiv preprint arXiv:1903.03614*, 2019.
- [31] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," *arXiv preprint arXiv:1412.6980*, 2014.

- [32] "Hyperparameter optimization." WikiHr.
https://hrvwiki.net/Wikipedia_Hyperparameter_optimization#Evolutionary_optimization (accessed Feb. 5, 2022).
- [33] B. Nakisa, M. N. Rastgoo, D. Tjondronegoro, and V. Chandran, "Evolutionary computation algorithms for feature selection of EEG-based emotion recognition using mobile sensors," *Expert Systems with Applications*, vol. 93, pp. 143-155, 2018.
- [34] J. Bergstra and Y. Bengio, "Random search for hyper-parameter optimization," *Journal of machine learning research*, vol. 13, no. 2, 2012.
- [35] V. Kachitvichyanukul, "Comparison of three evolutionary algorithms: GA, PSO, and DE," *Industrial Engineering and Management Systems*, vol. 11, no. 3, pp. 215-223, 2012.
- [36] N. M. Aszemi and P. Dominic, "Hyperparameter optimization in convolutional neural network using genetic algorithms," *Int. J. Adv. Comput. Sci. Appl*, vol. 10, no. 6, pp. 269-278, 2019.
- [37] S. Katoch, S. S. Chauhan, and V. Kumar, "A review on genetic algorithm: past, present, and future," *Multimedia Tools and Applications*, vol. 80, no. 5, pp. 8091-8126, 2021.
- [38] K. Deb, A. Pratap, S. Agarwal, and T. Meyarivan, "A fast and elitist multiobjective genetic algorithm: NSGA-II," *IEEE transactions on evolutionary computation*, vol. 6, no. 2, pp. 182-197, 2002.
- [39] T. B. Alakus, M. Gonen, and I. Turkoglu, "Database for an emotion recognition system based on eeg signals and various computer games—GAMEEMO," *Biomedical Signal Processing and Control*, vol. 60, p. 101951, 2020.
- [40] W.-L. Zheng and B.-L. Lu, "Investigating critical frequency bands and channels for EEG-based emotion recognition with deep neural networks," *IEEE Transactions on Autonomous Mental Development*, vol. 7, no. 3, pp. 162-175, 2015.
- [41] J. A. M. Correa, M. K. Abadi, N. Sebe, and I. Patras, "Amigos: A dataset for affect, personality and mood research on individuals and groups," *IEEE Transactions on Affective Computing*, 2018.
- [42] S. Katsigiannis and N. Ramzan, "DREAMER: A database for emotion recognition through EEG and ECG signals from wireless low-cost off-the-shelf devices," *IEEE journal of biomedical and health informatics*, vol. 22, no. 1, pp. 98-107, 2017.
- [43] S. Koelstra *et al.*, "Deap: A database for emotion analysis; using physiological signals," *IEEE transactions on affective computing*, vol. 3, no. 1, pp. 18-31, 2011.
- [44] M. Soleymani, J. Lichtenauer, T. Pun, and M. Pantic, "A multimodal database for affect recognition and implicit tagging," *IEEE transactions on affective computing*, vol. 3, no. 1, pp. 42-55, 2011.
- [45] P. J. Lang, "International affective picture system (IAPS): Affective ratings of pictures and instruction manual," *Technical report*, 2005.
- [46] M. Bradley and P. Lang, "The international affective digitized sounds: affective ratings of sounds and instruction manual (Technical Report No.

- B-3). University of Florida," *NIMH Center for the Study of Emotion and Attention, Gainesville, FL*, 2007.
- [47] X.-W. Wang, D. Nie, and B.-L. Lu, "Emotional state classification from EEG data using machine learning approach," *Neurocomputing*, vol. 129, pp. 94-106, 2014.
 - [48] J. Zhang, M. Chen, S. Zhao, S. Hu, Z. Shi, and Y. Cao, "ReliefF-based EEG sensor selection methods for emotion recognition," *Sensors*, vol. 16, no. 10, p. 1558, 2016.
 - [49] J. Li, Z. Zhang, and H. He, "Implementation of eeg emotion recognition system based on hierarchical convolutional neural networks," in *International Conference on Brain Inspired Cognitive Systems*, 2016: Springer, pp. 22-33.
 - [50] J. Li, Z. Zhang, and H. He, "Hierarchical convolutional neural networks for EEG-based emotion recognition," *Cognitive Computation*, vol. 10, no. 2, pp. 368-380, 2018.
 - [51] W. Zheng, "Multichannel EEG-based emotion recognition via group sparse canonical correlation analysis," *IEEE Transactions on Cognitive and Developmental Systems*, vol. 9, no. 3, pp. 281-290, 2016.
 - [52] Z. Lan, O. Sourina, L. Wang, and Y. Liu, "Real-time EEG-based emotion monitoring using stable features," *The Visual Computer*, vol. 32, no. 3, pp. 347-358, 2016.
 - [53] S. Alhagry, A. A. Fahmy, and R. A. El-Khoribi, "Emotion recognition based on EEG using LSTM recurrent neural network," *Emotion*, vol. 8, no. 10, pp. 355-358, 2017.
 - [54] Z. Li, X. Tian, L. Shu, X. Xu, and B. Hu, "Emotion recognition from EEG using RASM and LSTM," in *International Conference on Internet Multimedia Computing and Service*, 2017: Springer, pp. 310-318.
 - [55] Y. Yang, Q. Wu, M. Qiu, Y. Wang, and X. Chen, "Emotion recognition from multi-channel EEG through parallel convolutional recurrent neural network," in *2018 International Joint Conference on Neural Networks (IJCNN)*, 2018: IEEE, pp. 1-7.
 - [56] Y. Yang, Q. Wu, Y. Fu, and X. Chen, "Continuous convolutional neural network with 3d input for eeg-based emotion recognition," in *International Conference on Neural Information Processing*, 2018: Springer, pp. 433-443.
 - [57] T. Song, W. Zheng, P. Song, and Z. Cui, "EEG emotion recognition using dynamical graph convolutional neural networks," *IEEE Transactions on Affective Computing*, vol. 11, no. 3, pp. 532-541, 2018.
 - [58] V. Gupta, M. D. Chopda, and R. B. Pachori, "Cross-subject emotion recognition using flexible analytic wavelet transform from EEG signals," *IEEE Sensors Journal*, vol. 19, no. 6, pp. 2266-2274, 2018.
 - [59] Y. Luo and B.-L. Lu, "EEG data augmentation for emotion recognition using a conditional Wasserstein GAN," in *2018 40th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, 2018: IEEE, pp. 2535-2538.

- [60] S. Taran and V. Bajaj, "Emotion recognition from single-channel EEG signals using a two-stage correlation and instantaneous frequency-based filtering method," *Computer methods and programs in biomedicine*, vol. 173, pp. 157-165, 2019.
- [61] H. Yang, J. Han, and K. Min, "A multi-column CNN model for emotion recognition from EEG signals," *Sensors*, vol. 19, no. 21, p. 4736, 2019.
- [62] C. Qing, R. Qiao, X. Xu, and Y. Cheng, "Interpretable emotion recognition using EEG signals," *Ieee Access*, vol. 7, pp. 94160-94170, 2019.
- [63] Z. Gao, Y. Li, Y. Yang, X. Wang, N. Dong, and H.-D. Chiang, "A GPSO-optimized convolutional neural networks for EEG-based emotion recognition," *Neurocomputing*, vol. 380, pp. 225-235, 2020.
- [64] H. Chao and Y. Liu, "Emotion recognition from multi-channel EEG signals by exploiting the deep belief-conditional random field framework," *IEEE Access*, vol. 8, pp. 33002-33012, 2020.
- [65] Y. Zhao, J. Yang, J. Lin, D. Yu, and X. Cao, "A 3D Convolutional Neural Network for Emotion Recognition based on EEG Signals," in *2020 International Joint Conference on Neural Networks (IJCNN)*, 2020: IEEE, pp. 1-6.
- [66] P. Zhong, D. Wang, and C. Miao, "EEG-based emotion recognition using regularized graph neural networks," *IEEE Transactions on Affective Computing*, 2020.
- [67] Y. Yin, X. Zheng, B. Hu, Y. Zhang, and X. Cui, "EEG emotion recognition using fusion model of graph convolutional neural networks and LSTM," *Applied Soft Computing*, vol. 100, p. 106954, 2021.
- [68] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A next-generation hyperparameter optimization framework," in *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining*, 2019, pp. 2623-2631.
- [69] S. Liu, X. Wang, L. Zhao, J. Zhao, Q. Xin, and S.-H. Wang, "Subject-independent emotion recognition of EEG signals based on dynamic empirical convolutional neural network," *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, vol. 18, no. 5, pp. 1710-1721, 2020.
- [70] J. Atkinson and D. Campos, "Improving BCI-based emotion recognition by combining EEG feature selection and kernel classifiers," *Expert Systems with Applications*, vol. 47, pp. 35-41, 2016.
- [71] H. Cui, A. Liu, X. Zhang, X. Chen, K. Wang, and X. Chen, "EEG-based emotion recognition using an end-to-end regional-asymmetric convolutional neural network," *Knowledge-Based Systems*, vol. 205, p. 106243, 2020.
- [72] A. Topic and M. Russo, "Emotion recognition based on EEG feature maps through deep learning network," *Engineering Science and Technology, an International Journal*, 2021.

- [73] W. Liu, W.-L. Zheng, and B.-L. Lu, "Emotion recognition using multimodal deep learning," in *International conference on neural information processing*, 2016: Springer, pp. 521-529.
- [74] F. Wang *et al.*, "Emotion recognition with convolutional neural network and EEG-based EFDMs," *Neuropsychologia*, vol. 146, p. 107506, 2020.

Abstract

As an important field of research in Human-Machine Interactions, emotion recognition based on the electroencephalography (EEG) signals has become common research. Deep learning has enhanced the performance of brain-computer interface systems significantly in recent years. An urgent problem in the field of deep learning is the optimization of model construction, hyper-parameter optimization is the process of finding the right combination of hyper-parameter values in order to achieve maximum performance on data in a reasonable amount of time. Any deep convolutional neural networks (CNN) has hyper-parameters such as number of convolutional layer, number of filters, filter size, activation function, learning rate and number of fully connected layer. Generally, these hyper-parameters are selected manually and it varies for different models and datasets. To address this, several works have been proposed such as grid search which is limited to low dimensional space, and tails which use random selection. In this project, we propose an automatically optimization framework using Non-dominated Sorting Genetic Algorithm II to select the structure. The proposed method uses a layer-by-layer strategy to optimize deep neural network hyper-parameters. The use of NSGAI in hyper-parameters tuning aims is to find a structure that minimizes the cost function or maximizes the accuracy of EEG-based emotion detection. The public datasets of DEAP and SEED are used for testing. Experimental results show that the proposed network is more effective than conventional CNN methods on the emotion recognitions. The public datasets of DEAP and SEED are used for training and evaluation. Experimental results show that the proposed algorithm is more effective than other methods on the emotion recognitions. For the DEAP dataset, we have achieved test accuracy of 96.46% for Valence, 97.54% for Arousal, 98.18% for Dominance, and finally 98.10% for liking. For the SEED dataset, however, the best recognition accuracy reaches 96.14%. The evaluations of this method on emotion recognition problem revealed significant improvements in the testing accuracy when compared with other studies using deep neural networks (DNNs).

Keywords: Convolutional Neural Networks (CNNs); hyper-parameter optimization; electroencephalography (EEG); Emotion recognition; multi-objective optimization



University of Isfahan
Faculty of Engineering
Department of Biomedical Engineering

M.Sc. Thesis

**Using Evolutionary Computation Algorithms for EEG-based
Emotion Recognition**

Supervisor:
Dr. Mohammadreza Yazdchi

By:
Parichehr Moradi

February 2022